

AT-SKM-Net: 面向动态图上线性硬约束可行性的加速可训练采样 Kaczmarz–Motzkin 框架

Xiaochen Zhang, Haoyu Zhu, Yao Zhang, Qingchun Hou*

浙江大学

* 通讯作者: houqingchun@zju.edu.cn

摘要

带线性约束的图上优化是关键基础设施决策的核心环节，但海量严格硬约束与高维规模让它的可扩展性受限。近期的投影式方法——可训练采样 Kaczmarz–Motzkin 网络 (T-SKM-Net) 是其中一例——虽然能保证解的可行性，却要对整个约束集做处理，还要付出昂贵的矩阵分解代价，因而在动态环境里计算开销很高。我们提出加速可训练 SKM (AT-SKM) 框架来补上这一环。为了让计算集中到真正起作用的约束上、消除冗余计算，我们用拓扑感知异构图神经网络来引导混合采样。为了高效处理图上约束的拓扑变化，我们引入 Cholesky 更新机制，在低秩扰动下把等式投影的复杂度从 $\mathcal{O}(N^3)$ 降到 $\mathcal{O}(N^2)$ 。随机几何图、N-1 安全约束直流最优潮流和最小成本燃气输运问题上的实验表明，AT-SKM 最多可减少 85% 的迭代次数，SKM 层加速 2.95–7.29 倍，同时约束违背始终为零。

1 引言

约束优化在众多关键工程系统的决策中都是必需的一环 [1]。其中，基于图的表述对基础设施领域尤其重要，电网调度和交通网络流控制都属于这一类 [2]。这类应用面临的是双重困难：一方面，决策必须严格满足物理规律或运行要求施加的硬约束，哪怕很小的违背也不可接受；另一方面，真实环境高度动态——电网里一条线路突然故障，底层图的拓扑就会即时改变 [3]。这要求求解器适应拓扑变化，并在毫秒内给出可行解；而传统优化算法面对大规模网络和频繁的拓扑扰动，很难满足实时控制的要求。

近年来，神经网络凭借很强的函数逼近能力，被广泛用于各类优化问题的解的近似 [4], [5]。但标准神经网络本身无法保证其输出的可行性。已有的应对办法分成两类。软约束方法用惩罚项压制违背，却没有理论上的安全性保证，在安全攸关的场合风险不小 [6], [7], [8]。硬约束方法——可微优化层 [9], [10], [11] 和投影式方法 [12], [13]——能强制可行性，但推理时往往要求解复杂的内嵌优化子问题，计算可扩展性上有明显瓶颈，难以用到上千节点的大规模图数据上 [14]。

近期，[15] 提出了可训练采样 Kaczmarz–Motzkin 网络 (T-SKM-Net) 框架，把 SKM 算法嵌入网络，从而在保证线性硬约束得到满足的同时实现了端到端训练。不过 T-SKM-Net 依赖 SVD 处理等式约束投影，拓扑一变就要重算，代价很高。而且实际优化问题里通常只有少数约束是有效的，盲目均匀采样把大量计算预算浪费在冗余约束上，收敛速度因此受限。

针对这些困难，我们提出 AT-SKM-Net——一个面向动态图上优化的可训练硬约束修正框架。我们没有把可行性修正当成后处理步骤，而是让修正过程去贴合图上约束问题的两条结构特性：拓扑扰动是低秩的，有效约束是稀疏的。主要贡献如下：

- 建立一个感知图结构的可训练框架，既保留了投影式 SKM 的硬可行性保证，又解决了大规模约束与拓扑扰动带来的实时可扩展性瓶颈。
- 同时加速 SKM 修正的两个瓶颈环节：等式投影与不等式迭代。等式投影上用 Cholesky 更新，在低秩拓扑扰动下把适应代价从 $\mathcal{O}(N^3)$ 降到 $\mathcal{O}(N^2)$ ；不等式迭代上用有效集引导的混合采样，把计算集中到可能取等的约束上。
- 设计一个适配动态拓扑的异构图神经网络 (HGNN)，为 AT-SKM-Net 同时提供热启动候选与有效集评分。实验显示 AT-SKM-Net 在取得显著加速的同时，等式与不等式约束违背都保持为零。

2 相关工作

已有工作在提升神经求解器与传统优化方法所给解的可行性上已取得长足进展。与本文相关的文献大致可分三支：满足硬约束的神经方法、SKM 算法的加速策略，以及有效集预测的应用。

2.1 满足硬约束的神经方法

基于可微优化层的方法。 这类做法把优化问题或迭代过程直接嵌进神经推理流程。OptNet [9] 与 CvxPyLayers [10] 这类精确求解器让 QP 与一般凸问题可微，但计算复杂度高，可扩展性受限。SCQPTH

[16] 用一阶 ADMM 加速求解, 却仍局限于凸 QP 表述。类似的迭代投影方法, 如 LinSATNet [17] 与矫正正则化的 GLinSAT [4], 能够达到约束满足, 但因为需要大量迭代, 计算代价同样偏高。

可行集参数化方法。 这类方法把隐空间映射到可行域内。CP [18] 为线性不等式参数化解, 但维度一高就吃力。Rayen [19] 与基于缩放的方法 [20] 把支持范围扩展到二次约束及其他凸约束, 但都依赖一个事先找好的严格可行内点, 对随输入动态变化的约束并不合适。安全决策规则 [14] 用求解器与安全网络的凸组合来保证可行性, 要求约束集是凸的, 而且本质上要牺牲最优性。

修正与投影方法。 这类方法通过后处理或迭代更新把不可行的预测修正过来。DC3 [21] 用等式补全加不等式修正, 但只对等式满足给出严格保证。ProjectNet [22] 用交替投影, 只适用于简单的非负约束。[23] 借助分量平均 Dykstra 算法强制线性硬约束。T-SKM-Net [15] 用零空间投影加 SKM 迭代, 等式与不等式约束都能严格满足。但它使用 SVD 分解并对约束均匀采样, 没有利用有效约束集稀疏、约束矩阵有结构这两点, 推理效率因此受限。

2.2 SKM 的加速方法

在加速 Kaczmarz 类迭代方法的工作中, 贪心 Kaczmarz 算法 [24] 已被证明达到理论最优收敛速率。问题在于每次迭代都要扫过全部约束行去找最大残差, 单步代价高得难以承受, 用不到大规模问题上。随机分块 SKM [25] 靠多条约束并行迭代取得了更快的收敛速率, 但采样规模、分块大小这类参数很难调。概率加速 SKM (PASKM) [26] 把 Nesterov 动量引入 SKM 框架, 利用历史信息加速向可行域收敛; 不过它仍是均匀采样, 没有从根本上解决约束采样低效的问题。

2.3 有效集预测的应用

[27] 表明, 有效集预测能有效降低求解 Lasso 问题所需的时间与内存。类似地, [28] 用有效集预测来降低约束优化的复杂度, 但其方法要为所有被识别出的候选有效集求解缩减后的 KKT 系统, 一旦预测精度不够, 开销反而可观。[29] 提出基于集成的有效集预测, 依据输入参数预测最优解处的有效约束; 不过该方法假定约束系统本身不变, 无法处理拓扑变化引起的有效集迁移。[30] 则提出用 GNN 预测有效集, 为传统求解器提供热启动。

3 预备知识

给定图 $\mathcal{G}$, 考虑目标函数 F 与状态向量 $x \in \mathbb{R}^n$ 在线性约束下的可行性:

$$\begin{aligned} \min_x F(\mathcal{G}, x) \\ \text{s.t. } A(\mathcal{G})x \leq b, \quad C(\mathcal{G})x = d \end{aligned} \quad (1)$$

其中约束矩阵 $A(\mathcal{G}) \in \mathbb{R}^{n_{\text{ineq}} \times n}$ 、 $C(\mathcal{G}) \in \mathbb{R}^{n_{\text{eq}} \times n}$, $b \in \mathbb{R}^{n_{\text{ineq}}}$ 与 $d \in \mathbb{R}^{n_{\text{eq}}}$ 分别给出 n_{ineq} 条不等式约束和 n_{eq} 条等式约束。

带零空间投影的 SKM 先把初始猜测 x_0 投影到等式约束超平面上, 得到一个满足等式的点 [15]:

$$x_{\text{eq}} = x_0 - C^\dagger(Cx_0 - d). \quad (2)$$

设 $N \in \mathbb{R}^{n \times r}$ 是 $\text{null}(C)$ 的一组基。任何满足等式的迭代点都可写成 $x = x_{\text{eq}} + Nw$, 其中 $w \in \mathbb{R}^r$ 。

记 $\tilde{A} = AN$, 其各行为 $\tilde{a}_i^\top$; 再记 $\tilde{b} = b - Ax_{\text{eq}}$ 。用采样得到的约束下标集 $\mathcal{S}_k \subseteq \{1, \dots, n_{\text{ineq}}\}$ 与铰链算子 $[t]_+ \triangleq \max\{t, 0\}$, SKM 在零空间系数上的更新为:

$$\begin{aligned} i_k &\in \arg \max_{i \in \text{calS}_k} [\tilde{a}_i^\top w_k - \tilde{b}_i]_+, \\ w_{k+1} &= w_k - \alpha \frac{[\tilde{a}_{i_k}^\top w_k - \tilde{b}_{i_k}]_+}{\|v\|^2} \cdot \tilde{a}_{i_k}, \\ x_{k+1} &= x_{\text{eq}} + Nw_{k+1}, \quad w_0 = 0, \end{aligned} \quad (3)$$

其中步长 $\alpha \in (0, 2)$ 。式 (3) 在保持 $Cx_k = d$ 的同时, 逐步削减变换后不等式约束的违背量。

4 加速可训练 SKM 框架

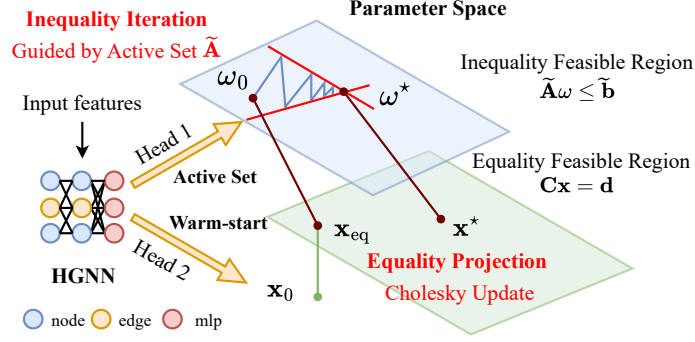


图 1 AT-SKM-Net 的流程框图。

我们提出加速可训练采样 Kaczmarz–Motzkin 网络 (AT-SKM-Net)，用以化解严格可行性保证与动态环境下实时可扩展性之间的矛盾。如图 1 所示，给定一份拓扑已更新、约束特征已改变的图实例，HGNN 先给出一个热启动候选和有效集评分；热启动解随后被投影到等式约束流形上，再在零空间里做 SKM 迭代，消除剩余的不等式违背。完整的推理流程见附录第 A.1 节。框架的目标是让上述两个环节各由一种互补机制加速，从而获得端到端的整体提速：

不等式 SKM 迭代：采样加速。 为克服均匀采样低效的问题，我们在第 4.1 节引入由有效集预测引导的混合策略。借助拓扑先验识别紧约束，搜索空间就从庞大的全局集合收缩到局部的有效流形。第 4.2 节给出理论分析。

等式投影：计算加速。 为应对约束矩阵低秩扰动下 SVD 重分解的瓶颈，我们在第 4.3 节提出 Cholesky 更新机制。它利用约束矩阵的低秩特性，在理论上把等式投影复杂度从 $\mathcal{O}(N^3)$ 降到 $\mathcal{O}(N^2)$ 。

支撑这两个模块的是第 4.4 节提出的异构 GNN：它编码动态图结构，既为求解器提供热启动，也引导优化过程。

4.1 SKM 迭代的采样加速：有效集预测

标准 SKM 方法的结构性低效，源于约束的稀疏性与采样的均匀性之间的错配。可行域的几何形状通常由一小组有效约束刻画，绝大多数约束在解处都是冗余的。但标准 SKM 对这一结构毫无感知，仍从总数为 m 的约束集中均匀采样。这种盲搜使采样效率很低——大量非有效约束把选中一条有用约束的可能性稀释掉了。

为补上这一环，我们提出一种基于神经网络的混合采样策略，把采样概率集中到有效约束上。理论上，这把收敛性的依赖从约束总数 m 与全局 Hoffman 常数，转移到缩减后的有效集规模 $|\hat{\mathcal{A}}|$ 与局部条件数上。

4.1.1 由预测有效集引导的混合采样

考虑多面体上的线性不等式约束：

$$\mathcal{P} = \{x \in \mathbb{R}^n \mid Ax \leq b\}, \quad (4)$$

其中 $A \in \mathbb{R}^{m \times n}$ ， $a_i^\top$ 表示 A 的第 i 行。设 x^* 为目标可行解。在 x^* 处，有效约束集定义为

$$\mathcal{A}^*(x^*) = \{i \in \{1, \dots, m\} \mid a_i^\top x^* = b_i\}. \quad (5)$$

在 x^* 的邻域内，其余不等式约束仍然松弛，可行域由仿射流形 $A_{\text{calA}}^* x = b_{\text{calA}}^*$ 局部刻画。

针对这种结构性采样低效，我们提出由神经网络预测引导的混合采样策略：把计算资源集中到有效概率高的约束上，同时保留一部分均匀采样，以保证理论上的全局收敛性。

设 $\varphi(\mathcal{G})$ 为神经网络模型。对输入的优化实例 $\mathcal{G}$ ，模型输出未归一化的 logit 向量 $z \in \mathbb{R}^m$ 。我们通过全局归一化，把预测的有效评分转成采样分布 p ：

$$p_i = \frac{\sigma(z_i)}{\sum_{j=1}^m \sigma(z_j)}, \quad \forall i \in \{1, \dots, m\}. \quad (6)$$

在每次 SKM 迭代 k 中，给定总批规模 β 与混合比例 $\rho \in (0, 1]$ ，采样的下标集 τ_k 由两部分构成。

预测引导的利用 (τ_{learn})。按分布 p 做加权采样，选出 $\beta_1 = \lfloor \rho\beta \rfloor$ 个下标。这一步相当于从预测有效集 $\hat{\mathcal{A}}$ 中采样，目的是把有效采样空间的维数从 m 压到大约 $|\hat{\mathcal{A}}|$ ，从而加快收敛。

均匀探索 (τ_{unif})。从剩余约束集中均匀采样 $\beta_2 = \beta - \beta_1$ 个下标。这一步是保险，防止真正有效约束因预测出错而被漏掉，保证算法的全局稳健性。

第 k 次迭代最终采到的约束子集为 $\tau_k = \tau_{\text{learn}} \cup \tau_{\text{unif}}$ 。这种混合方式既用上了先验几何信息，又避免了纯预测方法可能存在的盲区。

4.2 理论分析

为量化降维带来的加速，下面对局部几何与预测器的能力作两条假设。

假设 1. (有效集局部稳定性) 存在 x^* 的一个邻域 $\mathcal{U}$ ，使得对其中任一迭代点 $x \in \mathcal{U}$ ，投影处的有效约束集保持不变：在 x^* 处非有效的约束在 $\Pi_{\mathcal{P}}(x)$ 处仍为松弛，且 $\Pi_{\mathcal{P}}(x)$ 落在由 $\mathcal{A}^*(x^*)$ 确定的仿射子空间上，即 $\mathcal{A}(\Pi_{\mathcal{P}}(x)) = \mathcal{A}^*(x^*)$ 。

假设 2. (有效集覆盖有效性) 预测器给出的候选集 $\hat{\mathcal{A}}$ 满足两个条件：一是**覆盖性**，它包含真实有效集，即 $\mathcal{A}^* \subseteq \hat{\mathcal{A}}$ ；二是**稀疏性**，其规模远小于约束总数，即 $|\hat{\mathcal{A}}| \ll m$ 。

加速机制的理论分析分两步展开：先确立算法的全局收敛保证，再在局部线性区间内量化它相对标准 SKM 的加速。

定理 1. (全局收敛性与稳健性) 只要混合比例满足 $\rho < 1$ ，所提算法就保持向可行集 $\mathcal{P}$ 的期望全局线性收敛。

证明. 证明要点在于采样概率为正。由于 $\rho < 1$ ，每条约束被采到的概率都严格大于零，这正好满足随机化 Kaczmarz 理论中全局线性收敛的充分条件 [31], [32]，因而对预测误差是稳健的。完整证明见附录第 A.2 节。■

定理 2. (降维带来的效率增益) 考虑假设 1 所述局部线性区间内的迭代点，并设各行已归一化。把在 $\in \{1, \dots, m\}$ 上的均匀采样与在预测集 $\hat{\mathcal{A}}$ 上的均匀采样相对照，在假设 2 之下，单步期望误差收缩速率分别为：**标准 SKM (在 m 上均匀采样)**：

$$\mathbb{E}[\|v\|_{k+1}^2] \leq \left(1 - \frac{1}{m\mathcal{H}^2(A)}\right) \|v\|_k^2 \quad (7)$$

加速 SKM (在 $\hat{\mathcal{A}}$ 上均匀采样)：

$$\mathbb{E}[\|v\|_{k+1}^2] \leq \left(1 - \sigma_{\min}^2 \frac{A_{\text{calA}^*}}{|\hat{\mathcal{A}}|}\right) \|v\|_k^2 \quad (8)$$

其中 $\mathcal{H}(A)$ 为全局 Hoffman 常数， $\sigma_{\min}(A_{\text{calA}^*})$ 表示真实有效子矩阵的最小非零奇异值。

证明. 加速来自假设 1 所给局部线性区间内误差的收缩行为。在邻域 $\mathcal{U}$ 内，任何非有效约束的铰链损失都满足 $[a_i^\top x - b_i]_+ = 0$ ，于是期望更新中的求和项从整个约束集塌缩到有效集 $\mathcal{A}^*$ 。完整证明见附录第 A.2 节。■

这一定理从两条互补机制上说明了加速的来源。其一是采样效率：分母由 m 变为 $|\hat{\mathcal{A}}|$ ，反映采样空间被压缩，只要 $|\hat{\mathcal{A}}| \ll m$ 就能带来显著加速。其二是几何正则化：收敛速率由真实有效集 $\mathcal{A}^*$ 的奇异值 $\sigma_{\min}$ 决定，而不再是 Hoffman 常数 $\mathcal{H}$ ——后者刻画的是所有子矩阵中最坏的条件数 [33]。

4.3 等式投影的加速计算：Cholesky 更新

在 T-SKM-Net 里，SKM 层先把神经预测 x_0 投影到等式流形 $Cx = d$ 上，随后在 C 的零空间内做不等式迭代。这一步等式投影是保持可行性的关键，但在动态图问题上成了主要瓶颈：图拓扑一变，等式矩阵 C 随之改变，T-SKM-Net 所用的基于 SVD 的投影就要重算，代价是每扰动一次便要付出 $\mathcal{O}(n^3)$ [34]。

不过，线路断开或重连这类温和的拓扑变化，通常在邻接矩阵或图 Laplacian 上只造成局部改动。受此启发，我们提出一个增量式 Cholesky 更新框架，利用这种结构化变化来加速等式约束投影阶段。

给定行满秩矩阵 $C \in \mathbb{R}^{m \times n}$ ，由 $\tilde{C} = C + u^\top$ 定义的秩一扰动会在其 Gram 矩阵 $G = CC^\top$ 上诱导出一个秩二改动。为高效处理这一情形，我们绕开代价高昂的 SVD 重算，改用一般的增量 Cholesky 更新策略：对原有的 $G = LL^\top$ 依次施加一次秩一加更新与一次秩一减更新，就能直接把三角因子演化出 $\tilde{L}$ 以适应新拓扑，无需从头重构矩阵。

有了更新后的因子 $\tilde{L}$ ，显式求逆就化为两次高效的下三角与上三角求解。对约束残差 $\tilde{r} = \tilde{C}x_0 - d$ ，投影解可写成：

$$\tilde{x}_{\text{eq}} = x_0 - \tilde{C}^\top (\tilde{L}^{-\top} (\tilde{L}^{-1} \tilde{r})) \quad (9)$$

后续 SKM 迭代所用的零空间表示，也随扰动后的等式约束一致更新。我们不重构整组零空间基，而是复用上一轮的基，只修正受扰动影响的那一低维子空间 [35]。直观上， C 的低秩改变只影响零空间中少数几个方向，其余方向经正交对齐后即可保留。该基更新的具体构造见附录第 B.1 节。

计算复杂度. SVD 方法必须整体重分解，复杂度为三次方 $\mathcal{O}(N^3)$ ；我们的框架利用约束矩阵的低秩扰动，把全局分解换成局部化的 Cholesky 秩一更新与高效基旋转，从而把高维问题解耦成一串向量运算与三角求解，整体复杂度降到 $\mathcal{O}(N^2)$ ，相对标准方法给出量级为 N 的理论加速。更多细节见附录第 B.2 节。

4.4 面向有效集预测的拓扑感知异构图神经网络

第 4.1 节提出的混合采样策略，依赖对单条约束有效概率的准确估计，这带来两个关键难点：如何刻画约束的异质性，以及如何在拓扑不断变化的场景间泛化。为此我们设计了一种异构图神经网络（HGNN），其结构与图上约束优化问题的约束组成和拓扑相对齐。

4.4.1 异构图表示

图上的优化问题中，约束天然分为节点级与边级两类。同质 GNN 把边仅当作消息传递的通道，边上的专属信息容易被抹平进节点表示 [36]。这种平滑效应使得为边级耦合关系区分出各自的有效概率变得困难。

为此我们采用异构二分图结构，把原始节点与边都建成独立的计算实体，从而在神经网络嵌入与优化约束集之间建立结构对应。设 $\mathbf{h}_u^{(l)}$ 与 $\mathbf{h}_e^{(l)}$ 分别为节点 u 与边 $e = (u, v)$ 在第 l 层的隐表示，异构消息传递的更新为：

$$\begin{aligned}\mathbf{h}_e^{(l+1)} &= \varphi_{\text{edge}}(\mathbf{h}_e^{(l)}, \mathbf{h}_u^{(l)}, \mathbf{h}_v^{(l)}), \\ \mathbf{h}_u^{(l+1)} &= \varphi_{\text{node}}(\mathbf{h}_u^{(l)}, \sum_{e \in \text{calN}(u)} \mathbf{h}_e^{(l+1)}),\end{aligned}\tag{10}$$

其中 φ_{edge} 与 φ_{node} 为非线性变换函数。这一写法让每条耦合约束的表示 $\mathbf{h}_e$ 在整个传播深度上都独立保留，而不是被吸进节点状态里。

4.4.2 静态-动态特征分离

图拓扑变化时，模型要在这些扰动之间泛化。我们注意到问题输入可分成两类：定义约束系数矩阵 A 的静态几何参数 $\mathbf{z}_{\text{stat}}$ ，以及定义边界向量 $\mathbf{b}$ 的动态工况参数 $\mathbf{z}_{\text{dyn}}$ 。

为防止静态结构信息在深层消息传递中被动态变化稀释，我们采用一种结构感知归一化机制：先把动态隐特征 $\mathbf{h}^{(l)}$ 与静态物理特征 $\mathbf{z}_{\text{stat}}$ 拼接，再经图卷积生成归一化参数：

$$\mathbf{h}^{(l+1)} = \gamma(\mathbf{h}^{(l)}, \mathbf{z}_{\text{stat}}) \odot \frac{\mathbf{h}^{(l)} - \mu}{\sigma} + \beta(\mathbf{h}^{(l)}, \mathbf{z}_{\text{stat}}),\tag{11}$$

其中仿射参数 γ 与 β 由拼接向量 $[\mathbf{h}^{(l)} \parallel \mathbf{z}_{\text{stat}}]$ 生成。这一写法与 [37] 提出的自适应归一化方法相关，但我们注入的不是随机噪声，而是图的全局静态拓扑。这有助于保证当 $\mathcal{G}$ 的拓扑改变时，预测结果仍与它的约束保持一致。

4.4.3 输出头

HGNN 充当加速求解器的生成器。最终嵌入送入两个输出头：回归头预测原始变量候选 $\hat{x}_0$ ，为 SKM 层提供热启动；分类头为节点约束与边约束分别生成有效评分。混合策略所需的采样分布 $\mathbf{p}$ 由全局归一化得到：

$$p_k = \frac{\sigma(\text{MLP}(\mathbf{h}_k))}{\sum_{j \in \text{calV} \cup \text{calE}} \sigma(\text{MLP}(\mathbf{h}_j))},\tag{12}$$

其中 k 遍历全部节点约束与边约束。

5 实验

我们在随机几何图与 N-1 安全约束直流最优潮流问题上评测所提的 AT-SKM 方法，并在附录第 C 节就最小成本燃气输运问题补充一项验证。全部实验在 Apple M4 芯片上完成。

5.1 随机几何图上的等式投影

我们用不同规模的随机几何图（RGG）验证所提 Cholesky 更新方法在等式约束投影上的渐近计算复杂度。RGG 的节点均匀分布在单位正方形内，欧氏距离小于阈值 r 的点对连边；这种局部连通结构与物理邻近决定连接的真实网络十分接近。

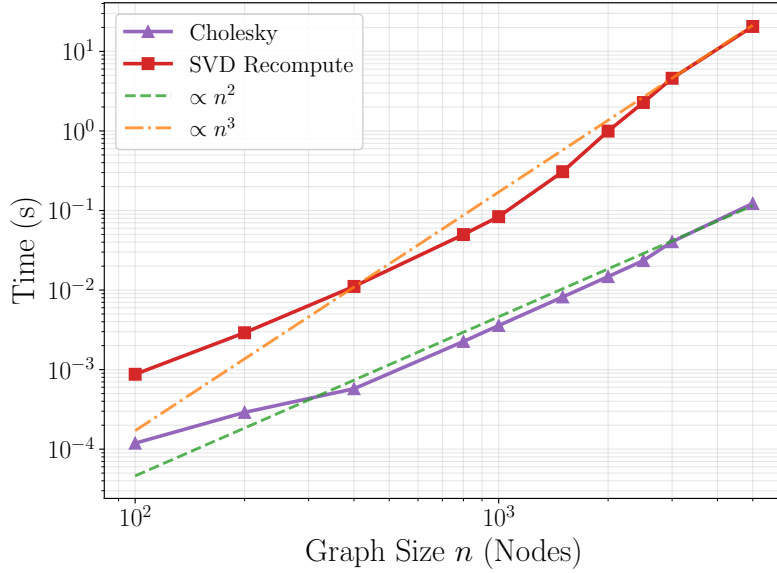


图2 RGG上SVD重算与Cholesky更新的计算复杂度对照。SVD呈 $\mathcal{O}(n^3)$ 标度，Cholesky更新为 $\mathcal{O}(n^2)$ 。

图2对比了两种做法的耗时：Cholesky更新在初始分解上做增量更新，SVD重算则每遇拓扑变化都做一次完整分解。在双对数坐标下，随着节点数增加，SVD的耗时紧贴 $\mathcal{O}(N^3)$ 参考线；我们方法的实测运行时间则与 $\mathcal{O}(N^2)$ 吻合得很好。值得注意的是，图规模达到约2000个节点时，SVD需要数秒才能完成，这对电力调度一类安全攸关的实时应用是不可接受的；相比之下，Cholesky更新把耗时保持在 10^{-2} 秒量级，效率优势明显。这些计算开销的细分见附录第B.3节。

5.2 N-1安全约束直流最优潮流

我们在N-1安全约束直流最优潮流（N-1 SC DC-OPF）问题上评测所提方法的性能。该问题是电力系统基础设施中的基础性难题，也是一类典型的图上约束优化：安全要求严格，网络拓扑又处于动态变化之中[38]。

其目标是在满足物理约束的前提下使成本最小，约束包括功率平衡方程、机组出力限值与线路热稳定限值。严格的N-1安全准则要求系统在失去单一输电元件后仍保持可行[39]。完整数学表述见附录第D.1节。

实验基于IEEE 57节点、118节点与300节点系统。我们考虑所有可行的N-1故障场景，但只把其中一部分纳入训练集，以考察模型对未见拓扑的适应与泛化能力。测试集则在已见与未见拓扑上同时评估求解器的成本优化水平与约束满足情况。全部实例的真值解由PyPower库生成[40]。

对比方法包括：(1) **PyPower**，作为真值的传统内点求解器；(2) **NN**与**HGNN**，不带显式约束处理的端到端学习基线；(3) **DC3**，用投影保证等式约束的可微优化方法；(4) **T-SKM-Net**，原始的可训练SKM框架。为分离各核心模块的贡献，我们还评测三种变体：**AT-SKM-A**（仅有效集预测）、**AT-SKM-C**（仅Cholesky更新）与**AT-SKM-AC**（完整方法）。

方法	总 耗 时 (ms)	迭代次数	SKM 耗时	SKM 加速 比	最优间隙 (%)	等式最大违 背	不等式最大违背
IEEE 57 节点系统: $n = 64$, $n_{eq} = 58$, $n_{ineq} = 174$							
PyPower	14.785	–	–	–	0 / 0	0 / 0	0 / 0
NN	0.048	–	–	–	0.173 / 5.379	24.77 / 53.07	0.101 / 192.71
HGNN	4.735	–	–	–	0.071 / 0.061	17.52 / 5.163	0.061 / 0.041
DC3	6.278	–	–	–	0.013 / 0.013	0 / 0	0.067 / 0.051
T-SKM-Net	5.831	6.93 (148)	1.096	$1\times$	0.008 / 0.008	0 / 0	0 / 0
AT-SKM-A	5.202	1.42 (11)	0.467	$2.35\times$	0.008 / 0.008	0 / 0	0 / 0
AT-SKM-C	5.353	6.93 (148)	0.618	$1.77\times$	0.008 / 0.008	0 / 0	0 / 0
AT-SKM-AC	5.009	1.42 (11)	0.274	$4.00\times$	0.008 / 0.008	0 / 0	0 / 0
IEEE 118 节点系统: $n = 172$, $n_{eq} = 119$, $n_{ineq} = 480$							
PyPower	31.557	–	–	–	0 / 0	0 / 0	0 / 0
NN	0.057	–	–	–	0.142 / 1.481	72.59 / 93.21	0.031 / 664.11
HGNN	6.938	–	–	–	0.017 / 0.016	61.06 / 67.36	0.010 / 0.047
DC3	8.040	–	–	–	0.019 / 0.019	0 / 0	0.011 / 0.009
T-SKM-Net	10.251	34.60 (141)	3.313	$1\times$	0.026 / 0.025	0 / 0	0 / 0
AT-SKM-A	9.349	15.68 (57)	2.411	$1.37\times$	0.026 / 0.025	0 / 0	0 / 0
AT-SKM-C	8.942	34.60 (141)	2.004	$1.65\times$	0.026 / 0.025	0 / 0	0 / 0
AT-SKM-AC	8.060	15.68 (57)	1.122	$2.95\times$	0.026 / 0.025	0 / 0	0 / 0
IEEE 300 节点系统: $n = 369$, $n_{eq} = 301$, $n_{ineq} = 960$							
PyPower	64.398	–	–	–	0 / 0	0 / 0	0 / 0
NN	0.078	–	–	–	0.057 / 0.367	2.00e+3 / 9.44e+3	1.53e+3 / 8.52e+3
HGNN	9.390	–	–	–	0.068 / 0.068	64.61 / 62.36	537.66 / 0.086
DC3	16.138	–	–	–	0.102 / 0.102	0 / 0	0.471 / 0.465
T-SKM-Net	18.382	24.72 (285)	8.992	$1\times$	0.108 / 0.108	0 / 0	0 / 0
AT-SKM-A	17.264	3.68 (9)	7.874	$1.14\times$	0.108 / 0.108	0 / 0	0 / 0
AT-SKM-C	12.179	24.72 (285)	2.789	$3.22\times$	0.110 / 0.110	0 / 0	0 / 0
AT-SKM-AC	10.623	3.69 (9)	1.233	$7.29\times$	0.110 / 0.110	0 / 0	0 / 0

表1 各方法的性能对照。最优间隙与约束违背量（容差 10^{-5} ）按“已见 / 未见”给出。“迭代次数”列为不等式迭代次数的均值（最大值）。SKM 相关指标在未见过拓扑上报告，以显示稳健的加速效果。

从表1可以看到，在所有系统规模上，所提方法相对 T-SKM-Net 基线都取得显著加速，同时严格满足全部等式与不等式约束，解的质量没有受损。就解的质量而言，无约束基线 NN 与 HGNN 的最优间隙虽然不大，但约束违背程度各不相同，实际运行中并不可用；NN 在未见拓扑上的泛化尤其差。DC3 虽满足等式约束，却消不掉不等式违背。

我们再分别考察有效集预测与 Cholesky 更新的独立影响。

有效集预测：AT-SKM-A 在 57、118、300 节点系统上分别把平均迭代次数降低 80%、55% 与 85%，说明混合采样确实把计算资源集中到了稀疏的有效约束子集上。

Cholesky 更新：AT-SKM-C 显著加快了投影阶段。在 300 节点系统上，结果显示 Cholesky 更新并不影响不等式迭代速率：AT-SKM-C 把 SKM 运行时间从 8.99 ms 压到 2.79 ms（加速 3.22 倍），而 AT-SKM-A 虽减少 85% 的迭代次数，却只带来 1.14 倍加速。这揭示出大规模系统中计算瓶颈已从迭代搜索转移到线性代数运算，正好凸显我们 Cholesky 更新 $\mathcal{O}(n^2)$ 的优势。

有意思的是，两种手段之间存在协同效应：AT-SKM-AC 的总加速比接近甚至超过各自加速比的乘积。例如在 57 节点系统上， $S_A(2.35\times) \times S_C(1.77\times) \approx S_{AC}(4.00\times)$ ；在 300 节点系统上，组合加速 $(7.29\times)$ 明显超过单项增益之积， $S_A(1.14\times) \times S_C(3.22\times) \ll S_{AC}(7.29\times)$ ，呈现出超线性的效率提升。

更多实验见附录：混合采样敏感性（第 D.4 节）、运行时间细分（第 D.5 节）、高负荷稳健性（第 D.6 节）、有效集预测质量（第 D.7 节）、有效集扰动（第 D.8 节），以及基于伪标签有效集训练的迁移学习（第 D.10 节）。

6 结论

本文提出 AT-SKM 框架，用于处理图上结构优化中严格可行性与实时可扩展性之间的取舍。把神经网络的有效集预测与高效的 Cholesky 增量更新结合起来，AT-SKM-Net 克服了原版投影式 T-SKM-Net 在动态环境中受限于计算的关键瓶颈。

参考文献

- [1] J. Kotary, F. Fioretto, P. Van Hentenryck, and B. Wilder, “End-to-End Constrained Optimization Learning: A Survey,” in International Joint Conference on Artificial Intelligence, 2021.
- [2] W. Wei, W. Danman, W. Qiuwei, M. Shafie-Khah, and J. P. Catalão, “Interdependence between transportation system and power distribution system: A comprehensive review on models and applications,” *Journal of Modern Power Systems and Clean Energy*, vol. 7, no. 3, pp. 433–448, 2019.
- [3] M. Khanabadi, H. Ghasemi, and M. Doostizadeh, “Optimal Transmission Switching Considering Voltage Security and N-1 Contingency Analysis,” *IEEE Transactions on Power Systems*, vol. 28, no. 1, pp. 542–550, 2013, doi: 10.1109/TPWRS.2012.2207464.
- [4] H. Zeng, C. Yang, Y. Zhou, C. Yang, and Q. Guo, “GLinSAT: The General Linear Satisfiability Neural Network Layer By Accelerated Gradient Descent,” *Advances in Neural Information Processing Systems*, vol. 37, pp. 122584–122615, 2024.
- [5] U. Utkarsh, D. C. Maddix, R. Ma, M. W. Mahoney, and Y. Wang, “End-to-end probabilistic framework for learning with hard constraints,” *arXiv preprint arXiv:2506.07003*, 2025.
- [6] F. Fioretto, P. Van Hentenryck, T. W. Mak, C. Tran, F. Baldo, and M. Lombardi, “Lagrangian duality for constrained deep learning,” in Joint European conference on machine learning and knowledge discovery in databases, 2020, pp. 118–135.
- [7] L. F. Chamon, S. Paternain, M. Calvo-Fullana, and A. Ribeiro, “Constrained learning with non-convex losses,” *IEEE Transactions on Information Theory*, vol. 69, no. 3, pp. 1739–1760, 2022.
- [8] J. Kotary and F. Fioretto, “Learning constrained optimization with deep augmented lagrangian methods,” *arXiv preprint arXiv:2403.03454*, 2024.
- [9] B. Amos and J. Z. Kolter, “Optnet: Differentiable optimization as a layer in neural networks,” in International conference on machine learning, 2017, pp. 136–145.
- [10] A. Agrawal, B. Amos, S. Barratt, S. Boyd, S. Diamond, and J. Z. Kolter, “Differentiable convex optimization layers,” *Advances in neural information processing systems*, vol. 32, 2019.
- [11] Y. Min and N. Azizan, “HardNet: Hard-Constrained Neural Networks with Universal Approximation Guarantees,” *arXiv preprint arXiv:2410.10807*, 2024.
- [12] E. Liang, M. Chen, and S. H. Low, “Low complexity homeomorphic projection to ensure neural-network Solution feasibility for optimization over (non-)convex set,” in Proceedings of the 40th International Conference on Machine Learning, in ICML’23. Honolulu, Hawaii, USA: JMLR.org, 2023.
- [13] X. Pan, T. Zhao, M. Chen, and S. Zhang, “Deepopf: A deep neural network approach for security-constrained dc optimal power flow,” *IEEE Transactions on Power Systems*, vol. 36, no. 3, pp. 1725–1735, 2020.
- [14] G. E. Constante-Flores, H. Chen, and C. Li, “Enforcing Hard Linear Constraints in Deep Learning Models with Decision Rules,” *arXiv preprint arXiv:2505.13858*, 2025.
- [15] H. Zhu, Y. Zhang, J. Ren, and Q. Hou, “T-SKM-Net: Trainable Neural Network Framework for Linear Constraint Satisfaction via Sampling Kaczmarz-Motzkin Method,” *arXiv preprint arXiv:2512.10461*, 2025.
- [16] A. Butler, “SCQPTH: an efficient differentiable splitting method for convex quadratic programming,” *arXiv preprint arXiv:2308.08232*, 2023.
- [17] R. Wang, Y. Zhang, Z. Guo, T. Chen, X. Yang, and J. Yan, “Linsatnet: the positive linear satisfiability neural networks,” in International Conference on Machine Learning, 2023, pp. 36605–36625.
- [18] T. Frerix, M. Nießner, and D. Cremers, “Homogeneous linear inequality constraints for neural network activations,” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 2020, pp. 748–749.
- [19] J. Tordesillas, J. P. How, and M. Hutter, “Rayen: Imposition of hard convex constraints on neural networks,” *arXiv preprint arXiv:2307.08336*, 2023.

- [20] A. V. Konstantinov and L. V. Utkin, “A new computationally simple approach for implementing neural networks with output hard constraints,” in *Doklady Mathematics*, 2023, pp. S233–S241.
- [21] P. Donti, D. Rolnick, and J. Z. Kolter, “DC3: A learning method for optimization with hard constraints,” in *International Conference on Learning Representations*, 2021.
- [22] R. Cristian, P. Harsha, G. Perakis, B. L. Quanz, and I. Spantidakis, “End-to-end learning for optimization via constraint-enforcing approximators,” in *Proceedings of the AAAI conference on artificial intelligence*, 2023, pp. 7253–7260.
- [23] A. Rashwan, K. Briggs, C. Budd, and L. Kreusser, “Enforcing convex constraints in Graph Neural Networks,” *arXiv preprint arXiv:2510.11227*, 2025.
- [24] J. Nutini, B. Sepehry, I. Laradji, M. Schmidt, H. Koepke, and A. Virani, “Convergence rates for greedy Kaczmarz algorithms, and faster randomized Kaczmarz rules using the orthogonality graph,” *arXiv preprint arXiv:1612.07838*, 2016.
- [25] Y. Zhang and H. Li, “Randomized block subsampling Kaczmarz-Motzkin method,” *Linear Algebra and its Applications*, vol. 667, pp. 133–150, 2023.
- [26] M. S. Morshed, M. S. Islam, and M. Noor-E-Alam, “Sampling Kaczmarz-Motzkin method for linear feasibility problems: generalization and acceleration,” *Mathematical Programming*, vol. 194, no. 1, pp. 719–779, 2022.
- [27] Z. J. Xiang, Y. Wang, and P. J. Ramadge, “Screening tests for lasso problems,” *IEEE transactions on pattern analysis and machine intelligence*, vol. 39, no. 5, pp. 1008–1027, 2016.
- [28] S. Misra, L. Roald, and Y. Ng, “Learning for constrained optimization: Identifying optimal active constraint sets,” *INFORMS Journal on Computing*, vol. 34, no. 1, pp. 463–480, 2022.
- [29] Y. Ng, S. Misra, L. A. Roald, and S. Backhaus, “Statistical Learning for DC Optimal Power Flow,” in *2018 Power Systems Computation Conference (PSCC)*, 2018, pp. 1–7. doi: 10.23919/PSCC.2018.8442859.
- [30] E. J. Schmidtbreick, D. Arnström, P. Häusner, and J. Sjölund, “Warm-starting active-set solvers using graph neural networks,” *arXiv preprint arXiv:2511.13174*, 2025.
- [31] J. Haddock and A. Ma, “Greed works: An improved analysis of sampling Kaczmarz-Motzkin,” *SIAM Journal on Mathematics of Data Science*, vol. 3, no. 1, pp. 342–368, 2021.
- [32] J. A. De Loera, J. Haddock, and D. Needell, “A sampling Kaczmarz-Motzkin algorithm for linear feasibility,” *SIAM Journal on Scientific Computing*, vol. 39, no. 5, pp. S66–S87, 2017.
- [33] D. Klatte and G. Thiere, “Error bounds for solutions of linear equations and inequalities,” *Zeitschrift für Operations Research*, vol. 41, no. 2, pp. 191–214, 1995.
- [34] N. K. Vishnoi, “Laplacian solvers and their algorithmic applications,” *Foundations and Trends in Theoretical Computer Science*, vol. 8, no. 1–2, pp. 1–145, 2010.
- [35] J. Nocedal, “Numerical optimization,” *Springer Ser. Oper. Res. Financ. Eng./Springer*, 2006.
- [36] S. Ghamizi, A. Ma, J. Cao, and P. R. Cortes, “Opf-hgnn: Generalizable heterogeneous graph neural networks for ac optimal power flow,” in *2024 IEEE Power & Energy Society General Meeting (PESGM)*, 2024, pp. 1–5.
- [37] M. Eliasof, B. Bevilacqua, C.-B. Schönlieb, and H. Maron, “Granola: Adaptive normalization for graph neural networks,” *Advances in Neural Information Processing Systems*, vol. 37, pp. 90514–90551, 2024.
- [38] X. Zhang, K. Xu, S. Liao, L. Qiu, C. Ye, and Y. Fang, “Disturbed security-constrained and time-variant optimal power flow for dynamic power system based on chaotic-genetic-centroid puffin optimization,” *Applied Energy*, vol. 397, p. 126287, 2025.
- [39] M. Zhou, C. Liu, A. A. Jahromi, D. Kundur, J. Wu, and C. Long, “Revealing Vulnerability of N-1 Secure Power Systems to Coordinated Cyber-Physical Attacks,” *IEEE Transactions on Power Systems*, vol. 38, no. 2, pp. 1044–1057, 2023, doi: 10.1109/TPWRS.2022.3169482.
- [40] R. Lincoln, “PYPOWER.” *Python Package Index*, 2025.
- [41] D. Leventhal and A. S. Lewis, “Randomized methods for linear constraints: convergence rates and conditioning,” *Mathematics of Operations Research*, vol. 35, no. 3, pp. 641–654, 2010.

- [42] A. S. Householder, “Unitary triangularization of a nonsymmetric matrix,” *Journal of the ACM (JACM)*, vol. 5, no. 4, pp. 339–342, 1958.
- [43] M. Schmidt et al., “GasLib—A library of gas network instances,” *Data*, vol. 2, no. 4, p. 40, 2017.
- [44] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proceedings of the IEEE international conference on computer vision*, 2017, pp. 2980–2988.

附录内容目录

附录 A 算法流程与理论证明

附录 B Cholesky 更新方法的计算复杂度

附录 C 最小成本燃气输运问题

附录 D N-1 安全约束直流最优潮流的实验设置与附加结果

附录 A AT-SKM-Net 算法流程与理论证明

A.1 AT-SKM-Net 算法流程

算法 1 汇总了 AT-SKM-Net 的完整求解流程：先由预测器给出热启动点并做等式投影，随后在 C 的零空间内按混合采样推进不等式迭代。

输入： 约束数据 (A, b, C, d)、预测器 φ、采样批规模 β、混合比例 ρ、最大迭代数 K 输出： 可行解 x_K <pre> 1: $(x_0, s) \leftarrow \varphi(A, b, C, d)$ 2: $p_i \leftarrow \frac{\sigma(s_i)}{\sum_{j=1}^m \sigma(s_j)}, i = 1, \dots, m$ 3: 等式投影阶段。 4: $L \leftarrow \text{CholeskyUpdate}(C)$, 使得 $LL^\top = CC^\top$ 5: 求解 $LL^\top y = Cx_0 - d$, 并置 $x_{\text{eq}} = x_0 - C^\top y$ 6: $N \leftarrow \text{NullSpaceUpdate}(C, L)$, $CN = 0$ 7: $\tilde{A} \leftarrow AN, \tilde{b} \leftarrow b - Ax_{\text{eq}}, \omega_0 \leftarrow 0$ 8: 不等式迭代阶段。 9: for $k = 0, 1, \dots, K-1$ do 10: $\beta_{\text{act}} \leftarrow \lfloor \rho\beta \rfloor, \beta_{\text{unif}} \leftarrow \beta - \beta_{\text{act}}$ 11: 按分布 p 从 $\{1, \dots, m\}$ 中取 β_{act} 个下标, 得到 τ_{act} 12: 从 $\{1, \dots, m\}$ 中均匀取 β_{unif} 个下标, 得到 τ_{unif} 13: $\tau_k \leftarrow \tau_{\text{act}} \cup \tau_{\text{unif}}$ 14: $i_k \leftarrow \arg \max_{i \in \tau_k} [\tilde{a}_i^\top \omega_k - \tilde{b}_i]_+$ 15: if $\tilde{a}_{i_k}^\top \omega_k > \tilde{b}_{i_k}$ then 16: $\omega_{k+1} = \omega_k - \alpha \frac{\tilde{a}_{i_k}^\top \omega_k - \tilde{b}_{i_k}}{\ \tilde{a}_{i_k}\ _2^2} \tilde{a}_{i_k}, \alpha \in (0, 2)$ 17: else 18: $\omega_{k+1} \leftarrow \omega_k$ 19: end if 20: end for 21: $x_K \leftarrow x_{\text{eq}} + N\omega_K$ 22: return x_K </pre>
--

算法 1 所提 AT-SKM-Net 框架的伪代码。

A.2 基于有效集预测的加速采样

以下补全正文第 4.2 节两条定理的完整证明。

定理 1. (全局收敛性与稳健性) 只要混合比例满足 $\rho < 1$, 所提算法就保持向可行集 $\mathcal{P}$ 的期望全局线性收敛。

证明. AT-SKM 在零空间系数 ω 上迭代。记零空间表示下的可行集为 $\Omega = \{\omega \in \mathbb{R}^r \mid \tilde{A}\omega \leq \tilde{b}\}$, 其中 $\tilde{A} = AN, \tilde{b} = b - Ax_{\text{eq}}$ 。设 ω^* 为当前迭代点 ω_k 在 Ω 上的投影, 并定义误差向量 $e_k = \omega_k - \omega^*$ 。

考察第 k 次迭代。令

$$g_{j(\omega_k)} = \frac{[\tilde{a}_j^\top \omega_k - \tilde{b}_j]_+^2}{\|\tilde{a}_j\|_2^2} = [\tilde{a}_j^\top \omega_k - \tilde{b}_j]_+^2$$

为行归一化后第 j 条约束的平方归一化违背量。算法按贪心准则从采样批 $\mathcal{S}_k$ 中选出有效约束下标 i_k :

$$i_k = \arg \max_{j \in \mathcal{S}_k} g_{j(\omega_k)}. \quad (13)$$

步长 $\alpha \in (0, 2)$ 的标准 Kaczmarz 更新给出如下的误差收缩递推 [32]:

$$\|e_{k+1}\|^2 \leq \|e_k\|^2 - \alpha(2 - \alpha)g_{i_k}(\omega_k). \quad (14)$$

混合采样保证批 $\mathcal{S}_k$ 中含一个规模为 $\beta_{\text{unif}} \geq 1$ 的子集 τ_{unif} , 它是在全部 m 条约束上均匀采得的, 而 $\rho < 1$ 正是这一规模的保证。整批中的最大违背量不小于均匀子集内的最大违背量, 后者又不小于该子集上的平均违背量:

$$g_{i_k}(\omega_k) = \max_{j \in \mathcal{S}_k} g_{j(\omega_k)} \geq \max_{j \in \tau_{\text{unif}}} g_{j(\omega_k)} \geq \frac{1}{\beta_{\text{unif}}} \sum_{j \in \tau_{\text{unif}}} g_{j(\omega_k)}. \quad (15)$$

再对批的随机采样取期望。 τ_{unif} 是在 $\{1, \dots, m\}$ 上均匀采出的，故任一给定约束 l 落入其中的概率为 $\frac{\beta_{\text{unif}}}{m}$ ，由期望的线性性：

$$\begin{aligned} \mathbb{E}[g_{i_k}(\omega_k)] &\geq \mathbb{E}\left[\frac{1}{\beta_{\text{unif}}} \sum_{j \in \tau_{\text{unif}}} g_{j(\omega_k)}\right] \\ &= \frac{1}{\beta_{\text{unif}}} \sum_{l=1}^m \frac{\beta_{\text{unif}}}{m} g_{l(\omega_k)} \\ &= \frac{1}{m} \sum_{l=1}^m g_{l(\omega_k)}. \end{aligned} \quad (16)$$

上式右端的求和项正是残差向量的平方范数 $\left\| [\tilde{A}\omega_k - \tilde{b}]_+ \right\|^2$ 。由全局 Hoffman 误差界定理，存在常数 $\mathcal{H}(\tilde{A})$ 使得

$$\sum_{l=1}^m g_{l(\omega_k)} = \left\| [\tilde{A}\omega_k - \tilde{b}]_+ \right\|^2 \geq \frac{1}{\mathcal{H}^2(\tilde{A})} \|e_k\|^2. \quad (17)$$

把它代回误差递推的期望：

$$\mathbb{E}[\|e_{k+1}\|^2] \leq \left(1 - \frac{\alpha(2-\alpha)}{m\mathcal{H}^2(\tilde{A})}\right) \|e_k\|^2 = \left(1 - \frac{1}{m\mathcal{H}^2(\tilde{A})}\right) \|e_k\|^2. \quad (18)$$

取 $\alpha = 1 \in (0, 2)$ ，并注意到 $\mathcal{H}(\tilde{A}) < \infty$ ，算法便在期望意义下线性收敛。 ■

定理 2. (降维带来的效率增益) 考虑假设 1 所述局部线性区间内的迭代点，并设各行已归一化。把在 $\{1, \dots, m\}$ 上的均匀采样与在预测集 $\hat{\mathcal{A}}$ 上的均匀采样相对照，在假设 2 之下，单步期望误差收缩速率分别为：

标准 SKM (在 m 上均匀采样)：

$$\mathbb{E}[\|e_{k+1}\|^2] \leq \left(1 - \frac{1}{m\mathcal{H}^2(A)}\right) \|e_k\|^2$$

加速 SKM (在 $\hat{\mathcal{A}}$ 上均匀采样)：

$$\mathbb{E}[\|e_{k+1}\|^2] \leq \left(1 - \frac{\sigma_{\min}^2(A_{[\mathcal{A}^*]})}{|\hat{\mathcal{A}}|}\right) \|e_k\|^2$$

其中 $\mathcal{H}(A)$ 为全局 Hoffman 常数， $\sigma_{\min}(A_{[\mathcal{A}^*]})$ 表示真实有效子矩阵的最小非零奇异值。

证明. 记 $e_k = x_k - x^*$ 。在行归一化条件下，带铰链损失的 Kaczmarz 更新给出 $\|e_{k+1}\|^2 = \|e_k\|^2 - [a_i^\top x_k - b_i]_+^2$ 。对采到的下标 i 取期望：

$$\mathbb{E}[\|e_{k+1}\|^2] = \|e_k\|^2 - \sum_{i \in \mathcal{S}} p_i [a_i^\top x_k - b_i]_+^2. \quad (19)$$

对**标准 SKM**， $\mathcal{S} = \{1, \dots, m\}$ 且 $p_i = \frac{1}{m}$ 。把全局 Hoffman 界用在残差向量 $[Ax_k - b]_+$ 上，便有 $\frac{1}{m} \|[Ax_k - b]_+\|^2 \geq \frac{1}{m\mathcal{H}^2(A)} \|e_k\|^2$ [41]。

对**加速 SKM**， $\mathcal{S} = \hat{\mathcal{A}}$ 且 $p_i = \frac{1}{|\hat{\mathcal{A}}|}$ 。关键在于：在假设 1 之下，任一非有效约束 $i \notin \mathcal{A}^*$ 都满足 $a_i^\top x_k < b_i$ ，从而 $[a_i^\top x_k - b_i]_+ = 0$ 。于是求和里非有效约束的贡献全部消失，只留下真实有效集 $\mathcal{A}^*$ 的部分；而对 $i \in \mathcal{A}^*$ ，由 $a_i^\top x^* = b_i$ ，该项化为 $[a_i^\top x_k - b_i]_+^2 = \|a_i^\top e_k\|^2$ ：

$$\begin{aligned} \sum_{i \in \hat{\mathcal{A}}} \frac{1}{|\hat{\mathcal{A}}|} [a_i^\top x_k - b_i]_+^2 &= \frac{1}{|\hat{\mathcal{A}}|} \sum_{i \in \mathcal{A}^*} \|a_i^\top e_k\|^2 \\ &= \frac{1}{|\hat{\mathcal{A}}|} \|A_{[\mathcal{A}^*]} e_k\|^2. \end{aligned} \quad (20)$$

最后套用谱界 $\|A_{[\mathcal{A}^*]} e_k\|^2 \geq \sigma_{\min}^2(A_{[\mathcal{A}^*]}) \|e_k\|^2$ ，即得加速后的收敛速率。 ■

附录 B 所提 Cholesky 更新方法的计算复杂度

B.1 Cholesky 更新的实现细节

所提 Cholesky 更新框架的关键，在于利用低秩扰动的结构性质，把已经更新过的 Cholesky 因子反复复用下去。这样既绕开了奇异值分解的高昂代价，又能高效地同时维护投影算子与零空间基。

设原 Gram 矩阵为 $G = CC^\top$ ，则扰动后的 Gram 矩阵 $\tilde{G}$ 可推导为：

$$\begin{aligned}\tilde{G} &= (C + uv^\top)(C + uv^\top)^\top \\ &= CC^\top + Cvu^\top + uv^\top C^\top + u(v^\top v)u^\top \\ &= G + (Cv)u^\top + u(Cv)^\top + \|v\|^2 uu^\top\end{aligned}\quad (21)$$

记 $h = Cv$ ，标量 $\lambda = \|v\|^2$ ，上式即可改写为

$$\tilde{G} = G + hu^\top + uh^\top + \lambda uu^\top \quad (22)$$

再引入辅助向量 $m = h + (\frac{\lambda}{2})u$ ，于是有

$$\begin{aligned}hu^\top + uh^\top + \lambda uu^\top &= um^\top + mu^\top \\ &= \left(\frac{1}{2}\right)(u+m)(u+m)^\top - \left(\frac{1}{2}\right)(u-m)(u-m)^\top\end{aligned}\quad (23)$$

代回 Gram 矩阵的表达式，得到

$$\tilde{G} = G + \left(\frac{1}{2}\right)(u+m)(u+m)^\top - \left(\frac{1}{2}\right)(u-m)(u-m)^\top \quad (24)$$

右端第二项与第三项分别对应秩一“加更新”和秩一“减更新”。

由此可见， $\tilde{G}$ 无需显式重构：直接对原因子 L 调用标准的 `chol_update` 与 `chol_downdate` 例程，依次施加一次秩一加更新与一次秩一减更新，便可得到满足 $\tilde{L}\tilde{L}^\top = \tilde{G}$ 的 $\tilde{L}$ 。

有了更新后的因子 $\tilde{L}$ ，即可定义约束残差 $r = \tilde{C}x_0 - d$ ，投影公式写为

$$x_{\text{eq}} = x_0 - \tilde{C}^\top \left((\tilde{L}^\top)^{-1} (\tilde{L}^{-1} r) \right) \quad (25)$$

借助 $\tilde{L}$ ，式 (25) 用两次三角替换即可求解：

1. 前代 (Forward Substitution): $\tilde{L}k = r$;
2. 回代 (Backward Substitution): $\tilde{L}^\top y = k$ 。

最终的投影解为

$$\tilde{x}_{\text{eq}} = x_0 - \tilde{C}^\top y \quad (26)$$

下面构造新的零空间基 $\tilde{Z}$ ，使其满足 $\tilde{C}\tilde{Z} = 0$ ，做法是旋转—修正策略。先把扰动投影到原零空间上，得 $w = Z^\top v$ ；为使扰动集中到少数方向，用 $q = w - \|w\|e_1$ 构造 Householder 反射 $H = I - 2\frac{qq^\top}{\|q\|^2}$ ，把它作用在原基上便得到过渡基 [42]：

$$Z' = ZH = [z'_1, z'_2, \dots, z'_{n-m}] \quad (27)$$

由 Householder 变换的性质， Z' 的第 2 列至第 $n-m$ 列都满足 $v^\top z'_j = 0$ ，因此对 $j \geq 2$ 有

$$\tilde{C}z'_j = (C + uv^\top)z'_j = Cz'_j + u(v^\top z'_j) = 0 \quad (28)$$

也就是说， $Z'_{[:,2:\text{end}]}$ 直接构成了新零空间的绝大部分。只有首列 z'_1 会产生非零残差 $\tilde{C}z'_1 = u(v^\top z'_1)$ 。为消去这一项，需要找一个满足 $\tilde{C}p = u$ 的向量 p ：利用已维护好的 $\tilde{L}$ ，通过三角替换求解 $\tilde{C}\tilde{C}^\top y = u$ ，并令 $p = \tilde{C}^\top y$ 。最后把修正项加到 z'_1 上，即得完整的新基：

$$\tilde{Z} = [z'_1 - (v^\top z'_1)p, Z'_{[:,2:\text{end}]}] \quad (29)$$

B.2 复杂度分析

设 $C \in \mathbb{R}^{n_{\text{eq}} \times n}$ 为行满秩的等式约束矩阵，其零空间维数为 $r = n - n_{\text{eq}}$ 。SVD 方法要对约束矩阵做一次完整分解，时间复杂度为 $\mathcal{O}(n^3)$ 。所提框架则借助拓扑扰动的低秩特性，把高维问题解耦成一串向量级的序贯运算。一次完整迭代的计算代价可拆分如下：

- **因子维护**：在 $G = CC^\top \in \mathbb{R}^{n_{\text{eq}} \times n_{\text{eq}}}$ 的 Cholesky 因子 L 上做一次秩一加更新与一次秩一减更新。这一步只在三角因子上操作，复杂度降为 $\mathcal{O}(n_{\text{eq}}^2)$ ，其中 n_{eq} 为等式约束个数。
- **等式投影**：计算投影解涉及矩阵-向量乘法，以及用更新后的 $\tilde{L}$ 做三角替换。主导项是矩阵-向量乘法，标度为 $\mathcal{O}(n_{\text{eq}} \cdot n)$ 。

· **零空间更新**：子空间旋转要对基矩阵 $Z \in \mathbb{R}^{n \times r}$ 施加 Householder 变换，代价为 $\mathcal{O}(n \cdot r)$ ；修正部分需求解向量 p ，无论零空间维数多大，都会额外带来 $\mathcal{O}(n_{\text{eq}} \cdot n)$ 的代价。

由于 n_{eq} 与 r 均以 n 为上界，框架的整体渐近复杂度为 $\mathcal{O}(n^2)$ 。相比基于 SVD 的标准方法，这相当于在理论上快了一个 n 的量级，把昂贵的拓扑适应变成了一个计算上很轻的过程，适合实时应用。

B.3 随机几何图上结果的详细分析

为验证上述理论复杂度分析，我们在不同规模的随机几何图 (RGG) 上做了测试，表 2 给出整体性能对照。

小规模 ($N = 100 \sim 1000$)					大规模 ($N = 1500 \sim 5000$)				
N	K	SVD (ms)	Chol. (ms)	加速比	N	K	SVD (ms)	Chol. (ms)	加速比
100	10	0.874	0.119	$7.36 \times$	1500	38	307.441	8.187	$37.55 \times$
200	14	2.906	0.290	$10.02 \times$	2000	44	995.480	14.754	$67.47 \times$
400	20	11.106	0.575	$19.33 \times$	2500	50	2276.658	23.450	$97.09 \times$
800	28	49.833	2.257	$22.08 \times$	3000	54	4595.625	40.505	$113.46 \times$
1000	31	83.666	3.583	$23.35 \times$	5000	70	20596.582	122.586	$168.02 \times$
Complex.	–	$\mathcal{O}(n^{1.99})$	$\mathcal{O}(n^{1.46})$	–	Complex.	–	$\mathcal{O}(n^{3.49})$	$\mathcal{O}(n^{2.28})$	–

表 2 随机几何图上 SVD 与 Cholesky 更新的计算耗时对照。表中的复杂度数值是在双对数空间用最小二乘线性回归拟合出的实测标度指数。

表 2 凸显了 SVD 方法与所提 Cholesky 更新方法之间明显的可扩展性差距。在 100 到 1000 的小规模组里，SVD 与 Cholesky 更新的实测复杂度分别为 $\mathcal{O}(n^{1.99})$ 和 $\mathcal{O}(n^{1.46})$ 。两者的增长速率都低于各自的理论渐近上界，原因在于底层线性代数库针对较短矩阵做了专门优化，把缓存效率和指令吞吐都拉到了较高水平。即便如此，作为基线的 SVD 已经享受到库级加速，我们的方法仍保持领先，加速比稳定落在 $7.36 \times$ 到 $23.35 \times$ 之间。

节点数从 1500 增至 5000 后，大规模组中 SVD 的耗时呈超三次方增长，拟合指数达到 3.49，反映出计算量与内存数据搬运的双重压力。与之相对，Cholesky 更新的增速接近二次方，约为 2.28，与理论下界吻合得很好。该方法仍有一处局限：大规模矩阵运算可能受内存带宽制约，矩阵尺寸增大带来的数据搬运开销会部分抵消算术上的节省，使实测标度略高于理想的二次速率。即便如此，其相对 SVD 的效率优势依然清晰——在 5000 节点上加速超过 168 倍。

B.4 更高秩故障场景下的数值稳定性

在有限精度下，序贯 Cholesky 更新会累积数值误差，多次拓扑变更连续施加时尤其明显。秩更高的故障场景与更大规模的系统上，这一问题更容易暴露：更新向量与减更新向量里可能同时出现量级相差悬殊的元素。为应对这一数值隐患，我们采用一种自适应缩放策略，在不改变低秩扰动本身的前提下，改善中间更新向量的条件数。

对秩一扰动 $\Delta C = uv^\top$ ，该表示并不唯一：对任意标量 $\alpha > 0$ ，恒有

$$\Delta C = uv^\top = (\alpha u) \left(\frac{v}{\alpha} \right)^\top. \quad (30)$$

附录第 B.1 节在推导 Gram 矩阵更新时定义了 $h = Cv$ 、 $\lambda = \|v\|_2^2$ 以及 $m = h + \left(\frac{\lambda}{2}\right)u$ 。施加上述缩放后，进入更新与减更新的向量对变为 αu 与 $\frac{m}{\alpha}$ 。扰动本身完全不变，两个向量的数值量级却得到了均衡。实践中取

$$\alpha = \sqrt{\frac{\|m\|_2}{\|u\|_2}}, \quad (31)$$

它恰好使 αu 与 $\frac{m}{\alpha}$ 的范数相等。自适应缩放显著压低了极端的中间量：例如在 IEEE 300 节点系统上，最大的中间量级由约 10^{10} 降到约 10^5 。

我们分别在 fp32 与 fp64 精度下评测了原始更新与自适应更新。实验覆盖 IEEE 57、118、300 三个节点系统上的全部 $N-1$ 与 $N-2$ 故障场景，以及一部分 $N-3$ 场景。若序贯 Cholesky 更新在相应浮点精度下无法完成，该场景即计为一次失败。

系统	故障场景	场景数	FP32 失败数		FP64 失败数	
			原始	自适应	原始	自适应
57-bus	$N-1$	79	68 (86.1%)	0 (0.0%)	0 (0.0%)	0 (0.0%)
57-bus	$N-2$	3024	2973 (98.3%)	0 (0.0%)	0 (0.0%)	0 (0.0%)
57-bus	$N-3$	6048	–	0 (0.0%)	–	0 (0.0%)
118-bus	$N-1$	177	174 (98.3%)	0 (0.0%)	0 (0.0%)	0 (0.0%)
118-bus	$N-2$	15502	15501 (99.9%)	0 (0.0%)	0 (0.0%)	0 (0.0%)
118-bus	$N-3$	31004	–	0 (0.0%)	–	0 (0.0%)
300-bus	$N-1$	322	303 (94.1%)	1 (0.3%)	2 (0.6%)	0 (0.0%)
300-bus	$N-2$	51559	51405 (99.7%)	279 (0.5%)	641 (1.2%)	0 (0.0%)
300-bus	$N-3$	103118	–	558 (0.5%)	–	0 (0.0%)

表 3 原始 Cholesky 更新与自适应 Cholesky 更新在 fp32 与 fp64 精度下的失败次数。括号中的百分比为失败场景占被测故障场景总数的比例。

表 3 表明，原始序贯更新在 fp32 下极不稳定，在 $N-1$ 与 $N-2$ 场景上几乎不可用。fp64 明显改善了稳定性，但原始更新在 IEEE 300 节点系统上仍会出现少量失败。相比之下，自适应缩放把所有被测系统与故障层级上的 fp64 失败全部消除；在 fp32 下，它也彻底解决了 57 与 118 节点系统的失败，只在更大的 300 节点系统上留下很低的失败率。可见序贯 Cholesky 更新的数值稳定性问题能够由自适应缩放有效压制，而低秩扰动的精确形式与理论更新结构都不受影响。

附录 C 最小成本燃气输运问题

本文进一步在最小成本燃气输运问题上验证所提方法，算例取自 GasLib-135 基准 [43]。给定燃气网络 $G = (V, E)$ ：节点 $v \in V$ 表示一个供气点或需求点，边 $e \in E$ 各带容量上界与输运成本。优化目标是在满足节点流量平衡约束与边容量约束的前提下，寻求成本最低的流量分配方案。每个测试实例对应一种运行场景，需求水平互不相同，拓扑也可能改变，例如删去某条边或计入故障。为考察不同网络工况下的泛化能力，已见与未见场景一并纳入评估。优化问题建模如式 (32)：

$$\begin{aligned}
& \min_{\mathbf{g}^{(k)}, \mathbf{f}^{(k)}} \sum_{s \in \mathcal{S}} \alpha_s g_s^{(k)} + \sum_{\ell \in \mathcal{L}^{(k)}} \rho_\ell |f_\ell^{(k)}| \\
& \text{s.t.} \quad \sum_{s \in \mathcal{S}(v)} g_s^{(k)} + \sum_{\ell \in \mathcal{L}^{(k)}} A_{v\ell}^{(k)} f_\ell^{(k)} = d_v, \quad \forall v \in \mathcal{V} \setminus \{v_{\text{ref}}\} \\
& \quad \sum_{s \in \mathcal{S}} g_s^{(k)} = \sum_{r \in \mathcal{R}} d_r \\
& \quad 0 \leq g_s^{(k)} \leq \bar{g}_s, \quad \forall s \in \mathcal{S} \\
& \quad -\bar{f}_\ell \leq f_\ell^{(k)} \leq \bar{f}_\ell, \quad \forall \ell \in \mathcal{L}^{(k)} \\
& \quad k \in \{0\} \cup \mathcal{K}.
\end{aligned} \tag{32}$$

其中

$$\mathcal{L}^{(0)} = \mathcal{L}, \quad \mathcal{L}^{(k)} = \mathcal{L} \setminus \{k\}, \quad k \in \mathcal{K}.$$

方法	前向时间 (ms)	最大等式违背	最大不等式违背	最优性间隙 (%)
HGNN	3.810 ± 2.074	473.6 / 2337.0	100.5 / 416.8	0.008 / 0.009

表 4 HGNN 单独预测在最小成本燃气输运问题上的预测质量。除前向时间外，各指标均按“已见 / 未见”格式给出。

方法	等式投影 (ms)	等式加速比	不等式迭代	不等式时间 (ms)	不等式加速比	SKM 时间 (ms)	SKM 加速比	最优性间隙 (%)
T-SKM	2.19 ± 1.06	$1.00 \times$	15.21 (128)	0.96 ± 1.22	$1.00 \times$	3.15	$1.00 \times$	0.006 / 0.019
AT-SKM	0.53 ± 0.35	$4.13 \times$	5.33 (78)	0.37 ± 0.71	$2.59 \times$	0.90	$3.50 \times$	0.006 / 0.019

表 5 SKM 层在最小成本燃气输运问题上的性能。最优性间隙给出均值，格式为“已见 / 未见”。

由表 4 可见，只用 HGNN 预测时平均最优性间隙很小，最坏情形下的等式与不等式违背却相当严重，未见场景尤其如此；仅靠神经网络的直接预测，达不到安全攸关约束优化对可行性的要求。

表 5 则显示，T-SKM-Net 与 AT-SKM-Net 在已见与未见场景上均做到零等式违背、零不等式违背。相对 T-SKM-Net，AT-SKM-Net 把等式投影时间由 2.19 ms 压到 0.53 ms，加速 4.13 $\times$ ；不等式迭代时间由 0.96 ms 降到 0.37 ms，加速 2.59 $\times$ 。总体来看，SKM 的总计算时间从 3.15 ms 缩短至 0.90 ms，相当于 3.50 $\times$ 的加速，严格可行性得以保持，平均最优性间隙也基本持平。

附录 D N-1 安全约束直流最优潮流的实验设置与附加结果

D.1 N-1 安全约束直流最优潮流的数学建模

N-1 安全约束直流最优潮流问题要确定最优的机组出力分配，使总运行成本最小，同时保证系统在正常运行方式和任一单条线路断开后都保持可行。记 $\mathcal{K}$ 为所考虑的全部场景集合，其中 $k = 0$ 表示基础运行方式，其余每个 $k \in \mathcal{K}$ 各对应一条具体的线路断开故障场景。在给定场景 k 下网络拓扑随之改变：用 $\mathcal{L}^{(k)}$ 表示该拓扑下仍在运行的线路集合，用 $\mathcal{N}^{(k)}(i)$ 表示该拓扑下节点 i 的相邻节点集合。优化问题表述如下：

$$\begin{aligned} \min_{P_G, \delta} \quad & \sum_{i \in \mathcal{G}} \left(\frac{1}{2} c_i P_{G,i}^2 + b_i P_{G,i} \right) \\ \text{s.t.} \quad & P_{G,i} - P_{D,i} = \sum_{j \in \mathcal{N}^{(k)}(i)} B_{ij} (\delta_i^{(k)} - \delta_j^{(k)}), \quad \forall i \in \mathcal{B}, \forall k \in \{0\} \cup \mathcal{K} \\ & P_{G,i}^{\min} \leq P_{G,i} \leq P_{G,i}^{\max}, \quad \forall i \in \mathcal{G} \\ & -P_{ij}^{\max} \leq B_{ij} (\delta_i^{(k)} - \delta_j^{(k)}) \leq P_{ij}^{\max}, \quad \forall (i, j) \in \mathcal{L}^{(k)}, \forall k \in \{0\} \cup \mathcal{K} \end{aligned} \quad (33)$$

其中集合 $\mathcal{B}$ 、 $\mathcal{G} \subseteq \mathcal{B}$ 与 $\mathcal{L}$ 依次表示节点、机组与输电线路。决策变量由各机组的有功出力 $P_G = \{P_{G,i}\}_{i \in \mathcal{G}}$ 和每个场景下的电压相角 $\delta^{(k)} = \{\delta_i^{(k)}\}_{i \in \mathcal{B}}$ 组成。需要强调的是：出力分配 P_G 是预防性的、在所有场景之间共用，而系统状态 $\delta^{(k)}$ 则随各自拓扑分别调整。目标函数里， c_i 与 b_i 分别是机组 i 的二次与线性成本系数； $P_{D,i}$ 表示节点 i 的有功负荷； B_{ij} 为线路电纳，取正值 $\frac{1}{X_{ij}}$ 。对非机组节点 $i \in \mathcal{B} \setminus \mathcal{G}$ ，令 $P_{G,i} = 0$ 。 $P_{G,i}^{\min/\max}$ 与 $P_{ij}^{\max}$ 分别给出机组容量限值与线路热稳定限值。

D.2 N-1 故障场景数据集的生成

为检验所提方法的有效性，我们以 IEEE 57、118 与 300 节点系统作为实验基准。构建 N-1 故障场景数据集时，先对所有可能的单线断开场景做筛选，只保留物理上可行的场景：这里可行是指故障后拓扑保持连通、没有形成孤岛，且 OPF 求解器能收敛到可行解。表 6 汇总了各测试系统的统计信息，包括节点数、支路总数，以及筛选后连同基础场景一并计入的有效 N-1 场景数。

对每个选定的拓扑场景，我们通过对节点负荷施加随机扰动，生成 100 个相互独立的运行实例。具体做法是把基准负荷向量整体随机缩放：

$$P_D^{(i)} = \alpha_i \cdot P_D^{\text{base}}, \quad \alpha_i \sim \mathcal{U}(0.8, 1.2), \quad (34)$$

其中 P_D^{base} 为基准负荷值， α_i 是取自区间 $[0.8, 1.2]$ 上均匀分布的随机缩放系数。这一生成流程使数据集覆盖了足够宽的负荷波动范围。

关于数据集划分：为考察模型对未见故障场景的泛化能力，我们把全部有效 N-1 场景随机分成两个子集，70% 作为训练阶段的已见场景，其余 30% 作为未见场景。训练集只包含由已见场景生成的样本，测试集则同时覆盖已见与未见拓扑上的实例。

测试系统	节点数	支路数	可移除支路	场景数	β	ρ
IEEE 57 节点	57	80	79	80	10	0.8
IEEE 118 节点	118	186	177	178	50	0.8
IEEE 300 节点	300	411	322	323	60	0.8

表 6 N-1 故障场景数据集与 SKM 采样的超参数设置。

D.3 实验超参数与损失函数配置

模型结构与训练配置方面，采用的异构图神经网络 (HGNN) 含两层消息传递层，隐藏维度统一设为 128。训练用 Adam 优化器，初始学习率为 $5e-4$ ，并施加 StepLR 调度器实现阶梯衰减：

$$\eta_t = \eta_0 \cdot \gamma^{\lfloor \frac{t}{S} \rfloor}, \quad (35)$$

其中 η_0 为初始学习率， $S = 25$ 为步长， $\gamma = 0.8$ 为衰减系数。训练阶段的批大小为 64；测试阶段的批大小为 1，以模拟对单个样本做实时推断的真实场景。

复合损失函数由回归损失与分类损失两部分构成。沿用 T-SKM 的做法 [15]，回归损失取均方误差 (MSE)，并按投影前与投影后两项加权求和：

$$L_{\text{reg}} = 0.9 \cdot \text{MSE}(\hat{\mathbf{y}}_{\text{pre}}, \mathbf{y}) + 0.1 \cdot \text{MSE}(\hat{\mathbf{y}}_{\text{proj}}, \mathbf{y}), \quad (36)$$

这里 $\hat{\mathbf{y}}_{\text{pre}}$ 是模型的原始输出， $\hat{\mathbf{y}}_{\text{proj}}$ 是约束投影之后的输出。二者组合让模型先学到主要的特征映射，同时促使输出满足物理约束。

有效集预测任务用 Binary Focal Loss 来处理正负样本不均衡的问题 [44]：

$$L_{\text{focal}(p_t)} = -\alpha_t(1 - p_t)^\gamma \log(p_t), \quad (37)$$

其中 p_t 是模型对真实类别的估计概率。聚焦参数 $\gamma = 2.0$ 下调容易分类样本的权重，平衡参数 $\alpha = 0.5$ 则调节正负样本的相对重要性。总损失函数为：

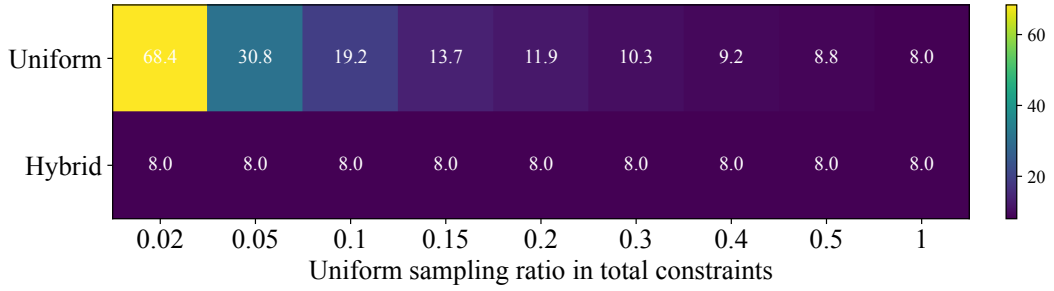
$$L_{\text{total}} = L_{\text{reg}} + \lambda(t) \cdot L_{\text{cls}}. \quad (38)$$

其中 $\lambda(t)$ 采用线性 warmup 调度，在前 40 个训练轮次内由 0 线性增大到 1。这样，模型在训练初期专注于回归任务，分类目标随后才逐步纳入优化。

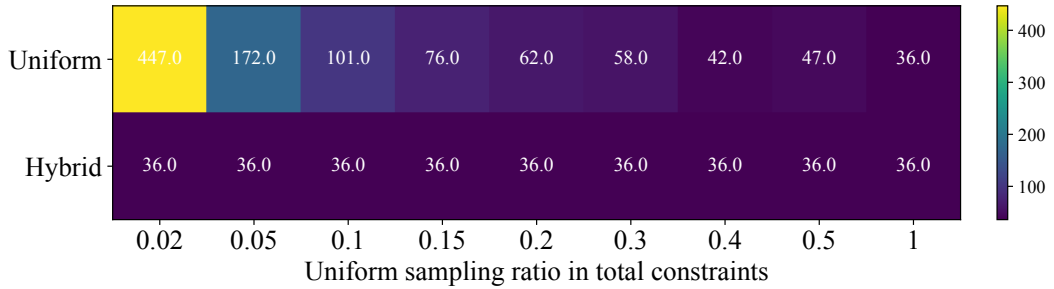
有效集标签按相对松弛量判据生成。对双边不等式 $l_i \leq g_{i(x)} \leq u_i$ ，若某约束到任一边界的松弛量小于可行区间 $u_i - l_i$ 的 1%，就把该约束标记为有效。该阈值只用于训练有效集预测器。每次迭代采样的约束数目约为约束总数的 10%。各测试系统下采样批规模 β 与混合采样比例 ρ 的具体配置见表 6。

D.4 混合采样策略的超参数敏感性

为考察所提有效集预测方法对批规模参数的敏感性，我们用真值数据做了一组受控实验。这一设置假定预测器是完美的：直接取最优解对应的真实有效集来引导采样过程。我们在 IEEE 118 节点系统上比较了均匀采样与真值引导的混合采样在不同采样比例下的收敛表现。

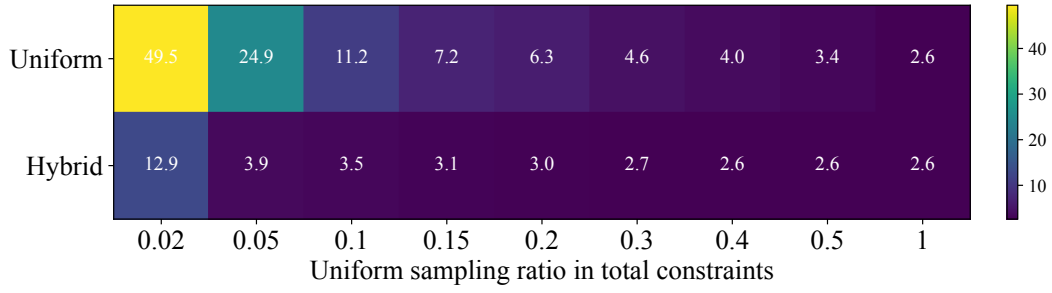


(a) IEEE 118 节点：平均迭代次数

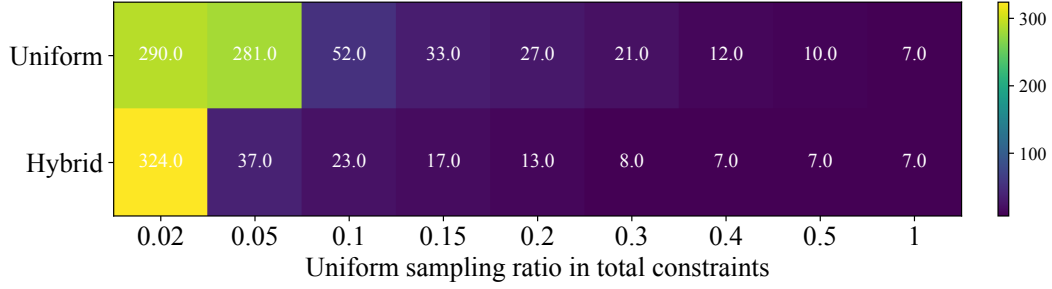


(b) IEEE 118 节点：最大迭代次数

图 3 在具备完美预测器的条件下，IEEE 118 节点系统上采样策略的敏感性分析：均匀采样与真值引导的混合采样在不同采样比例下的对照。



(a) IEEE 300 节点: 平均迭代次数



(b) IEEE 300 节点: 最大迭代次数

图 4 IEEE 300 节点系统上的同一组对照实验, 条件与图 3 相同。

两幅图给出敏感性分析的结果, 其中 SKM 迭代过程以 HGNN 预测出的解作为初值。

图 3 显示, IEEE 118 节点系统上只要有效集识别准确, 混合采样就十分稳定: 无论额外随机采样占多大比例, 平均与最大迭代次数都压在很低水平。真实有效约束一旦被覆盖, 算法便基本不受海量非有效约束的干扰。

在规模更大的 IEEE 300 节点系统 (图 4) 上, 混合策略相对均匀采样的收敛加速要陡峭得多。只需掺入极少量的随机采样, 迭代次数就能迅速降到最优水平。其中最大迭代次数那一幅 (子图 b) 尤其说明问题: 混合策略有效压住了最坏情形, 达到同等表现所需的采样量只有均匀采样方案的约十分之一, 而后者需要扫描整个约束集。

D.5 AT-SKM-Net 在 SC DC-OPF 问题上的详细耗时分解

模型与实验设置与主文 SC DC-OPF 部分完全相同, 这里把 T-SKM-Net 与 AT-SKM-Net 的运行时拆开细看: 等式投影阶段与不等式 SKM 迭代阶段分别计时, 二者恰好对应由 Cholesky 更新和有效集引导采样所加速的两个主要计算环节。

系统	方法	等式投影时间	等式投影加速比	不等式迭代时间	不等式迭代加速比	SKM 总加速比
57-bus	T-SKM-Net	0.56 ± 0.34	1.00×	0.41 ± 1.20	1.00×	1.00×
57-bus	AT-SKM-AC	0.18 ± 0.02	3.11×	0.06 ± 0.07	6.83×	4.04×
118-bus	T-SKM-Net	1.56 ± 0.06	1.00×	2.13 ± 2.51	1.00×	1.00×
118-bus	AT-SKM-AC	0.30 ± 0.03	5.20×	1.01 ± 1.38	2.11×	2.81×
300-bus	T-SKM-Net	7.65 ± 1.54	1.00×	2.07 ± 4.59	1.00×	1.00×
300-bus	AT-SKM-AC	0.70 ± 0.02	10.92×	0.32 ± 0.20	6.46×	9.53×

表 7 T-SKM-Net 与 AT-SKM-Net 在 SC DC-OPF 问题上的详细耗时分解。AT-SKM-AC 为同时使用有效集引导采样与 Cholesky 更新的完整 AT-SKM-Net, 各时间量以毫秒计。

表 7 显示, 相对 T-SKM-Net, AT-SKM-Net 大幅压缩了等式投影时间, 而且网络规模越大、优势越明显: 等式投影加速比从 57 节点系统的 $3.11 \times$ 一路升到 300 节点系统的 $10.92 \times$ 。这与 Cholesky 更新的理论动机吻合——等式投影所涉约束矩阵越大, 增量的好处越显著。

不等式 SKM 迭代阶段同样变快。与 T-SKM-Net 相比, AT-SKM-Net 在 57、118、300 三个系统上把迭代耗时分别加速 6.83 倍、2.11 倍与 6.46 倍, 来源正是有效集引导采样不再把迭代浪费在非有效或冗余约束

上。三者合起来，AT-SKM-Net 在三个系统上取得的 SKM 总加速比分别为 $4.04 \times$ 、 $2.81 \times$ 与 $9.53 \times$ ，与主文结论一致：框架同时加速等式投影与不等式迭代，且不牺牲严格可行性。

D.6 高负荷运行条件下的鲁棒性

为进一步考察 AT-SKM-Net 的鲁棒性，我们为 SC DC-OPF 另设一组高负荷测试工况。主文实验中负荷扰动取额定负荷的 $[0.8, 1.2]$ 区间，这里把区间接体上移到 $[1.0, 1.2]$ ，使测试实例集中在重载工况。这类算例更难：线路潮流与机组出力上限更容易逼近边界，有效集形态对负荷变化和拓扑变化都更敏感。

系统	方法	等式投影时间	等式加速比	不等式迭代	不等式时间	不等式加速比	SKM 加速比	平均间隙 (%)
57-bus	T-SKM-Net	0.42 ± 0.14	$1.00 \times$	16.00 (133)	0.70 ± 1.22	$1.00 \times$	$1.00 \times$	0.014
57-bus	AT-SKM-AC	0.18 ± 0.04	$2.33 \times$	2.75 (12)	0.13 ± 0.14	$5.38 \times$	$3.61 \times$	0.010
118-bus	T-SKM-Net	1.81 ± 0.59	$1.00 \times$	18.59 (160)	1.45 ± 2.80	$1.00 \times$	$1.00 \times$	0.004
118-bus	AT-SKM-AC	0.37 ± 0.22	$4.89 \times$	9.21 (56)	0.82 ± 1.56	$1.77 \times$	$2.74 \times$	0.004
300-bus	T-SKM-Net	7.05 ± 0.51	$1.00 \times$	25.49 (248)	1.78 ± 3.02	$1.00 \times$	$1.00 \times$	0.136
300-bus	AT-SKM-AC	0.71 ± 0.02	$9.93 \times$	5.34 (28)	0.42 ± 0.58	$4.24 \times$	$7.81 \times$	0.136

表 8 高负荷 SC DC-OPF 工况下 T-SKM-Net 与 AT-SKM-Net 的表现，负荷扰动取自 $[1.0, 1.2]$ ，时间量以毫秒计。“不等式迭代”列为迭代次数的均值，括号内为最大值。

由表 8 可见，重载工况下 AT-SKM-Net 相对 T-SKM-Net 的加速依然清晰。等式投影阶段稳定提速，加速比从 57 节点系统的 $2.33 \times$ 增至 300 节点系统的 $9.93 \times$ ，再次印证 Cholesky 更新随系统规模增大而收益递增。

不等式迭代阶段在重载下同样稳健。与 T-SKM-Net 相比，AT-SKM-Net 把不等式迭代均值从 57 节点系统的 16.00 降到 2.75，118 节点系统从 18.59 降到 9.21，300 节点系统从 25.49 降到 5.34；三个系统的最大迭代次数也同步大幅下降，说明即使大量约束已逼近活跃边界，有效集引导采样仍能压住困难尾部算例。这表明 HGNN 预测器在更紧张的工况下依然有效：热启动预测仍提供有用的初始化，有效集预测也把采样集中到最相关的约束上。最终 AT-SKM-Net 在 57、118、300 三个系统上的 SKM 总加速比分别为 $3.61 \times$ 、 $2.74 \times$ 、 $7.81 \times$ ，平均最优间隙与 T-SKM-Net 相当。

D.7 有效集预测质量

系统	准确率	精确率	召回率
IEEE 57-Bus	0.9995 / 0.9995	0.9814 / 0.9802	0.9804 / 0.9815
IEEE 118-Bus	0.9995 / 0.9995	0.9988 / 0.9989	0.9948 / 0.9940
IEEE 300-Bus	0.9991 / 0.9991	0.9647 / 0.9649	0.9834 / 0.9834

表 9 测试集上“已见 / 未见”场景的有效集预测性能。

灵敏度分析给出的只是理论上的加速潜力，能否落地取决于预测器的实际判别能力，为此我们评测 HGNN 预测器的分类性能。

表 9 列出三个系统上的准确率、精确率与召回率，并按“已见”“未见”场景分别统计，用以考察模型的泛化能力。

有效约束在总约束里只占极小比例，却严格决定了最优解，漏掉一条紧约束就足以让收敛停滞，因此召回率是最关键的指标。表 9 中 HGNN 在全部系统上的召回率都超过 98%，这样高的覆盖率保证预测器几乎收齐了确定有效流形所需的全部紧约束，SKM 于是可以专注在可行边界上，不必再靠随机探索去补漏。如此召回水平也为假设 2 中的覆盖条件 $\mathcal{A}^* \subseteq \hat{\mathcal{A}}$ 提供了经验支持，只是有限测试样本上仍存在很小的预测误差。可靠性之外，精确率稳定在 96.5% 到 99.9% 之间，说明预测出的候选集合紧凑、冗余极少。这种紧凑性对效率不可或缺——一旦掺入过多无效约束，采样概率就会被稀释。同时框架对拓扑变化也保持稳健：已见与未见场景之间的性能差异微乎其微，可见 HGNN 学到的是决定约束激活的物理规律，而非拟合特定模式。正是这一点保证 AT-SKM 在意外线路故障下仍能维持加速效果。

D.8 对有效集扰动的鲁棒性

我们再考察预测有效集不完美时，有效集引导采样策略的稳健程度。实际中有效集预测器的误差分两类：假阴性，即真正有效的约束被从预测池里漏掉；假阳性，即非有效约束被加进预测池。两类误差都会削弱采样引导，但影响并不对称。

为把两种效应分开，我们基于 oracle 有效集设计二维扰动实验：从真有效集出发，随机丢弃一定比例的真有效约束，同时加入一定数量的非有效约束，两个比例都以真有效集规模归一化；随后用扰动后的有效集池运行 SKM 层，报告不等式迭代次数的均值。

添加比例	丢弃比例						
	0.00	0.05	0.10	0.15	0.20	0.25	0.50
0.0	15.68	18.04	20.02	22.71	24.41	24.71	29.61
0.5	15.85	20.64	29.60	33.44	39.12	39.71	42.53
1.0	16.37	21.41	29.04	35.27	37.91	42.79	64.02
1.5	17.04	21.34	27.89	35.81	39.81	41.90	63.72
2.0	17.64	22.10	30.32	36.28	41.06	42.42	63.08
3.0	19.12	24.32	31.16	36.93	41.80	44.11	65.27

表 10 IEEE 118 节点系统上有效集扰动导致的 SKM 不等式迭代次数均值。行为加入的非有效约束比例，列为丢弃的真有效约束比例，两者均以真有效集规模归一化。

添加比例	丢弃比例						
	0.00	0.05	0.10	0.15	0.20	0.25	0.50
0.0	3.69	4.15	7.68	8.88	10.99	13.96	19.24
0.5	3.69	4.51	9.65	10.39	14.43	16.55	23.97
1.0	3.72	4.78	11.53	12.50	17.17	23.93	33.14
1.5	3.77	5.25	12.03	13.27	20.15	24.80	39.51
2.0	3.80	4.79	13.36	15.24	23.41	28.90	43.07
3.0	4.04	5.79	17.90	21.70	34.99	40.32	69.75

表 11 IEEE 300 节点系统上有效集扰动导致的 SKM 不等式迭代次数均值。行为加入的非有效约束比例，列为丢弃的真有效约束比例。

表 10 与 表 11 说明，假阳性与假阴性都会拖累有效集引导采样的效率，但丢弃真有效约束通常比加入非有效约束更有害。IEEE 118 节点系统上，在不加入非有效约束时，丢弃比例从 0 增至 0.5 会让迭代均值从 15.68 升到 29.61；反过来，在不丢弃真有效约束时，加入比例从 0 增至 3.0 只让迭代均值从 15.68 升到 19.12。IEEE 300 节点系统趋势相同：丢弃比例从 0 到 0.5 时迭代均值由 3.69 升到 19.24，而加入比例从 0 到 3.0 时仅由 3.69 升到 4.04。作为参照，原始 T-SKM-Net 在 IEEE 118 节点系统上需要 34.60 次不等式迭代，在 IEEE 300 节点系统上需要 24.72 次。

这一现象与 SKM 的更新规则相符。每次迭代中，SKM 采样一个约束子集，并在子集内最违背的约束上做投影。因此非有效的假阳性约束未必造成有害投影，其主要作用是稀释采到真有效约束的概率；假阴性则把真有效约束从引导采样池里剔除，只能靠均匀采样分支把它们重新找回来。

设约束总数为 m ，预测有效集池的规模为 s ，引导分支与均匀分支的采样规模分别为 β_g 和 β_u 。对一条仍留在预测池中的真有效约束，它被采到的概率为

$$p_{\text{keep}} = \frac{\beta_g}{s} + \left(1 - \frac{\beta_g}{s}\right) \frac{\beta_u}{m - \beta_g} > \frac{\beta_g}{s}. \quad (39)$$

若这条有效约束被错误地从预测池中丢弃，它就只能由均匀分支选中：

$$p_{\text{drop}} = \frac{\beta_u}{m - \beta_g}. \quad (40)$$

由此可见，加入 Δ 条非有效约束，主要作用是把引导采样概率从 $\frac{\beta_g}{s}$ 稀释到 $\frac{\beta_g}{s+\Delta}$ ；丢弃一条真有效约束，却是把它从引导分支挪到均匀分支，采样概率由大约 $\frac{\beta_g}{s}$ 降到 $\frac{\beta_u}{m-\beta_g}$ 。在我们的设置下，预测有效集池远小于完整约束集，且引导采样比例满足 $\rho > \frac{1}{2}$ ，于是

$$\frac{\frac{\beta_u}{m-\beta_g}}{\frac{\beta_g}{s+\Delta}} = \frac{1-\rho}{\rho} \cdot \frac{s+\Delta}{m-\beta_g} \ll 1. \quad (41)$$

这正解释了丢弃真有效约束为何比加入非有效约束更具破坏性。同时扰动结果也表明，AT-SKM-Net 在轻度有效集预测误差下仍然稳健，即便预测池中含有中等数量的假阳性，引导采样策略依旧能提供加速。

D.9 迁移学习与伪标签有效集训练

主文实验用的是求解器参考解指导下的监督训练，但 AT-SKM-Net 并不要求在全部分训实例上都拿到精确最优解。整个框架只依赖两类加速部件：一是供等式投影与 SKM 迭代使用的热启动候选，二是引导不等式采样的有效集评分，两者都能在较弱监督下训练或适配。

热启动分支方面, T-SKM-Net 的已有工作表明, 预测器无需求解器真值就能训练——直接优化目标函数并叠加约束违背惩罚即可。有效集预测分支同样不必严格要求求解器给出的有效集标签: 这一分支只用于把 SKM 的采样分布偏向可能激活的约束, 因此可以用模型自身修正出的解来构造伪标签。具体做法是, 对每个目标样本, 迁移后的模型先给出热启动解, SKM 层把它修正为可行解, 再取该修正解的有效约束作为伪标签, 反过来重训有效集预测头。

为验证这一思路, 我们设置两种迁移场景: 从 IEEE 57 节点系统迁到 IEEE 118 节点系统, 以及从 IEEE 118 节点系统迁到 IEEE 300 节点系统。每个场景先在较小系统上训练源模型, 再迁移到较大的目标系统; 随后冻结共享的 HGNN 主干与热启动输出分支, 只用 5% 的目标 $N-1$ 场景重训有效集预测头。关键在于, 这些预测头不使用求解器导出的有效集标签, 而用模型自身修正后的 SKM 输出生成的伪标签。

迁移设定	方法	等式投影时间	等式加速比	不等式迭代	不等式时间	不等式加速比	SKM 加速比	间隙 (%)
57 $\rightarrow$ 118	T-SKM-Net	1.54 $\pm$ 0.02	1.00 $\times$	57.31 (148)	5.93 $\pm$ 7.07	1.00 $\times$	1.00 $\times$	0.009
57 $\rightarrow$ 118	AT-SKM-AC	0.28 $\pm$ 0.02	5.50$\times$	29.28 (59)	1.96 $\pm$ 1.58	3.02$\times$	3.33$\times$	0.009
118 $\rightarrow$ 300	T-SKM-Net	7.01 $\pm$ 0.08	1.00 $\times$	30.83 (218)	2.06 $\pm$ 2.53	1.00 $\times$	1.00 $\times$	0.618
118 $\rightarrow$ 300	AT-SKM-AC	0.74 $\pm$ 0.05	9.47$\times$	6.30 (18)	0.51 $\pm$ 0.54	4.03$\times$	7.26$\times$	0.590

表 12 伪标签有效集训练下的迁移学习结果, 时间量以毫秒计。57 $\rightarrow$ 118 表示从 IEEE 57 节点系统迁移到 IEEE 118 节点系统。

表 12 显示, 有效集预测头仅用伪标签训练时, AT-SKM-AC 仍保有可观的加速。57 $\rightarrow$ 118 场景下, 不等式迭代均值由 57.31 降至 29.28, 最坏情形迭代次数由 148 降至 59; 更难的 118 $\rightarrow$ 300 场景下, 迭代均值由 30.83 降至 6.30, 最坏情形由 218 降至 18。可见迁移到更大系统之后, 伪标签有效集学习仍能提供有用的采样引导。

运行时结果呈同一趋势。57 $\rightarrow$ 118 场景中, AT-SKM-AC 的等式投影加速 5.50 $\times$, 不等式迭代加速 3.02 $\times$, SKM 总加速 3.33 $\times$; 118 $\rightarrow$ 300 场景对应的三项加速分别为 9.47 $\times$ 、4.03 $\times$ 与 7.26 $\times$ 。与此同时, 最优间隙与 T-SKM-Net 处于同一水平: 57 $\rightarrow$ 118 两者同为 0.009%, 118 $\rightarrow$ 300 为 0.590% 对 0.618%。由于最终输出都经过投影层与 SKM 层修正, 两种方法在修正后都保持严格的约束可行性。

由此看来, 在当前实现中, 监督真值解只是训练上的一个选择, 而非 AT-SKM-Net 的根本前提。当大规模系统上求解器标签代价过高或数量不足时, 模型依然可以从小系统迁移过来, 用自生成的伪标签训练有效集预测器, 从而在保住严格可行性的同时留下大部分加速收益。